

PROYECTO DE GRADO

INSTITUTO DE COMPUTACIÓN  
FACULTAD DE INGENIERÍA  
UNIVERSIDAD DE LA REPÚBLICA

---

# Representación de Palabras en Espacios de Vectores

---

Agustín AZZINNARI (aazzinnari@gmail.com)  
Alejandro MARTÍNEZ (ale.martinez.uy@gmail.com)

Tutores:  
Mathías Etcheverry  
Dina Wonsever

Mayo de 2016

## **Resumen**

abstract

# Índice general

<b>1</b>	<b>Introducción</b>	<b>5</b>
1.1	Objetivos del Proyecto . . . . .	6
1.2	Estructura del Informe . . . . .	8
<b>2</b>	<b>Representación Vectorial de Palabras</b>	<b>9</b>
2.1	Conceptos Básicos . . . . .	9
2.2	Modelos Estadísticos . . . . .	13
2.3	Modelos Neuronales . . . . .	18
2.4	Modelos Híbridos . . . . .	24
2.5	Evaluación y Estado del Arte . . . . .	26
<b>3</b>	<b>Corpus</b>	<b>31</b>
3.1	Estado del Arte . . . . .	31
3.1.1	Análisis de proyectos existentes . . . . .	32
3.1.2	Conclusiones . . . . .	38
3.2	Proceso de Construcción . . . . .	38
3.2.1	Requerimientos . . . . .	39
3.2.2	Relevamiento de Fuentes de Palabras . . . . .	41
3.3	Implementación . . . . .	48
3.4	Resultado . . . . .	58
3.4.1	Composición del Corpus . . . . .	58
3.4.2	Calidad del Corpus . . . . .	59
<b>4</b>	<b>Herramienta</b>	<b>61</b>
4.1	Requerimientos . . . . .	61
4.2	Diseño de la Solución . . . . .	63
4.2.1	Dashboard . . . . .	64
4.2.2	Corpus . . . . .	65
4.2.3	Embeddings . . . . .	66
4.2.4	Tests . . . . .	68
4.3	Implementación . . . . .	70

---

4.3.1	Arquitectura General . . . . .	70
4.3.2	Backend . . . . .	72
4.3.3	Frontend . . . . .	82
<b>5</b>	<b>Evaluación</b>	<b>89</b>
5.1	Modelos Entrenados . . . . .	89
5.2	Comparación con la Literatura . . . . .	97
5.3	Comportamiento Específico al Español . . . . .	105
5.4	Análisis Cualitativo de Resultados . . . . .	111
<b>6</b>	<b>Conclusiones y Trabajo Futuro</b>	<b>115</b>
6.1	Conclusiones . . . . .	116
6.2	Trabajo Futuro . . . . .	116



# Capítulo 1

## Introducción

El tratamiento de lenguaje natural (PLN) por parte de computadoras ha sido siempre un punto de gran interés de la comunidad. Desde los trabajos de John McCarthy y Marvin Minsky en los años 1950 hasta la actualidad, se han publicado miles de trabajos al respecto. Históricamente han habido dos paradigmas para el tratamiento del lenguaje: uno basado en reglas y otro en aprendizaje automático.

El primer enfoque busca construir reglas que capturen el conocimiento de expertos en lingüística para resolver una problemática particular, construyendo reglas que generalicen lo suficiente pero sin dejar de lado los casos particulares. Mientras que ambos enfoques se desarrollaron paralelamente, no fue hasta la adopción masiva de Internet, junto con los inmensos volúmenes de texto que consecuentemente se generaron, que los métodos de aprendizaje automático comenzaron a ser significativamente más exitosos.

Todas las tareas en el área de PLN involucran, en algún nivel, trabajar con palabras. Dado que muchos de los algoritmos de aprendizaje automático utilizados como soluciones de dichas tareas se alimentan de vectores (como lo hacen los modelos de aprendizaje profundo o las técnicas de regresión), es usual requerir de un mecanismo para traducir de unas a otros.

La forma más simple de realizar esta traducción es posiblemente asociarle, a cada palabra, un vector bajo un esquema *one-hot*: esto es, a cada palabra se le asigna un vector donde todas las componentes son cero salvo por un uno en la correspondiente a la palabra. Sin embargo, puesto que todos los vectores

resultan equidistantes, esta representación no tiene la capacidad de generalizar bien: las palabras *el* y *lenguaje* están a la misma distancia que *el* y *de*, por lo que se pierde información de su función sintáctica y semántica. Por esta razón, la búsqueda de métodos que asignen representaciones parecidas a palabras relacionadas es un área de investigación de particular interés.

Basándose en la hipótesis distribucional de Harris [44], la cual plantea que palabras que ocurren en contextos similares tienen significados similares, se han desarrollado históricamente una gran cantidad de métodos para realizar la tarea de traducción, principalmente basados en construir una matriz de coocurrencias la cual asocia, a cada par de palabras del vocabulario, una medida de similitud obtenida a partir de los contextos en los cuales éstas aparecen juntas. Estos métodos, donde entran técnicas como el análisis semántico latente (LSA), logran resultados relativamente satisfactorios.

Sin embargo, recientemente ha surgido una nueva generación de métodos para representar palabras que, mediante el uso de técnicas inspiradas en el modelado de lenguaje mediante redes neuronales, han logrado resultados sorprendentes para la comunidad del PLN. Estos algoritmos se basan en métodos de aprendizaje automático no supervisado que, a partir de grandes volúmenes de texto, consiguen representaciones vectoriales con una fuerte capacidad de almacenar información sintáctica y semántica. Entre los modelos más conocidos de este grupo se encuentran los propuestos por Mikolov et al. [80, 75, 76], *Skipgram* y *CBOW*, comúnmente referidos bajo el nombre `word2vec`.

Una de las grandes atracciones de `word2vec` es la capacidad de los modelos generados de expresar relaciones sintácticas y semánticas mediante operaciones algebraicas. Quizás el ejemplo más conocido de este fenómeno es la relación que cumplen los vectores de las palabras *reina*, *rey*, *mujer*, y *hombre*, donde el primer vector puede ser aproximadamente recuperado de los siguientes mediante la relación  $reina \approx rey - hombre + mujer$ . A partir del surgimiento de `word2vec`, se ha reinvigorizado la investigación en el área, y se han publicado numerosos artículos estudiando los modelos y proponiendo variantes de los mismos.

## 1.1. Objetivos del Proyecto

En este marco es que surge el presente proyecto de grado, el cual plantea, mediante el estudio en profundidad de las técnicas existentes para la represen-

tación vectorial de palabras, los siguientes objetivos:

- La generación de un corpus de texto para el español del orden de dos mil millones de palabras. Dado que los algoritmos anteriormente mencionados requieren de grandes cantidades de texto, es necesario como primer paso del proyecto -y de cualquier investigación en el área-, generar un corpus de tales características. Para la obtención del mismo se deberá realizar crawling masivo en la web, pues no existen corpus semejantes para el español de forma libre.
- La creación de una herramienta que permita, de una manera simple y con una interfaz accesible, explorar el corpus generado de manera interactiva, pudiendo realizar búsquedas sobre el mismo. La herramienta también brindará acceso a un servidor de cómputo especializado que permitirá entrenar algoritmos de modelado de manera remota, pudiendo almacenar allí todos los datos y descargarlos en la medida que sea necesario. Ofrecerá a su vez la posibilidad de evaluar la calidad de los modelos masivamente sobre diferentes conjuntos de pruebas, y permitirá la visualización de esta información fácilmente.
- La construcción de un conjunto de datos de evaluación que permitan analizar la calidad de las representaciones logradas, mediante la traducción de los principales conjuntos de pruebas utilizados en la literatura en inglés, para poder formar así una idea de cómo se diferencia el comportamiento de los modelos en el idioma español. También se crearán nuevos datos de prueba especializados en el lenguaje de estudio que tengan en cuenta las particularidades del mismo, sobretodo en el ámbito sintáctico.
- La comparación de la calidad de las representaciones obtenidas de los distintos modelos de representaciones para el español, estudiando así la existencia de particularidades de un lenguaje sobre otro que influyeran en el comportamiento de los modelos entrenados.
- Dejar disponible una infraestructura que ayude a futuras investigaciones en el área a no partir de cero, dejando como fruto los resultados de los anteriores puntos mencionados. De particular interés es brindar acceso a modelos vectoriales previamente entrenados, así como dejar un corpus que permita obtener nuevas representaciones que sean competitivas con el estado del arte. Con la herramienta creada, se pretende facilitar el entrenamiento de vectores especializados para distintas tareas del PLN.



## 1.2. Estructura del Informe

El presente informe se estructura de la siguiente forma: en el capítulo 2 se realiza un relevamiento del estado del arte para la construcción de representaciones vectoriales de palabras, dando una clasificación de los métodos existentes junto a una breve descripción de los mismos. Se busca que al finalizar este capítulo el lector conozca las técnicas principales y qué resultados éstas obtienen.

El capítulo 3 describe el proceso de construcción del corpus de texto, y se realiza un relevamiento de la literatura en construcción de corpus para el español. Se describen las técnicas empleadas, la infraestructura utilizada, y los problemas enfrentados. Se detalla la composición del corpus generado, junto a un breve análisis de su calidad.

En el capítulo 4 se presenta la herramienta construida, con sus objetivos iniciales y decisiones de diseño. Se describen sus funcionalidades y se procede a detallar los principales aspectos de su implementación.

El capítulo 5 se exponen los resultados de las evaluaciones realizadas. Se comienza por presentar la metodología empleada y los conjuntos de prueba construidos, y finalmente se realiza una comparación con el estado del arte en otros idiomas.

Por último, el capítulo 6 plantea las conclusiones y propuestas para trabajo futuro.

## Capítulo 2

# Representación Vectorial de Palabras

En esta sección se pretende realizar una recorrida por la literatura en el área de representación vectorial de palabras, un tema que se ha ubicado en los últimos años en el centro de la escena en muchas tareas de PLN. Se dará un pantallazo de qué entendemos por representaciones vectoriales, de dónde surgen, y cuáles son los principales trabajos asociados a su desarrollo, mediante un tratamiento más bien superficial que permita poner en perspectiva el trabajo que se realiza en el presente proyecto de grado.

### 2.1. Conceptos Básicos

En los últimos años ha habido un importante cambio de paradigma en PLN, donde la mayor investigación, y el mayor éxito, se ha obtenido con la aplicación de métodos de aprendizaje automático para el tratamiento del lenguaje, en oposición a métodos basados en reglas.

Los métodos de aprendizaje automático son técnicas principalmente estadísticas que manipulan vectores, por lo general reales. Dado que la unidad semántica básica del lenguaje natural, las palabras<sup>1</sup>, son entidades discretas y de gran cardinalidad, es necesario realizar un mapeo entre estos dos espacios. Por esta razón es que existe un gran interés en buscar y caracterizar mecanismos que

---

<sup>1</sup>Se podrían considerar entidades más pequeñas como los morfemas como unidad básica, pero el punto se mantiene.

permitan construir representaciones vectoriales para las palabras del lenguaje.

Formalmente, si  $V$  es el vocabulario con el que se está tratando en un contexto dado (por ejemplo,  $V = \{a, \text{ábaco}, \text{abajo}, \dots\}$ ), decimos que una función  $F : V \rightarrow \mathbb{R}^N$  induce una representación vectorial de dimensión  $N$  para dicho vocabulario si le asigna un vector de  $\mathbb{R}^N$  a cada palabra de  $V$  (e.g.  $F(a) = (1, 1, 0, 9, \dots, 0, 2)$ ,  $F(\text{ábaco}) = (2, 3, 0, 1, \dots, 0, 1)$ ).

La construcción de funciones  $F$  que tengan buenas propiedades es un objeto de estudio muy interesante y por lo tanto muy tratado, pues la performance de una gran cantidad de algoritmos de PLN dependen directamente de la calidad de las mismas. Dependiendo el contexto en que se esté trabajando, puede ser deseable requerirle a  $F$  tener algunas propiedades particulares:

- Puesto que los algoritmos de aprendizaje automático por lo general trabajan con vectores reales continuos, suele ser un punto positivo que palabras que están relacionadas o que tienen significados similares tengan asociados vectores que también sean similares en cierto nivel, pudiendo explotar así la continuidad de los métodos utilizados.

Por ejemplo, imaginemos que se quiere entrenar un clasificador de tópico trivial utilizando *Support Vector Machines* para asociar a cada palabra del vocabulario una etiqueta indicando el tema del que trata (supongamos *Deportes* y *No Deportes*). Será altamente deseable que palabras que suelen aparecer en los mismos contextos estén cerca en el espacio vectorial resultante, asociando vectores más cercanos entre sí a palabras como *tenis*, *fútbol* y *gol* que a palabras como *gato* o *comida*. Así, el algoritmo logrará separar las palabras pertenecientes a ambas categorías más efectivamente.

- Uno de los principales problemas de trabajar con el lenguaje natural es la dimensionalidad de los vocabularios con los que se trata. Por esta razón, otro requerimiento interesante para las representaciones vectoriales es que asocien a las palabras vectores de  $\mathbb{R}^N$  donde  $N \ll |V|$ , logrando así hacer tratables las dimensiones de las entradas.
- Otra alternativa al punto anterior que también hace tratables entradas de dimensiones altas es utilizar representaciones vectoriales dispersas: esto es, que los vectores asociados a las palabras tengan casi todas sus entradas en cero. Esto permite el empleo de técnicas de tratamiento de matrices dispersas, mejorando así la eficiencia desde el punto de vista computacional y de almacenamiento.

- Dado que se está embebiendo un espacio muy rico en estructura, tanto desde el punto de vista semántico como sintáctico, es de particular interés lograr mantener dicha estructura en el espacio de destino: esto es, obtener una representación que exhiba regularidades lingüísticas en alguna medida.

Por ejemplo, sería satisfactorio que la relación que existe entre el par de palabras *correr* y *corriendo* (esto es, el gerundio) pudiera ser capturada matemáticamente, y que fuera el mismo que presentan las palabras *jugar* y *jugando*. O, desde un punto de vista semántico, que el par de palabras *frío* y *calor* presente las mismas propiedades que *alto* y *bajo*.

Desde las distintas áreas del PLN se han desarrollado una gran cantidad de métodos para la construcción de representaciones vectoriales que cumplan con algunas de las propiedades anteriores, donde el elemento común suele ser la utilización de grandes cantidades de texto a partir del cuál inferir buenas representaciones. Por esta razón, las representaciones vectoriales suelen recibir diversos nombres, dependiendo de la literatura consultada.

Uno de los enfoques más tradicionales recibe el nombre de *modelos semánticos distribucionales* (o DSMs por su sigla en inglés) los cuales, inspirados en el campo de la semántica estadística y la hipótesis distribucional [44], hacen uso de estadísticas globales derivadas de un corpus de texto para aprender representaciones que capturen la semántica de las palabras. En este grupo de técnicas se puede encontrar el modelo LSA [30, 27], junto con sus principales variantes, y el modelo HAL [54, 64].

El otro gran enfoque en la construcción de representaciones vectoriales es el proveniente de la comunidad de modelado de lenguaje mediante redes neuronales. Estos son métodos predictivos que utilizan información local para construir modelos de lenguaje a partir de redes neuronales [11] y redes neuronales recurrentes [72]. Una de las salidas de estos algoritmos son vectores para las palabras del lenguaje, las cuales suelen denominarse *vectores* o *modelos neuronales*, o *embeddings* de palabras.

Otros nombres utilizados incluyen *representaciones vectoriales continuas*, *espacios de palabras semánticos*, o simplemente *vectores de palabras*.

Destacamos también la existencia de técnicas basadas en métodos aglomerativos para la construcción de representaciones vectoriales más compactas. Un ejemplo son los métodos basados en el algoritmo de Brown [15] (denominados

*Brown Clusters*): bajo este esquema, se realiza un *clustering* jerárquico de palabras utilizando estadísticas de los bigramas del corpus, tales como su información mutua, y se construye un código que busca minimizar el largo de las representaciones para grupos de palabras semánticamente relacionadas. También existen diferentes técnicas que se basan en modelos ocultos de Markov [61] o en K-means [62]. Sin embargo, dado que estos modelos no han tenido los mejores resultados en la literatura, y que tienen la desventaja de no producir representaciones continuas, limitaremos nuestro estudio en el presente proyecto a los dos enfoques anteriormente presentados.

Vectores de palabras obtenidos con distintos mecanismos han sido utilizados exitosamente para una gran cantidad de tareas de PLN, en especial en los últimos años, donde se han superado resultados del estado del arte mediante la combinación de los mismos con aprendizaje profundo (o *deep learning*, como es conocido en la literatura). Mencionamos a continuación algunos de los principales resultados.

- En [108, 109], se utilizan vectores basados en modelos neuronales para realizar análisis de sentimiento en críticas de películas a nivel de árboles de parsing, superando levemente los resultados obtenidos anteriormente.
- En [24, 25], los autores plantean un nuevo esquema para resolver problemas de PLN utilizando redes neuronales convolucionales cuya única entrada son vectores de palabras, logrando resultados muy cercanos al estado del arte en tareas como *POS tagging* (etiquetado de categorías gramaticales), etiquetado de roles semánticos, y reconocimiento de entidades con nombre.
- En [116], se mejoran los resultados obtenidos en reconocimiento de entidades con nombre y en *chunking* al agregar vectores de palabras como *features* en un algoritmo de CRF (campos aleatorios condicionales).
- En [107], mediante la utilización de representaciones vectoriales y de *auto-encoders*, se mejora el estado del arte en materia de detección de parafraseo en textos cortos.
- En [74], el autor entrena una red neuronal recursiva utilizando como única entrada vectores de palabras para generar un modelo de lenguaje para el checo, que posteriormente es utilizado para reconocimiento automático de habla.

- En [131], se generan vectores de palabras bilingües, donde se aprenden representaciones para dos lenguajes de manera simultánea, obteniendo buenos resultados en traducción automática de frases cortas.

En las siguientes secciones presentaremos una descripción más detallada de los principales enfoques para la construcción de representaciones vectoriales, llegando así a los métodos del estado del arte en el área.

## 2.2. Modelos Estadísticos

Los modelos estadísticos se originan en el área de la lingüística computacional, basándose en estudios teóricos de semántica distribucional de lingüistas como Zellig Harris, con su *hipótesis distribucional* [44], y John Firth, con su noción de *contexto de situación* [38], haciendo referencia a la dependencia que tiene el significado de las palabras del contexto en el que ocurren (o, como lo plantea Firth, *Conocerás una palabra por la compañía que mantiene*). El hecho de que surjan hace tantos años dotan al área de una literatura muy rica y extensa. A continuación daremos una breve reseña, recorriendo los resultados más significativos.

La idea principal detrás de estos modelos es, pues, describir a las palabras del vocabulario según el contexto en el que estas ocurren en un determinado corpus de texto utilizado para la construcción de las representaciones. Con este fin, se construye un vector  $v \in \mathbb{R}^N$  que captura, de alguna manera, información acerca del contexto donde aparece la palabra.

Qué es considerado como el contexto de una palabra es una decisión propia de cada método; para un elemento lingüístico particular, se podría considerar la pertenencia a una región de texto dado (e.g. la pertenencia a una oración, un párrafo, o hasta un documento entero), o se puede considerar definiciones que sean independientes de la estructura, considerando la relación con otros elementos lingüísticos (e.g. la cantidad de *coocurrencias* con otra palabra).

Para el punto anterior, también es importante definir qué *métrica de asociación* se estará midiendo respecto al contexto elegido: el caso más básico es contar la cantidad de ocurrencias de la palabra en dicho contexto, pero existen técnicas que capturan mejor esta relación.

Otro punto importante a considerar es que la cantidad de contextos que se consideran puede ser muy elevada: en el caso de coocurrencias con elementos lingüísticos, el vector asociado a un contexto tendrá un tamaño del orden de  $|V|$  elementos (donde  $V$  es el vocabulario), mientras que si se consideran regiones de texto se estará tratando con dimensiones aun mayores. Por esta razón, es necesario evaluar el uso de técnicas de reducción de dimensionalidad, o al menos métricas de asociación que generen representaciones dispersas que hagan al resultado tratable computacionalmente (esto es, vectores con muchos ceros).

Por último, cómo utilizar la representación final obtenida y cómo medir la similitud entre dos palabras es un tema no menor a resolver, que dependerá de la aplicación final de los vectores. Por ejemplo, cuando se trata con representaciones dispersas, medir la similitud con una distancia euclídea tendrá resultados inferiores que la distancia coseno, pues esta última estará menos sesgada a la cantidad de componentes nulas que hay en el vector.

Resumiendo, a la hora de construir un modelo estadístico para la representación vectorial de palabras, es necesario tomar las siguientes decisiones:

- **Tipo de contexto:** utilizar regiones de texto o relaciones con otros elementos lingüísticos.
- **Forma que tendrá este contexto:** la forma que tendrán las regiones de texto consideradas o la ventana de coocurrencia con los elementos lingüísticos.
- **Métrica de asociación:** cómo se medirá la relación de una palabra con su contexto.
- **Reducción de dimensionalidad:** cómo se manejará el tamaño elevado de las representaciones obtenidas.
- **Integración:** cómo utilizar los vectores en la tarea en la que se trabaja. Este punto no es particular a los modelos estadísticos, pero es bueno resaltarlos, pues es de suma importancia. Podría involucrar, por ejemplo, determinar cómo medir la similitud entre dos palabras si se van a utilizar directamente o, si servirán como *features* en un algoritmo de aprendizaje automático, cómo encajarlos en esta maquinaria más grande.

Siguiendo los puntos anteriores, un modelo estadístico se podría formalizar de la siguiente manera:

- Un vocabulario  $V$ , conjunto de palabras que se considerarán.  $V$  podría formarse con las palabras que están presentes en el corpus, por ejemplo.
- Un conjunto de contextos  $C$ , que captura las decisiones respecto al tipo y forma de los contextos a utilizar.  $C$  podría ser una lista de documentos (donde  $c_1 \in C$  corresponde al primer documento,  $c_2 \in C$  al segundo, etc.), o un conjunto de elementos lingüísticos con los que se medirá la coocurrencia (podrían ser las palabras de  $V$ , por ejemplo).
- Una matriz de asociación  $A \in \mathcal{M}_{|V| \times |C|}(\mathbb{R})$ , que captura la métrica de asociación entre el vocabulario y el contexto. Si  $f : V \times C \rightarrow \mathbb{R}$  es la métrica de asociación entre la palabra y su contexto, entonces  $A = (a_{ij}) = f(v_i, c_j)$ .
- Una transformación de reducción de dimensionalidad  $R : \mathcal{M}_{|V| \times |C|}(\mathbb{R}) \rightarrow \mathcal{M}_{|V| \times d}(\mathbb{R})$ , donde  $d$  es la dimensión de los vectores resultantes asociados a las palabras de  $V$ .  $R$  podría eventualmente ser la identidad (y  $d = |C|$ ), o podría ser la aplicación de técnicas como SVD.
- La matriz de traducción  $T$ , resultado de aplicarle  $R$  a la matriz de asociación  $A$  (i.e.  $T = R(A)$ ), es la matriz utilizada para ir de una palabra codificada bajo un esquema *one-hot* al espacio de vectores asociado al vocabulario  $V$ : esto es, las filas de la matriz corresponden a los vectores de las palabras de  $V$ .

Cabe aclarar que la formalización recién presentado es más bien de carácter general y de ningún modo exhaustiva: mientras que la mayoría de los modelos estadísticos siguen el esquema anterior, hay variantes que no encajan a la perfección pero no por eso se los deja de considerar modelos estadísticos.

Como se mencionó anteriormente, los modelos estadísticos tienen una larga historia, principalmente en las áreas de recuperación de información (IR, por sus siglas en inglés) y representaciones vectoriales semánticas.

Uno de los primeros trabajos en el área fue el modelo de análisis latente semántico (LSA) propuesto en [30], también llamado indizado latente semántico (o LSI, en especial en el área de IR). Siguiendo un modelo basado en resultados de la psicología, los autores proponen utilizar documentos enteros como contextos, y contar la cantidad de veces que dos palabras dadas coocurren como métrica de asociación: esto es, la matriz de asociación contará la cantidad de veces que dos palabras aparecen en un mismo documento. Una vez construida esta matriz, los autores proponen utilizar una descomposición en valores



singulares (SVD, por sus siglas en inglés) de dicha matriz, truncándola a los  $d$  valores singulares más grande, donde  $d$  varía dependiendo del caso (los autores utilizan 100 en algunos casos, 200 en otro).

En [27], los autores continúan con la técnica anterior, pero variando la métrica de asociación: consiguen un mejor resultado utilizando TF-IDF en lugar de las frecuencias absolutas para las coocurrencias. El objetivo principal de LSI es la recuperación de documentos basados en una consulta, donde una palabra dada se proyecta al espacio de dimensión reducida y se devuelven los documentos más cercanos en dicho espacio.

En [55] los autores profundizan y formalizan los anteriores modelos, incluso planteando LSA como un modelo de adquisición del lenguaje en humanos. Además proponen la utilización la entropía (de teoría de la información) como métrica de asociación alternativa, mejorando los resultados obtenidos en tareas de similitud de palabras.

Continuando con estas ideas, [47] propone una variante al algoritmo anterior, denominado LSI probabilístico (o pLSI, pLSA). Plantea formalmente la noción de variables latentes, denominadas tópicos, relacionadas a documentos y palabras. Bajo este esquema, en lugar de utilizar SVD para reducir la dimensionalidad, los autores plantean fijar a priori la cantidad de tópicos, que corresponde a la dimensión  $d$  resultante de los vectores, y luego expresar cada documento como una combinación (denominada *mixture*) de dichos tópicos. Cada palabra tiene una cierta probabilidad de utilizarse en un tópico dado, y todos los parámetros se ajustan mediante un algoritmo de maximización de la esperanza.

Otra variante al último algoritmo es la propuesta en [13], donde los autores plantean un modelo generativo denominado LDA (asignación de Dirichlet latente) que sigue un esquema de pLSI donde la distribución de fondo para los tópicos se asume que sigue una distribución de Dirichlet.

Los anteriores modelos emplearon contextos basados en documentos. Otra corriente paralela fue propuesta en [54, 64], denominada análogo en el hiperespacio para el lenguaje (o HAL). En esta propuesta, los contextos se forman en base a las coocurrencias de las palabras del vocabulario en una ventana de largo fijo dado. Esto es, se construye una matriz de tamaño  $|V| \times |V|$ , y en la entrada  $(v_i, v_j)$  se acumula el resultado la métrica de asociación  $f(v_i, v_j)$  para cada coocurrencia de las palabras  $v_i$  y  $v_j$  en el corpus.

En el planteo original, los autores proponen formar una matriz de  $|V| \times 2|V|$ , y consideran una ventana de largo 10 a la izquierda y otra a la derecha de la palabra central ( $v_i$ , en el caso anterior). La métrica de asociación utilizada es el inverso de la distancia entre ambas palabras (donde la palabra más cercana toma el valor 1, mientras que el más lejano  $1/10$ ).

Para la reducción de la dimensionalidad, los autores se quedan con las 200 componentes con más varianza, bajo la observación que para la mayoría de las palabras la varianza es casi nula. Esto corresponde a quedarse con las 200 palabras que presentan mayor varianza en sus entradas. En [118] se obtienen mejores resultados (aunque a un costo computacional mayor) realizando un análisis de componentes independientes (ICA) para reducir la dimensionalidad.

Distintas alternativas se han empleado también para la reducción de dimensionalidad, además de SVD, ICA o las técnicas probabilísticas de pLSA. Una de las que mayor éxito ha tenido fue el indizado aleatorio (también conocido como *random indexing*, *random mapping*, o *random projection*), propuesto en [53], el cual propone quedarse con  $d$  dimensiones elegidas aleatoriamente de la matriz de coocurrencias. Esta técnica se basa en el lema de Johnson-Linderstrauss, que plantea que las distancias entre los vectores de palabras entre el espacio original y el reducido se preservarán casi completamente, siempre y cuando el valor de  $d$  sea suficientemente grande. En [102], se emplea esta técnica en lugar de SVD siguiendo un esquema HAL.

En cuanto a métricas de asociación, mucho trabajo se ha centrado alrededor de la información mutua puntual entre dos palabras (PMI). Esta medida fue propuesta inicialmente en [23] y busca modelar correctamente nociones de asociatividad entre palabras del lenguaje: el hecho de que frases como *cuesta arriba* son más comunes que *cuesta derecha*. El trabajo inicial de los autores no estuvo relacionado a representaciones vectoriales, pero fue tomado más adelante por [117] con ese fin. En dicho trabajo se presenta un algoritmo que usa PMI como medida de asociatividad, y compara los resultados con LSA.

De todos modos, no es hasta [17] que se utiliza dicha métrica para la construcción explícita de modelos vectoriales del lenguaje. En este trabajo los autores hacen una evaluación sistemática de distintos parámetros para la construcción de vectores basándose en un esquema HAL. Una de los principales aportes fue la introducción de la PMI positiva (PPMI), igual a la PMI pero donde los valores negativos se sustituyen por cero. La intuición detrás de este cambio, plantean los autores, es que los valores negativos implican que el par de pala-

bras tiene menos coocurrencias de lo esperado, punto que se podría dar por, por ejemplo, un corpus de tamaño insuficiente o ruidoso. Otra ventaja de esta métrica es que la matriz de asociación resultante es dispersa, lo que ayuda a que su cálculo sea manejable computacionalmente y a que la reducción de dimensionalidad no sea imprescindible.

Además de métricas de asociación, los autores realizan pruebas con la dimensionalidad de los vectores resultantes (quedándose únicamente con las  $d$  palabras de mayor frecuencia), con el tamaño del corpus utilizado para tomar las estadísticas, y con el tamaño de la ventana empleada. Llegan finalmente a que, en todos los casos, los mejores resultados se obtienen con la métrica PPMI, en especial cuando los tamaños de las ventanas son muy chicos (1 ó 2 a ambos lados de la palabra). En cuanto al corpus y la dimensionalidad, cuanto mayor mejor, aunque está claro que esto afectará muy negativamente a la eficiencia computacional.

Esta línea de investigación se continúa en [18], donde se evalúa también la utilización de técnicas de reducción de dimensionalidad. Los autores muestran que los resultados se pueden mejorar significativamente aplicando SVD y truncando a los  $d$  valores singulares más grandes (donde  $d$  varía según el problema objetivo, pero suele estar cerca de  $d = 1000$ ). Además, logran mejorar aún más los resultados mediante una variante de SVD propuesta por [20], donde la matriz de valores singulares se eleva a un exponente  $P$ , nivelando dichos valores para quitarles peso a los más grandes.

El estado del arte en modelos estadísticos sigue principalmente el esquema recién planteado, pero introduciendo algunas variantes adicionales inspiradas en los modelos neuronales: en [60], los autores utilizan distintas heurísticas para preprocesar el corpus con el que se entrena el modelo (como realizar un *subsampling* de palabras muy frecuentes, normalizar los vectores resultantes, o eliminar palabras raras del vocabulario), logrando así mejorar significativamente la calidad de las representaciones obtenidas.

## 2.3. Modelos Neuronales

La representación distribuida de conceptos mediante el uso de redes neuronales fue presentada inicialmente en [46]. En este artículo, el autor plantea la idea de usar los pesos de las capas internas de redes neuronales básicas como

la representación de un concepto particular en un espacio continuo. Esta idea fue también propuesta por Rumelhart en [101], donde se realiza una exposición más completa del mecanismo.

Aunque Hinton y Rumelhart plantearon inicialmente la idea de aprender conceptos abstractos (como relaciones familiares), la técnica no tardó en extenderse al lenguaje natural. En 1990, Elman [34] aplica redes neuronales recursivas básicas (denominadas *Elman networks*, utilizadas para realizar modelado a través del tiempo) a la tarea de predicción de oraciones y utiliza los pesos internos aprendidos por la red como representación de las palabras. En las pruebas que llega a realizar el autor (rudimentarias, debido al poder de cómputo disponible en la época), consigue resultados prometedores, donde la representación de palabras como *girl* y *woman* quedan más próximas que palabras como *cat* y *mouse*.

De todos modos, debido a la dificultad de entrenar dichas redes neuronales, la técnica quedó en desuso por varios años más.

No fue hasta 2003 donde Bengio presenta en [11] una alternativa competitiva al modelado de lenguaje a través de ngramas<sup>2</sup> mediante la utilización de redes neuronales. El autor plantea la idea de utilizar el espacio real para modelar el lenguaje, con el fin de explotar la continuidad local para obtener una mejor generalización, cualidad que carecen los modelos estadísticos basados en espacios discretos. Por ejemplo, en un modelo de ngramas, la ocurrencia de la frase “el gato corre” es completamente independiente (y no elevará la probabilidad) de la frase “el perro corre”. Esto implica además que es necesaria una mayor cantidad de parámetros para la estimación: una probabilidad de ocurrencia por ngrama. Otro punto positivo es que, al requerir menos parámetros, es posible utilizar contextos más grandes: mientras que el estado del arte en modelos estadísticos utilizan 3 ó 4 palabras, los modelos continuos llegan a utilizar hasta 10 ó 15.

La idea principal detrás del modelado continuo de lenguaje es distribuir la densidad de probabilidad de la siguiente palabra (dada una secuencia de palabras inicial) de forma más inteligente: mientras que los modelos estadísticos la distribuyen uniformemente alrededor de cada combinación de ngramas (e.g. de igual manera para “el gato árbol” que para “el gato camina”, dada la frase “el

---

<sup>2</sup>Los modelos de ngramas, o modelos estadísticos, buscan caracterizar al lenguaje en base a la probabilidad de secuencias cortas de palabras denominadas ngramas, y fueron el estado del arte hasta la década pasada.

gato corre”), los modelos continuos buscan que palabras relacionadas reciban más masa de probabilidad que las que no están relacionadas.

En su artículo, Bengio presenta un esquema distinto al usual para entrenar el modelo de lenguaje: plantea una arquitectura que consta de vectores continuos de palabras y una función paramétrica definida sobre dicho espacio de vectores, el cual modela la probabilidad de la siguiente palabra dada una ventana de  $N$  palabras precedentes. El autor utiliza una red neuronal para modelar la probabilidad, pero deja abierta la posibilidad de usar otros modelos, como modelos de combinación gaussiana (o *gaussian mixture models*). Bajo esta arquitectura, tanto los vectores de palabras como la función de probabilidad son aprendidas en simultáneo, utilizando un corpus de gran tamaño como entrada al algoritmo.

La principal innovación de este artículo fue la separación de los vectores de palabras y la función de modelado de la probabilidad; de hecho, en [71] ya se habían utilizado redes neuronales para el modelado de lenguaje. El esquema de Bengio logra así mejorar significativamente el estado del arte en materia de modelado de lenguaje, en especial a lo que respecta a la eficiencia (comparando con otros modelos basados en redes neuronales), desatando una nueva ola de investigación en el área, tanto en cuanto al modelado mediante redes neuronales como a la utilización de los vectores de palabras que deja como resultado adicional el algoritmo.

A partir de este artículo, surgen también variantes de la arquitectura anteriormente descrita. En [74, 79] Mikolov presenta una arquitectura alternativa, donde se aprende primero por separado las representaciones vectoriales utilizando un método no supervisado basado en recorrer bigramas en un corpus de texto; esto es, utiliza una ventana de largo dos, si se sigue el esquema anterior, pero los aprende independientemente del modelo de lenguaje. Luego estos vectores son utilizados para entrenar una red neuronal que modela el lenguaje. Bengio en su artículo original presentó una variante similar a esta, donde propone incluso la idea de utilizar vectores de LSA fijos, en lugar de entrenarlos junto a la red, pero obtuvo resultados inferiores.

Otra variante propuesta por Mikolov [72, 73, 77, 78] fue, en lugar de utilizar una ventana de largo fijo y una red neuronal estándar, utilizar una red neuronal recursiva simple para modelar el lenguaje. Esta arquitectura es similar a las *Elman networks*, pero el autor obtiene mejores resultados por utilizar técnicas de entrenamiento modernas que atenúan los problemas usuales de entrenar redes neuronales recursivas (RNNs). Como derivado de este modelo también se

generan representaciones vectoriales. El autor incluso ofrece una herramienta de código abierto (*RNN toolkit*) para la creación de modelos de lenguaje que sigan esta arquitectura, pudiendo obtener tanto los vectores como el modelo de lenguaje [78].

Por otro lado, la aparición de estos modelos generó gran interés en el uso de representaciones distribucionales para distintas tareas de PLN, más allá del modelado de lenguaje. En [24], los autores presentan una nueva arquitectura genérica para la resolución de problemas de PLN utilizando exclusivamente aprendizaje profundo (esto es, sin ingeniería de features), inspirados por el esquema propuesto por Bengio. Esta propuesta se basa en la noción de aprendizaje por transferencia (conocido como *transfer learning* o *multi-task learning*), donde se entrena un modelo para resolver más de una tarea a la vez, con el objetivo de que el conocimiento que adquiere en una tarea pueda ser de utilidad en otra.

Con este fin, entrenan primero un modelo de lenguaje siguiendo la arquitectura de Bengio y luego, con los vectores resultantes, entrenan en simultáneo cuatro redes neuronales para distintas tareas (POS tagging, etiquetado de roles semánticos, etiquetado de entidades con nombre, detección de sinónimos), propagando los errores hasta los vectores. Logran así mejorar el estado del arte en todas las tareas que prueban, donde destacan particularmente los resultados de SRL por considerarla la tarea más compleja. El resultado de este trabajo es de gran importancia, porque plantea la utilización de representaciones vectoriales como una nueva alternativa para la resolución de problemas y muestra que es una técnica competitiva con las técnicas existentes.

Con este nuevo auge de aplicaciones de las representaciones, se comienza también a buscar mejorar la eficiencia en la generación de vectores de palabras independientemente del modelado de lenguaje. En [81], los autores proponen variantes a la arquitectura de Bengio que buscan ser mejores desde el punto de vista computacional. De las cuatro variantes que proponen, una de ellas, un modelo *log-bilinear* (LBL), consigue incluso mejores resultados en la tarea de modelado de lenguaje. Esta técnica es luego extendida a una versión jerárquica y más rápida denominada HLBL en [82], haciendo uso de una versión jerárquica de la función *softmax*, propuesta por Bengio en [84].

En [80], Mikolov muestra que los vectores generados por una RNN (en particular, por una RNN entrenada utilizando su *RNN toolkit*) presentan regularidades lingüísticas muy interesantes: además de los vectores ser muy buenos en

tareas de similitud y relación entre palabras<sup>3</sup>, éstos logran capturar relaciones sintácticas y semánticas a través de vectores específicos a cada relación. El autor ejemplifica este fenómeno a través de la resolución de analogías<sup>4</sup>, y construye un conjunto de pruebas compuesto por analogías sintácticas.

Utilizando dicho conjunto, compara el rendimiento en esta tarea con sus vectores, con vectores basados en modelos estadísticos (aunque no hace una comparación exhaustiva, por lo que no obtiene buenos resultados), con los vectores generados por Collobert y Weston [24], y por los generados por Mnih y Hinton (HLBL [82]), obteniendo los mejores resultados con los propios y los HLBL.

Los resultados obtenidos en el anterior artículo motivaron la propuesta, por parte de Mikolov en [75], de dos arquitecturas novedosas para la construcción de vectores, centrada en la tarea de analogías y en mejorar la eficiencia computacional. En estas arquitecturas se deja de lado la RNN y el modelado de lenguaje, y se centra exclusivamente en la construcción de vectores.

Ambos esquemas propuestos se basan en definir una ventana de largo fijo, simétrica alrededor de una palabra central, y plantear un problema de optimización basado en predecir la palabra central dado el contexto o vice versa. El primer caso recibe el nombre de *Continuous Bag-of-words* (o CBOW, esquematizado en 2.1a), mientras que el segundo recibe el nombre de *Skipgram* (o SG, esquematizado en 2.1b).

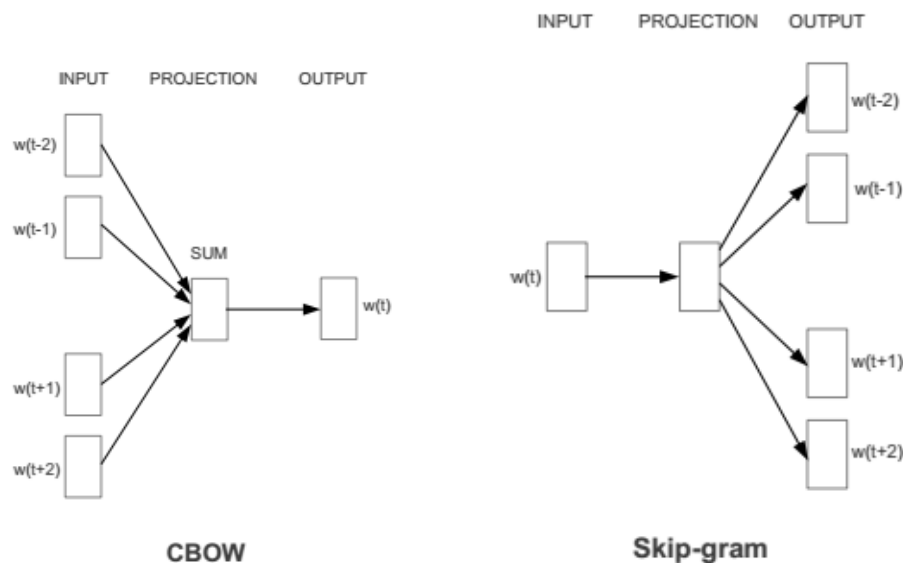
En los dos casos la probabilidad se modela utilizando exclusivamente un softmax jerárquico, como el propuesto por Morin y Bengio en [84], con el fin de mejorar la eficiencia. Estos dos nuevos modelos logran, por lo tanto, mejorar los resultados en la tarea de analogías a un costo computacional significativamente menor que el de entrenar una RNN completa.

Cabe notar que, mientras que el autor lo plantea como la utilización de una red neuronal de una única capa, también se puede ver directamente como una regresión logística multinomial, por lo que el modelo se está simplificando enormemente con la finalidad de mejorar la eficiencia computacional, en especial cuando se lo compara con modelos basados en RNNs. Dado el *trade-off* que existe entre la complejidad de los modelos estadísticos y la cantidad de datos

---

<sup>3</sup>Por ejemplo, decidir si una palabra es sustituible por otra en un contexto dado. En las siguientes secciones se dará una descripción más detallada de estas tareas.

<sup>4</sup>Por ejemplo, vectores que capturen la relación de género entre dos palabras, de modo que a partir de los vectores de *hombre*, *mujer* y *rey* se pueda recuperar la palabra *reina*. Más adelante se entrará en mayor detalle.



(a) Modelo Continuous Bag-of-words

(b) Modelo Skipgram

Figura 2.1: Esquemas de word2vec

que éstos pueden procesar, este punto ubica a la propuesta de Mikolov como un modelo simple que requiere de muchos datos. De hecho, en las pruebas que realiza el autor se utilizan corpus de texto del orden de los miles de millones de palabras y, cuanto más aumenta el tamaño del mismo, mejores resultados obtiene.

En [76], Mikolov cierra su trabajo en representaciones vectoriales de palabras presentando extensiones sobre el modelo Skipgram. El artículo comienza formalizando el modelo: se presenta la función objetivo, que previamente había obviado, y se detalla la utilización del softmax jerárquico. Luego se presenta una alternativa a esta última técnica que logra mejorar significativamente los resultados, basada en *Noise-contrastive Estimation* (NCE), propuesta inicialmente por Gutmann y Hyyvärinen [43] y aplicada por Mnih y Teh para modelado de lenguaje [83]. Esta técnica, que denomina *negative sampling* (NS), se basa en generar ejemplos negativos de uso del lenguaje: esto es, además de utilizar el texto proveniente del corpus de entrenamiento, se genera texto aleatorio, bajo la premisa de que será inválido gramaticalmente, como ejemplo de mal uso del lenguaje.

El autor también presenta una serie de heurísticas para el procesamiento



del corpus, como la realización de *subsampling* de palabras muy frecuentes (i.e. ignora aleatoriamente palabras que son demasiado comunes en el corpus) y la eliminación de palabras muy raras, que mejoran aún más los resultados.

Por último, junto a la publicación de este artículo, Mikolov presenta un nuevo conjunto de pruebas mucho más extenso, que abarca tanto casos sintácticos como semánticos. También hace pública su implementación de los modelos CBOW y Skipgram, bajo una herramienta denominada `word2vec`. Este punto no es de menor importancia, porque contribuyó a aumentar el interés en el tema, en especial entre el público amateur, y permitió reproducir y comparar los resultados con distintos métodos de manera más correcta desde un punto de vista metodológico.

## 2.4. Modelos Híbridos

Los dos tipos de representaciones vectoriales descritos tienen mucha literatura detrás, pero al haber surgido independientemente, carecían de comparaciones sistemáticas y completas entre ellos. La primera de estas evaluaciones se realiza en [10].

En este artículo, los autores reúnen catorce conjuntos de pruebas utilizados por la comunidad para los problemas de similitud entre palabras, analogías, y otros. Someten a estas pruebas a modelos estadísticos (modelos basados en contar, como los llama el autor) y a modelos neuronales (modelos basados en predecir). Para los primeros utiliza vectores construidos con la herramienta DISSECT [29], basados principalmente en esquemas PMI con reducción de dimensionalidad con SVD. Para los segundos utiliza la herramienta provista por Mikolov en [76], `word2vec`.

Los resultados que obtienen los autores presentan a los modelos neuronales como grandes ganadores, donde obtienen mejores resultados en todas las pruebas realizadas. Esta conclusión lleva a la comunidad a investigar qué es lo que hace mejores a los métodos neuronales por sobre los estadísticos.

Siguiendo esta línea de pensamiento, en [60] el autor busca identificar qué es lo que hace que Skipgram con Negative Sampling (SGNS) funcione tanto mejor que un modelo PPMI que utiliza SVD. Los resultados a los que llega, sin embargo, son contradictorios con los de Baroni. Plantea que la diferencia entre la

performance de ambos métodos se debe a que SGNS tiene una ventaja por utilizar, además del modelo básico, una serie de heurísticas en el preprocesamiento del corpus y el posprocesamiento de los vectores que mejoran drásticamente los resultados.

De esta forma, Levy identifica una serie de nueve heurísticas de uno y otro modelo, que los considerará hiperparámetros, y los adapta para ambos esquemas. Además de hacer esto, entrena todos los vectores utilizando exactamente el mismo corpus de datos (punto que no hizo Baroni, pues utilizó vectores pre-entrenados descargados de Internet) y compara contra el mismo conjunto de pruebas. Así, utilizando una metodología más robusta que en el estudio anterior, llega a que los resultados de los modelos estadísticos y los modelos neuronales son prácticamente equivalentes, con los primeros con una leve ventaja. De todos modos, el autor resalta que SGNS es mucho más eficiente computacionalmente, lo que le permite utilizar más datos.

Más allá de las comparaciones, los dos enfoques anteriores no son necesariamente ortogonales. En [59] se muestra que SGNS está en realidad siguiendo un esquema muy similar a los enfoques estadísticos, donde se realiza una factorización implícita de una matriz SSPMI: esto es, una matriz PPMI donde la medida de asociación es  $f(v_i, v_j) = \max(PMI(v_i, v_j) - \log(k), 0)$ , con  $k$  un hiperparámetro del modelo. Este resultado es muy importante, pues conecta directamente dos enfoques históricamente independientes. El autor plantea que la ventaja que SGNS tiene sobre la matriz PPMI estándar se da en que su factorización está ponderada de modo de no dar demasiada importancia a las palabras más comunes, una de las debilidades principales de la métrica PPMI.

Siguiendo estos resultados, han surgido diversos métodos que plantean un esquema híbrido, donde se busca hacer explícita la tarea de aprendizaje que se realiza, basándose en las lecciones aprendidas de los enfoques ya presentados. Uno de estos métodos es GloVe, presentado en [89], donde los autores construyen una matriz  $A$ , similar a la matriz de asociación de los modelos estadísticos, donde la función de asociación busca explícitamente quitar peso a las palabras más frecuentes y no sobrerrepresentar a las muy poco frecuentes. Luego plantea una reducción de dimensionalidad basada en factorizar dicha matriz a través de un método iterativo en lugar de usar SVD, lo que lo hace computacionalmente más eficiente. Los resultados que obtienen los autores son superiores a los obtenidos por SGNS en el conjunto de pruebas provisto por Mikolov<sup>5</sup>.

---

<sup>5</sup>Cabe notar que en [60] no se logra reproducir este resultado, aunque aun así es un método muy competitivo.

Los modelos estadísticos, neuronales e híbridos han resultado bastante similares en cuanto a los resultados obtenidos. Reconociendo este punto, la comunidad se está centrando en modelos híbridos que aprovechen las lecciones aprendidas por los tres enfoques, buscando nuevas métricas de asociación (definiendo matrices de asociación explícitamente) y nuevas formas de factorizarlas (ya sea con variantes de SVD, o con métodos iterativos).

## 2.5. Evaluación y Estado del Arte

Hasta ahora se presentaron distintos enfoques para la construcción de representaciones vectoriales, pero no se ha detallado qué entendemos por estado del arte: esto es, cuándo consideramos que una representación es mejor que otra, y cómo las comparamos.

Es posible comparar las representaciones de forma implícita y explícita. La primera implica evaluar los cambios en la performance en un algoritmo de aprendizaje automático donde se usan; esto es, como parte de una solución de un problema de PLN más grande. La segunda refiere a evaluar directamente la calidad de los vectores obtenidos mediante alguna tarea de PLN desarrollada específicamente para el caso.

Para la evaluación explícita, el objetivo es diseñar un experimento cuyo resultado esté, en la medida de lo posible, correlacionado a la calidad de una solución de PLN de mayor porte cuando se utilizan estas representaciones. Esto permite optimizar una métrica más definida y más fácil de calcular. Por ejemplo, si se está construyendo una solución para el procesamiento automático del habla (ASR), y se supiera que representaciones que funcionan mejor en la tarea de analogías mejoran el resultado final, sería mucho más fácil y eficiente probar distintos hiperparámetros y modelos evaluando con esa métrica, que entrenar todo un modelo de ASR de principio a fin para evaluar si los vectores produjeron mejores resultados<sup>6</sup>. En especial porque en un modelo complejo, pueden haber varios componentes que afecten la calidad final de la solución, por lo que no se sabrá si fueron los vectores los que mejoraron los resultados o no.

De todos modos, esta correlación entre la evaluación explícita e implícita de

---

<sup>6</sup>Esto es particularmente problemático para los vectores de palabras, pues suelen ser el primer componente en una solución PLN.

representaciones vectoriales por lo general no se puede probar, y es una suposición que se toma cuando se realiza una evaluación explícita.

En la literatura se han usado muchas tareas para la evaluación explícita de vectores, algunas de las cuales ya han sido mencionadas brevemente. Una de las más antiguas es la tarea de similitud y relación entre palabras, que busca decidir si una palabra es sustituible por otra en un contexto dado. Para esto, se construye un conjunto de pruebas compuesto por pares de palabras y un puntaje, determinado por un grupo de humanos, de qué tan similares son dichas palabras. El objetivo es obtener un buen nivel de correlación entre los puntajes de los pares de palabras y las distancias<sup>7</sup> en el espacio de vectores, medida utilizando la correlación de Spearman. Distinguimos también entre similitud, donde se mide relaciones más fuertes, como la sinonimia y la hiponimia, de la relación (*relatedness* en la literatura), donde se incluyen relaciones más amplias, posiblemente temáticas.

Existen muchos conjuntos de prueba para esta tarea. Uno de los más utilizados es WordSim353 [37], compuesta de 353 pares de palabras, diferenciados entre relación y similitud. También muy populares están MEN [16], compuesto de 1000 pares de palabras, SimLex999 [45], y Mechanical Turk [98].

Otra alternativa que ha surgido recientemente para el estudio de regularidades lingüísticas de representaciones vectoriales es la tarea de analogías, propuesta inicialmente por Mikolov en [80]. En este escenario, se cuenta con dos pares de palabras que mantienen una misma relación (sintáctica o semántica) y se busca determinar la cuarta palabra a partir de las anteriores tres. Por ejemplo, si se cuenta con los pares de palabras *correr* y *corriendo*, *jugar* y *jugando*, el objetivo es, a partir de los vectores de *correr*, *corriendo* y *jugar*, lograr recuperar la cuarta palabra, *jugando*.

Para esto Mikolov originalmente propone en [80] utilizar la función 3COSADD para recuperar la cuarta palabra, definida como:

$$\arg \max_{b' \in V} \cos(b', b - a + a')$$

Donde los pares de analogías son  $(a, a')$  y  $(b, b')$ . Sin embargo, en [58], Levy prueba que una mejor función para la recuperación de analogías es 3COSMUL, definida como:

---

<sup>7</sup>Es usual utilizar la distancia euclídea o la distancia coseno.

$$\arg \max_{b' \in V} \frac{\cos(b', b) \cos(b', a')}{\cos(b', a) + \epsilon}$$

Donde  $\epsilon$  es un valor muy pequeño (e.g.  $\epsilon = 0,001$ ) utilizado para evitar la división entre cero.

Mikolov introdujo inicialmente un conjunto de 8000 analogías exclusivamente sintácticas en [80], con relaciones como plurales y conjugaciones verbales. Luego introduce en [75] un conjunto de analogías más amplio que cuenta con cerca de 20000 analogías, tanto sintácticas como semánticas.

Existen también otras tareas que se han utilizado, aunque en menor medida, para la evaluación explícita de vectores, como la utilización del TOEFL (*Test of English as Foreign Language*, una prueba utilizada para medir el conocimiento de inglés) de [55], la categorización de conceptos de [2], y la preferencia de selección de [87].

En cuanto a evaluación implícita de las representaciones vectoriales, y cómo se relaciona con los resultados de la evaluación explícita, no existe mucho trabajo en la literatura. Un trabajo preliminar que toca superficialmente este punto es [97], donde los autores utilizan distintos modelos vectoriales (SGNS, GloVe, los vectores de Collobert y Weston, y Brown Clusters) como features de algoritmos de clasificación secuencial (principalmente CRFs, para resolver los problemas de POS tagging y NER). Llegan a que, al usar distintas representaciones bajo este esquema (donde los vectores son una feature más), los resultados mejoran de manera muy similar para los distintos modelos: esto es, se obtiene la misma ganancia utilizando Brown Clusters (que genera una representación más rudimentaria) que SGNS.

Existe también un poco de escepticismo por parte de algunos investigadores en el área respecto a qué beneficios proveen los vectores de palabras. Edward Grefenstette escribe [41] que las representaciones vectoriales parecen ser principalmente una forma de aprendizaje por transferencia, donde se entrena con la tarea de analogías o similitud entre palabras para resolver una tarea más compleja. Plantea que esto es beneficioso cuando se trabaja con corpus de entrenamiento demasiado chicos, pues ayuda a la generalización, pero que no son necesarios e incluso pueden perjudicar la performance cuando se tienen suficientes datos.

Otro caso que fortalece este argumento es el hecho que en [24] se obtienen

muy buenos resultados en el etiquetado de roles semánticos, pero los vectores son inferiores en la tarea de analogías (como muestra [80]). Esto, de todos modos, puede resultar del hecho que los autores ajustan los valores de los vectores en la medida que entrenan con las otras tareas.

Estos puntos son importantes y requieren de mayor investigación, pues determinan qué tanto es necesario buscar nuevos y mejores modelos vectoriales. Es posible, por ejemplo, que pequeñas diferencias en los resultados de evaluación explícita sean compensados por el modelo que los usa, como pasa con los Brown Clusters en [97]. En este caso, se podría incluso utilizar un corpus más chico para entrenar las representaciones, o vectores más simples.

De todos modos, en el presente proyecto se estará realizando una evaluación puramente explícita de los modelos vectoriales entrenados, por varias razones. En primer lugar, el objetivo es realizar una investigación del comportamiento de representaciones vectoriales en general, no de un problema de PLN particular. Segundo, porque no hay un estándar en evaluación implícita con el que se pueda comparar los resultados, ni que sean una aplicación directa de vectores de palabras. Tercero, porque realizar una evaluación implícita sería mucho más costoso computacional y metodológicamente, lo que nos impediría probar con una gran variedad de modelos. Y por último, porque las tareas con las que se estarán evaluando, analogías y similitud de palabras, entre otros, tienen de por sí aplicaciones directas que son de gran utilidad.

En cuanto a los modelos vectoriales que se evaluarán, se decidió optar por un representante de cada enfoque: Skipgram y CBOW como modelos neuronales, una matriz PPMI con SVD como modelo estadístico, y GloVe como modelo híbrido. Se eligen estos cuatro modelos por ser los que consiguen los mejores resultados en las tareas de analogías y similitud de palabras en la literatura en inglés, evitando así sesgarnos a un esquema de representación vectorial particular, y pudiendo evaluar si alguno de ellos tiene un comportamiento particular para el idioma español.



# Capítulo 3

## Corpus

El tamaño del corpus de texto utilizado para entrenar las representaciones vectoriales está fuertemente ligado a la performance que éstas consiguen en las principales tareas de evaluación, como se detalló en el capítulo anterior. Esto genera la necesidad de construir un corpus de texto en idioma español del mayor tamaño posible, buscando que sea comparable con los que se manejan en la literatura en inglés.

El capítulo empieza por presentar el relevamiento realizado sobre el tamaño y calidad de los corpus en español existentes. Luego se plantean los requerimientos y características que se consideró que el corpus debía contener, y se da una visión general del proceso empleado para lograrlo. Finalmente, se detalla la implementación de dicho esquema y se resumen las características del corpus construido.

### 3.1. Estado del Arte

Como ya se mencionó, una de las claves principales para la calidad de los vectores generados es contar con un corpus de gran tamaño, compuesto de documentos con estilos de redacción y temáticas variadas. Se procedió por tanto a investigar la oferta existente de corpus en idioma español en Internet. En esta sección se discutirán los proyectos de construcción de corpus más relevantes, detallando de cada uno su composición, medidas de calidad y limitantes de



acceso ó uso, en caso de haberlas.

La investigación incluida en esta sección no pretende ser completamente exhaustiva, pero si lo suficientemente profunda como para justificar la decisión de construir un nuevo corpus en lugar de utilizar alguno ya disponible públicamente. Como se verá, muchos de los proyectos de construcción de corpus existentes no cumplen con las condiciones más importantes requeridas por el presente proyecto.

Se procedió entonces a realizar una exploración formal de las alternativas existentes. Una de las fuentes consultadas fue la investigación realizada en el año 2009 por el Centro Virtual Cervantes [14]. En su trabajo los autores dan cuenta de la existencia de diversos proyectos para la construcción de corpus en español, clasificándolos en distintas categorías, entre ellas el tamaño de los corpus construidos y la capacidad de acceso a los textos que forman los mismos. Estas características son, naturalmente, muy relevantes al momento de considerar la utilidad de un corpus para la tarea de construcción de vectores de palabras. A pesar de su considerable valor la investigación apunta a corpus de muy diversos tipos, incluyendo grabaciones de entrevistas orales, y no resultó ser una referencia definitiva para nuestra investigación.

Aún así, la investigación del Instituto Virtual Cervantes resultó un buen punto de partida para nuestro relevamiento. Resulta interesante destacar que los autores obtienen entre sus principales conclusiones que la mayoría de los trabajos analizados contaron, en alguna medida, con apoyo económico de entidades privadas o gubernamentales para su desarrollo. Consideramos que este hecho pone en perspectiva los logros obtenidos en el presente proyecto de grado para la construcción de un corpus masivo, cuyos detalles se explicarán en las secciones posteriores.

### **3.1.1. Análisis de proyectos existentes**

A continuación se incluye un listado de los corpus encontrados en nuestra investigación y un análisis de las principales características de cada uno.

## Wikipedia

Como punto inicial es interesante considerar el corpus formado por todos los artículos de Wikipedia en español. En los últimos años, numerosos trabajos en el área del PLN han utilizado exitosamente los textos de Wikipedia para sus algoritmos [128]. Entre sus principales ventajas se destaca la calidad de sus textos, la enorme variedad de temáticas abarcadas por los mismos y, para nada menos importante, la naturaleza abierta y de libre acceso que diferencia a Wikipedia de otras fuentes de datos.

En idioma inglés, Wikipedia contiene casi tres mil millones de palabras repartidas en aproximadamente cinco millones de artículos [123]. En idioma español la cifra es mucho menor, ubicándose en 400 millones de palabras. Por tanto, quedó claro desde un principio que utilizar un corpus constituido únicamente por artículos de Wikipedia no sería suficiente para nuestros objetivos, aunque sí resultaría de gran utilidad para comenzar a construir un corpus de mayor tamaño.

## Sketch Engine: TenTen

Se consideró también el trabajo realizado por la organización Sketch Engine [106], dedicada a la construcción de corpus masivos en varios idiomas. Además, la organización elabora herramientas para la manipulación y consulta de los corpus generados, pensadas para profesionales de distintas áreas. Entre los corpus ofrecidos por Sketch Engine se destaca principalmente el proyecto TenTen [113]. TenTen consiste en una colección de corpus repartidos en varios idiomas superando en varios de ellos la barrera de las mil millones de palabras. Para el caso concreto del español se tiene un corpus de ocho mil millones de palabras. El corpus TenTen es catalogado por sus autores como un corpus web, lo que implica que para su construcción se utilizaron únicamente textos disponibles en Internet.

Existen diferentes estrategias para la construcción de corpus basados en Internet. En el caso de TenTen los autores utilizaron un proceso basado en crawling masivo, limpieza de documentos, detección de duplicados y almacenamiento. Para esto, los autores construyeron varias herramientas que posteriormente liberaron como código abierto.

Para la tarea de crawling masivo en la construcción de TenTen se utilizó la herramienta Spiderling [111], desarrollada especialmente para la construcción de corpus utilizando Internet. En la experiencia de los autores, el principal problema de los corpus web es la enorme cantidad de páginas que es necesario descargar para obtener una cantidad relativamente pequeña de texto útil. En su análisis definen la medida *tasa de rendimiento* (*yield rate*), que se aplica a cada página web descargada y expresa la relación entre la cantidad de bytes de la página y la cantidad de bytes de información útil obtenida a partir de la misma:

$$\text{tasa de rendimiento} = \frac{\text{tamaño de datos útiles obtenidos}}{\text{tamaño total de la página}}$$

Spiderling buscará de esta manera priorizar dominios que presenten tasas de rendimiento altas en el conjunto de sus páginas, permitiendo una extracción inicial a modo de muestra para decidir luego si vale la pena continuar procesando el dominio o si es mejor descartarlo. De este modo los autores aseguran que se obtiene un ahorro importante de ancho de banda y de tiempo de limpieza sin apenas comprometer el tamaño final que tendrá el corpus generado.

Naturalmente, luego del proceso de crawling es necesario extraer el texto útil a partir del código HTML descargado. En el caso de TenTen, los autores utilizaron herramientas construidas por ellos mismos para eliminar etiquetas HTML y texto *boilerplate* [90]. La definición de este último concepto es difícil y suele depender del contexto de su aplicación. En nuestro caso consideramos como *boilerplate* aquel texto que refiere a la estructura y navegación de una página web y no a su contenido real. Por ejemplo, texto de enlaces de una barra de navegación, texto perteneciente a secciones de publicidad, metadatos de la estructura del sitio, etcétera.

Lamentablemente, los corpus generados por Sketch Engine no están disponibles de forma gratuita. La organización ofrece en su sitio web un período de prueba sin costo para acceder a los mismos, pero la utilización prolongada de sus servicios requiere una suscripción. Desafortunadamente, esta modalidad de uso no es compatible con el alcance de este proyecto de grado.

### **Linguistic Data Consortium: Gigaword en español**

Otro corpus que vale la pena analizar es el corpus Gigaword en español construido por el Linguistic Data Consortium (LDC) [69]. El LDC es un consorcio de universidades, bibliotecas y laboratorios de investigación gubernamentales creado para enfrentar el problema de escasez de datos en las áreas de investigación vinculadas al lenguaje.

El corpus Gigaword, en su tercera edición, cuenta con más de mil millones de palabras repartidas en casi cuatro millones de documentos almacenados en formato SGML/XML. Los documentos utilizados para construir el corpus son en su totalidad cables de noticias provistos por las agencias internacionales Agence France-Presse, Associated Press (AP) y Xinhua News Agency.

Los documentos del corpus fueron catalogados por los autores, aunque estos advierten que las categorías asignadas son simplemente aproximaciones. Dichas categorías no son de mucha utilidad pues apenas distinguen entre reportes, como los que pueden encontrarse en cualquier revista de noticias, y cables dirigidos a editores y reporteros de periódicos. En cuanto a la calidad, los autores sólo aseguran controles exhaustivos en el formato de los datos, eliminando errores de recepción que corrompan el texto original, pero nada más. Se realiza también un proceso de filtro de cables repetidos, aunque se menciona que dicho proceso no es totalmente riguroso. Los autores advierten que es probable encontrar algunos errores de redacción o de ortografía, típicos del ritmo y exigencias diarias que se dan en los periódicos y agencias de noticias.

Como ocurre con TenTen, el acceso a Gigaword no es gratuito salvo para miembros del LDC. Los costos de adquisición del corpus resultan prohibitivos para el alcance del presente proyecto y, como ya se mencionó, esta modalidad de distribución tampoco se alinea con los objetivos del mismo.

### **Universidad de Brigham Young: Corpus del Español**

El Corpus del Español es un proyecto elaborado por Mark Davies del departamento de lingüística de la Universidad de Brigham Young y financiado a través de una subvención del fondo nacional estadounidense *US National Endowment for the Humanities* [26]. Este corpus está compuesto por cien millones de palabras, la cual es una cantidad relativamente pequeña si la comparamos con

las cantidades de los proyectos ya analizados. Sin embargo, este corpus cuenta con la particularidad de contener documentos de bastante antigüedad, abarcando el período desde el siglo XIII al siglo XX. Recientemente, el proyecto recibió una beca para extender el tamaño del corpus a dos mil millones de palabras. Dicha extensión comenzó a realizarse en 2015 y continuará durante el año 2016.

En la descripción de su trabajo, Davies explica los motivos para construir este corpus en español, habiendo ya alternativas disponibles de mucho mayor tamaño. Su argumento principal es que el tamaño no lo es todo y resulta muy importante contar con un corpus correctamente anotado y etiquetado para que este pueda ser de utilidad en la mayoría de las tareas. En su crítica a otros proyectos, el autor argumenta que en la mayoría de los casos se aprecia un bajo conocimiento del idioma español por parte de los encargados de los mismos y que el etiquetado de los corpus publicados fue hecho de manera automática sin prestar demasiada atención al resultado final.

Curiosamente, y a pesar de que los argumentos de Davies no deben ser despreciados, en el caso de entrenamiento de vectores de palabras no es necesario contar con un corpus anotado y etiquetado, como lo es en una gran cantidad de otras aplicaciones.

Finalmente, el acceso al Corpus del Español es totalmente gratuito, aunque no cuenta con mecanismos explícitos para descargarlo en su totalidad. Además, y de forma entendible, las consultas al corpus están limitadas de forma diaria por usuario registrado, y por dirección IP para usuarios anónimos. Estas limitantes de acceso, sumadas a las características ya descritas, hacen que este corpus no sea de gran utilidad para el presente proyecto.

### **Corpora from the Web: ESCOW14**

El proyecto Corpora from the Web (COW) es una iniciativa del grupo de gramática y lingüísticas generales de la Universidad Libre de Berlín (Freie Universität Berlin). El proyecto consta de una colección de corpus web en varios idiomas, entre los que se encuentra el español. Para este caso se cuenta con ESCOW14, un corpus en español de más de siete mil millones de palabras repartidas en cinco millones de documentos. El corpus fue generado realizando crawling masivo en Internet y en su versión actual cuenta con documentos del período comprendido entre 2012 y 2014, abarcando además documentos de una gran cantidad de países de habla hispana.

Para la limpieza de documentos obtenidos de la web y posterior extracción de texto útil se utilizó *texrex*, una herramienta creada por Roland Schäfer, integrante del equipo de COW. La herramienta cuenta con funcionalidades para filtrar duplicados, remover código HTML, extraer metadatos de los encabezados HTTP obtenidos del proceso de crawling, normalización de codificación de caracteres a UTF-8, entre otras. Este proceso resulta de mucha importancia pues en su descripción del corpus los autores mencionan como una de sus prioridades generar corpus de alta calidad, y no solamente enfocarse en el tamaño de los mismos.

El acceso a ESCOW14 está altamente limitado por los autores y regido por políticas de acceso muy estrictas, en un esfuerzo por ajustarse a las leyes alemanas de derecho de autor. Por este motivo los autores ofrecen para descargar solamente grupos de oraciones mezcladas lejos de su contexto inicial y no permiten acceso directo a los documentos originales. Además, para obtener acceso a este contenido es necesario completar un formulario detallando el uso que se planea hacer del corpus, entre otros datos. Lamentablemente, al momento de escribir este informe aún no fuimos capaces de obtener acceso a ESCOW14.

### **Spanish Billion Words Corpus and Embeddings**

Finalmente, consideramos importante mencionar el trabajo realizado por Cristian Cardellino en el proyecto Spanish Billion Words Corpus and Embeddings [19]. Dicho proyecto resulta de gran interés pues comparte muchos de nuestros objetivos para el presente proyecto de grado.

El autor, dedicado a la investigación en el área del PLN, expone en su trabajo los desafíos de construir representaciones vectoriales de palabras en idioma español, dadas las enormes dificultades para encontrar fuentes disponibles para construir un corpus no anotado de tamaño suficiente en dicho idioma. Se propuso por tanto la creación de un corpus en español de aproximadamente mil quinientos millones de palabras utilizando recursos de libre acceso disponibles en Internet. Además, el autor ofrece libremente un conjunto de vectores de palabras entrenados utilizando *word2vec*.

Para las conclusiones del proyecto, el autor realiza un análisis de los resultados obtenidos, mencionado brevemente algunos aspectos de composición y calidad del corpus generado. Se incluye también una traducción de los casos de prueba en inglés de *word2vec*, que resultó útil como comparación de nuestra

propia traducción de los mismos.

Lamentablemente el proyecto fue publicado en febrero de 2016, cuando nuestro propio trabajo se encontraba ya en su fase final. De cualquier manera, y como se explicará en secciones posteriores, parte de los recursos de libre acceso utilizados para la creación del corpus de Cardellino fueron agregados a nuestro corpus en su etapa final, aumentando la cantidad y diversidad de documentos utilizados.

### **3.1.2. Conclusiones**

La investigación realizada demuestra la dificultad que existe actualmente para acceder a un corpus en español de gran tamaño. Se comprobó que la mayoría de los proyectos existentes colocan numerosas restricciones para el acceso a sus recursos. En muchos casos la restricción es económica, y se requiere pagar para acceder a los textos. En otros, los corpus son ofrecidos de forma gratuita pero se limita la cantidad de consultas que pueden realizarse sobre los mismos. Es también común que se permita el acceso a los datos solamente a través de interfaces gráficas, útiles en ciertos contextos, pero que no sirven para nuestro caso de estudio.

Se llegó pues a la conclusión de que para cumplir el objetivo inicial de un corpus con dos mil millones de palabras, resultaría necesario construirlo de forma independiente, utilizando siempre que fuera posible las diferentes fuentes encontradas durante nuestra investigación. En las próximas secciones se describe el proceso llevado a cabo para alcanzar este propósito.

## **3.2. Proceso de Construcción**

En esta sección se presentan las características buscadas del corpus a generar y el proceso seguido para lograrlo.

### 3.2.1. Requerimientos

Previo al inicio de la construcción del corpus, se establecieron una serie de requerimientos que el mismo debiera cumplir:

- Puesto que el tamaño del corpus afecta directamente la calidad de las representaciones vectoriales, es claro que el principal requerimiento es que el resultado tenga una gran cantidad de palabras. El mínimo que se planteó al inicio del proyecto fue de dos mil millones de palabras (para comparar, el corpus en inglés utilizado por Mikolov en [76] ronda los seis mil millones de palabras).
- La única restricción que se plantea sobre el contenido es que sea texto en forma libre (sin ningún tipo de estructura a priori), y que esté limpio: esto es, que no cuente con *markup* de ningún tipo. Dado que los algoritmos para construir los vectores trabajan con una secuencia de palabras sin formato alguno, es deseable que el texto se procese incluso antes de ser almacenado, para evitar tener que tratarlo más adelante.
- Se desea que el corpus esté dividido en documentos individuales que sean coherentes en sí mismo, manteniendo un determinado estilo de escritura internamente. Así, artículos de noticias serán almacenados individualmente, y lo mismo con libros, artículos de Wikipedia, y cualquier otro texto que se recopile. El objetivo de este punto es permitir excluir o borrar un documento particular en caso de ser necesario.
- Se espera también que estos documentos puedan tener ciertos metadatos asociados. Algunos de estos datos pueden aplicar a todos los documentos, como la fecha en la que fue agregado al corpus, mientras que otros sólo tendrán sentido para un subconjunto, como la fecha de publicación de una noticia. Esto puede permitir eventualmente construir un corpus con las noticias de un año particular, para poder generar representaciones vectoriales más finas.
- Es de suma importancia tener trazabilidad sobre los distintos documentos del corpus para garantizar su calidad: esto es, saber de qué sitio se extrajo el texto de cada documento, en qué fecha, y mediante qué proceso. Así, en caso de haber un problema en el proceso de extracción, es siempre posible revertir el corpus a un estado anterior, eliminando todos los documentos erróneos. Este punto permite además evitar almacenar más de una vez



un documento particular, y ayuda también a identificar cuáles contenidos están protegidos por *copyright*.

- Con el fin de generar buenas representaciones vectoriales, es importante que el corpus cuente con variedad de texto: texto que tenga distintos estilos de escritura, que utilicen vocabularios distintos, y que tengan distintos niveles de correctitud ortográfica. Esto dota a los algoritmos de un mayor vocabulario y de información más rica acerca del contexto en el que las palabras pueden aparecer.
- Por último, puesto que el corpus debe contar con gran variedad, es necesario que esté ordenado. Se espera que cada documento esté etiquetado en base a sus cualidades, identificando cuáles son artículos de noticias, cuáles son de determinado país, etc. Etiquetar el texto brinda la posibilidad de construir un corpus a medida, para poder eventualmente hacer pruebas específicas que incluyan o excluyan cierto tipo de texto.

Los requerimientos recién planteados son exigentes, pero permiten la construcción de un corpus altamente versátil. Además de poder entrenar modelos vectoriales particulares a una aplicación (en base al texto que se incluya en el corpus), permite que el mismo pueda ser utilizado en otras investigaciones que no estén relacionadas a las representaciones vectoriales, pero que necesiten de texto en español con ciertas cualidades. Mediante la inclusión de metadatos particulares, de etiquetado según el estilo del texto, y de datos de trazabilidad para cada documento, se busca reforzar esta idea.

El hecho de exigir este tipo de requerimientos, sin embargo, hace que sea necesario tener cuidado al momento de escoger las fuentes de documentos para la construcción del corpus. Además, estos requerimientos imponen restricciones al momento de utilizar alguno de los proyectos de construcción de corpus ya existentes mencionados en la sección anterior, ya sea en su totalidad o tomando subconjuntos de sus documentos o fuentes.

En particular, sólo se consideraron fuentes que ofrezcan garantías mínimas de calidad, en concordancia con los objetivos recién planteados. Se buscó también que los documentos permitan una categorización básica a alto nivel, permitiendo eventualmente filtrar documentos y trabajar solamente con subconjuntos del corpus con ciertas características.

Hecha esta aclaración, se detalla a continuación el proceso seguido para la selección de fuentes de palabras, aclarando cuando corresponda si se utilizaron

fuentes provenientes de corpus ya existentes.

### 3.2.2. Relevamiento de Fuentes de Palabras

Se comenzó por la tarea de evaluar de dónde obtener texto libre de Internet, con el fin de construir un corpus de calidad que cumpla con los requerimientos anteriores. En esta sección enumeraremos los distintos tipos de sitios de donde se recopiló el texto, junto a las características del mismo y una breve descripción de cómo se realizó la extracción. En la siguiente sección se entrará en la implementación de estas técnicas en más detalle.

#### Portales de Noticias

La primer fuente de palabras investigada fueron los portales de noticias en línea, pues presentan varias ventajas: (a) están compuestos de texto por lo general bien escrito; (b) están divididos en documentos que tratan cada uno de un tema particular; (c) cada portal tiene un gran número de artículos y hay una gran cantidad de portales por país; (d) permiten obtener muestras de texto por país, mejorando la riqueza del corpus final; y (e) el texto es fácil de limpiar, pues el único markup con el que cuentan suele ser HTML.

En cuanto al vocabulario utilizado en los artículos de noticias, se puede considerar simple, pero con una fuerte presencia de nombres de personas y lugares, que a su vez son dependientes de la fecha de publicación del artículo: esto es, distintas personas tendrán más o menos menciones en períodos particulares de tiempo. Este punto es importante, y es una de las principales razones para decidir guardar esta fecha de como metadato del artículo.

La investigación de portales de noticias comenzó por el diario La Nación de Argentina [28], por ser uno de los primeros diarios grandes en tener presencia digital, desde el año 2000. Realizando algunos cálculos preliminares en base a un muestreo de artículos, se vio que el diario contaba con al menos un millón de artículos, cada uno con un promedio de 500 palabras, llegando a una masa total de palabras muy importante.

Uno de los primeros puntos que se notó es que la URL de todos los artículos del portal estaban identificadas por un número, y que cambiando este número

por uno distinto, se podía acceder a otra noticia. Además, la generación de estos números es secuencia: esto es, el primer artículo publicado tiene el identificador 1, mientras que el último el 1871018. Este hallazgo fue de suma importancia, pues permitió realizar *scraping* del portal de forma más directa.

Aprovechando esta característica, se construyó un script en Python [93] para recorrer la lista de identificadores (desde el 1 hasta el último presente en la portada) y descargar el contenido de los artículos. Puesto que el corpus a construir requiere de texto limpio, se generaron una serie de reglas XPath [127] para obtener los datos estructurados (título de la noticia, contenido, fecha de publicación). Corriendo este script en la totalidad de La Nación, se llegó a la cifra de 600 millones de palabras exclusivamente con sus artículos.

Los resultados obtenidos demostraron el alto potencial que tienen los portales de noticias como fuentes de palabras, por lo que se procedió a recopilar una lista de los principales diarios de América Latina y España. Con el objetivo de seguir el esquema anterior, se identificaron cuáles de estos sitios identificaban sus artículos con las mismas características, y se adaptó el anterior script a los 20 que presentaban un mayor potencial (en base a la actividad y al contenido).

Para cada uno de estos portales, se construyeron una serie de reglas XPath para extraer el contenido y un mecanismo para recorrer por el identificador numérico. Además se adaptó el script para que revise de forma continua por noticias nuevas, con el fin de que el corpus se mantenga siempre actualizado<sup>1</sup>. Este método lo denominamos *scraping automático*, y más adelante se detallará su implementación (por ejemplo, cómo sabe extraer los datos, cómo se define un nuevo sitio, y cómo se hace la recorrida por identificador).

En base a esta técnica se consiguieron más de 3 mil millones de palabras de texto limpio a partir de 20 portales de noticias.

Cabe resaltar que el método anterior depende de que los artículos de noticias tengan asociado un identificador secuencial. Lamentablemente, esto no es el caso con muchos sitios de noticias importantes y de gran tamaño, como El País de Madrid, El País de Uruguay, o Clarín de Argentina. Por esta razón, se decidió también emplear un mecanismo de *scraping* estándar mediante la herramienta Scrapy [105] para estos portales, implementación que se detalla más adelante.

---

<sup>1</sup>Para ilustrar la importancia de este punto, sólo por mantener actualizado el corpus se consiguieron 300 millones de palabras adicionales en el tiempo de proyecto transcurrido.

### Escritura Amateur

Existen diversos sitios en Internet dedicados a la escritura amateur, donde los usuarios se registran y publican historias propias. Puesto que muchos de estos sitios acumulan una gran cantidad de historias, se decidió investigar esta área en mayor profundidad.

Algunos de estos sitios, como Los Cuentos [63], son de carácter más bien general, donde los usuarios publican narraciones, ensayos, cuentos o poemas. La calidad y el contenido de estos textos varía drásticamente entre uno y otro, pudiendo encontrar piezas con una gran cantidad de faltas de ortografía y carentes de sentido, o piezas por autores renombrados que fueron republicados en el sitio.

La otra gran categoría de escritura amateur presente en Internet es el *fan-fiction* (*ficción de fans*, en inglés). Estos textos suelen ser escritos principalmente por jóvenes, centrados en universos o personajes de la cultura popular, como series de televisión, videojuegos o libros. Debido a esto, su calidad suele ser incluso inferior al anterior grupo. Suelen contener grandes cantidades de diálogo (como si fuera un guión) y muchas menciones a personajes o lugares ficticios.

De todos modos, la media de los textos obtenidos de estas fuentes de palabras está compuesta por oraciones coherentes y con relativamente pocas faltas de ortografía, por lo que es de gran utilidad para el corpus que se pretende construir. Además, existe un gran volumen de datos, y el texto es fácil de limpiar.

Para atacar estos sitios, se optó por usar principalmente la técnica de scraping automático mencionada en la sección anterior, pudiendo así incorporar al corpus nuevas historias en la medida que se escriban.

### Wikimedia

Los distintos proyectos de Wikimedia [120], como Wikipedia, Wikilibros, Wikicitas, y Wikiviajes, son una fuente de palabras particularmente interesante, pues tiene todas las cualidades que se espera del corpus:

- En primer lugar, cuentan con grandes volúmenes de texto que ayudan a

llegar a la meta propuesta. El principal proyecto de Wikimedia es Wikipedia, pero el resto tienen cantidades no despreciables de palabras también.

- Segundo, tienen una gran variedad de contenidos, en especial Wikipedia: siendo una enciclopedia, posee entradas y menciones para países, personas, lugares, eventos, fenómenos, etc., dotando así al corpus de un gran y diverso vocabulario, lo cuál será muy positivo al entrenar modelos vectoriales.
- Tercero, el texto está bien escrito y suele ser activamente revisado por distintas personas, por lo que el nivel de calidad es superior al resto de las fuentes.
- Cuarto, se encuentra dividido en artículos bien delimitados que tratan de un único tema particular, permitiendo obtener resultados más coherentes cuando se realizan búsquedas sobre el corpus.

El contenido de los proyectos de Wikimedia puede ser descargado en línea a través de *dumps* provistos por la fundación misma [121]. La principal complejidad de incorporar esta fuente es, sin embargo, su limpieza, pues los artículos vienen con un *markup* denominado *wikitexto* [124] que dificulta la extracción del texto. De todos modos, existen una gran variedad de herramientas para la limpieza del mismo, cuestión que se detallará más adelante.

## Foros

Los foros de discusión de Internet son otra gran fuente de palabras, en cuanto al volumen de datos. Dado que muchos poseen miles de usuarios registrados, llegan a manejar cantidades de texto muy elevadas. Como contrapartida, sin embargo, el texto publicado suele ser de muy baja calidad, donde algunos mensajes no son más que imágenes o emoticonos y por lo tanto carentes de contenido útil para el propósito del proyecto. Esto último depende también de la audiencia que interactúe en dicho foro, donde sitios con una demografía de edad mayor suelen tener mejor calidad.

De todos modos, se decidió utilizar estas plataformas como fuentes de noticias porque permiten experimentar con la calidad de los modelos vectoriales en función a la calidad del corpus. Además, puesto que suelen tener un estilo más

similar al habla, tienen vocabularios distintos al resto de las fuentes y consecuentemente una mayor cantidad de expresiones del argot de los participantes.

Se utilizaron técnicas de scraping a través de Scrapy para extraer el contenido de estas fuentes, punto que se detallará en la sección siguiente.

### **Subtítulos**

Hay una gran cantidad de texto en los subtítulos de series y películas extranjeras. Como referencia, los subtítulos de un capítulo de una serie de televisión de una hora rondan las cinco mil palabras. Dada la enorme cantidad de series existentes, cada una con decenas de episodios, se llega a un volumen de palabras muy alto.

El texto de los subtítulos por lo general está correctamente escrito, aunque se compone casi exclusivamente de diálogos. Esto también provee otro tipo de vocabulario distinto a las fuentes anteriores pues, por ejemplo, hay un mayor uso de la segunda persona.

La descarga de los subtítulos se realizó con un script manual, bajando todo el contenido disponible en Tu Subtítulo [115]. Luego fue necesario extraer el texto de los mismos, eliminando las indicaciones de tiempo (cuándo debe aparecer cada línea en pantalla) y el markup que pueden contener (tags HTML por lo general).

### **Documentos Oficiales**

Muchas instituciones públicas publican grandes cantidades de textos con el fin de informar a sus poblaciones sobre distintos temas, o de mantener registro de las actividades de sus representantes. Entre este tipo de texto se encuentran las versiones taquigráficas de sesiones de parlamentos de países u organizaciones internacionales, como la UE o UNASUR, así como comunicados de distintas instituciones como la ONU. Estos textos suelen tener una jerga particular, pues son muchas veces documentos altamente técnicos, pero son no obstante textos de calidad que pueden aportar mayor volumen y vocabulario al corpus.

Se incorporaron dos fuentes de documentos oficiales al corpus: los diarios de

sesiones del parlamento Uruguayo del año 1985 a la fecha y los comunicados emitidos por la ONU entre los años 1999 a 2009.

El primero fue descargado a través de un script de la página del Poder Legislativo Uruguayo [88] y luego procesado para eliminar el markup. Contiene las sesiones de la Cámara de Diputados, la Cámara de Senadores, y de la Asamblea General. El mecanismo para su descarga se detalla más adelante.

El segundo fue tomado de un corpus paralelo generado por [31] como insumo para tareas de traducción automática. Fue descargado de [85], procesado y finalmente agregado al corpus construido.

## Libros

Una fuente de palabras inmediata son libros de texto en español, pues se cuenta con cientos de miles, cada uno de gran tamaño. En la mayoría de los casos también son revisados por un editor, por lo que la calidad de la escritura es superior a la encontrada en las otras fuentes. Además cuentan con una gran variedad de vocabulario, pues su contenido va desde de ficciones narrativas hasta textos científicos.

La incorporación de libros en el corpus presenta, sin embargo, varias dificultad: en primer lugar, no es fácil acceder digitalmente a colecciones importantes de libros, pues no están disponibles de manera pública en Internet fácilmente. Segundo, incluso cuando sí es posible obtener libros digitalmente, suelen estar en formatos que hacen la extracción de texto muy compleja (por ejemplo, PDFs con escaneos del texto).

Se optó por utilizar un corpus ya existente que recopila textos relacionados a la Unión Europea (en particular a su librería, *EU Bookshop* [35]), provista por el proyecto *LetsMT!* [57].eu. Este es un corpus paralelo para la traducción automática, pero es posible utilizar únicamente los textos en español para incorporar al corpus.

Está compuesto principalmente por publicaciones escritas por instituciones de la UE, por lo que suelen ser de carácter más bien oficial (esto es, tratados, informes, y similares). Aún así, cuenta con algunos libros de lectura general.

## Otros Corpus

Se realizó también una investigación de los corpus en español existentes en la comunidad, como se mencionó en el capítulo anterior. Algunos de ellos, como los corpus paralelos de traducción automática a los que se hizo referencia arriba, fueron incluso incorporados al corpus.

Además, se tuvieron en cuenta fuentes de documentos que forman parte de proyectos de construcción de corpus de mayor envergadura. En particular, se utilizaron algunos de los recursos recopilados por el proyecto OPUS de la Universidad de Upsala, Suecia [92]. Dicho proyecto cuenta con una amplia colección de textos de carácter público, en varios idiomas. OPUS ofrece sus recursos de forma libre, tanto los textos recopilados como algunas herramientas utilizadas para la limpieza y preprocesamiento de los mismos.

Se tomaron en particular los documentos en español del EU Bookshop [35], mencionado en la subsección anterior. Como ya se comentó, la colección contiene documentos con temáticas variadas que datan desde el año 1952 hasta la actualidad.

Se tomó también una colección de resoluciones de la Asamblea General de las Naciones Unidas [85]. Dicha colección cuenta con traducciones para las seis lenguas oficiales de la organización, incluyendo naturalmente al español. Al tratarse de documentos con relevancia jurídica se puede confiar en la calidad de las traducciones. Los textos abarcan diversas temáticas y formatos, desde transcripciones o sumarios de reuniones oficiales hasta tratados de economía o resoluciones de carácter legal. Se utiliza además un lenguaje técnico y formal, lo cual convierte a estos textos en un excelente complemento para el resto de documentos que componen el corpus.

Finalmente, vale la pena comentar que tanto para las publicaciones del EU Bookshop como para las resoluciones de las Naciones Unidas fue necesario escribir scripts de limpieza que adaptaran los diversos formatos de los documentos de cada colección en un formato compatible con nuestro modelo de datos.



### 3.3. Implementación

A continuación se detalla la implementación del proceso de extracción del texto. Se comienza describiendo la arquitectura de la solución, fundamentando las decisiones tomadas, y luego se especifican las distintas técnicas empleadas para la obtención del texto.

#### Infraestructura

Uno de los principales desafíos del proyecto consiste en almacenar grandes cantidades de información de manera eficiente e indexar dicha información de tal forma que puedan realizarse búsquedas sobre la misma en tiempos razonables. Por lo tanto, se realizó una investigación de cuáles son las alternativas para almacenar grandes volúmenes de texto, evaluando tanto soluciones SQL como NoSQL. Finalmente, se optó por utilizar Elasticsearch [32] por ofrecer excelentes cualidades para almacenar información, pero sobre todo por brindar excelentes funcionalidades de indexado y búsqueda sobre los datos almacenados.

Elasticsearch es un almacén de documentos JSON (similar a una base de datos NoSQL) que provee funcionalidades de búsqueda *full-text* (esto es, texto libre sin ningún tipo de estructura) basado en la biblioteca Lucene [7], desarrollada para este propósito. Provee una interfaz HTTP RESTful para el acceso, consulta y almacenamiento de los documentos con los que trabaja.

Se optó utilizar Elasticsearch porque brinda varias ventajas por sobre las alternativas:

- Permite el almacenamiento grandes volúmenes de datos sin mayores problemas. Es capaz de manejar millones de documentos con ajustes mínimos a su configuración inicial. Esto será de crucial en el presente escenario, pues es el mayor punto de presión en la infraestructura.
- Brinda funcionalidades de búsqueda de texto que, mientras que no son un requerimiento *a priori*, son de gran utilidad a la hora de explorar el corpus. Utilizando la biblioteca Lucene, es capaz de realizar búsquedas *full-text*, aplicando técnicas de *stemming* y similares para mejorar la recuperación de documentos. Esto es de gran utilidad para estudiar la composición de los corpus de texto que se arman para entrenar modelos vectoriales.

- Posee mayor flexibilidad a la hora de diseñar el modelo de datos, permitiendo almacenar diferentes documentos con sólo algunos campos en común (e.g. que todos los documentos tengan un campo de texto, y que el resto dependa de la fuente de datos).
- Permite mezclar datos estructurados y texto libre, permitiendo así realizar consultas avanzadas (como, por ejemplo, cantidad de palabras por fuente de datos).
- Puede, en caso de ser necesario, adaptarse fácilmente a una infraestructura distribuida, con replicación y balanceo de carga para poder manejar incluso mayor cantidad de documentos.

Es importante mencionar que, comparado con un RDBMS más establecido como PostgreSQL, Elasticsearch no carece de problemas. Es sabido que bajo ciertas circunstancias, es posible que ocurra una pérdida de documentos [50], aunque esto ocurre en esquemas distribuidos y bajo casos muy particulares que no nada frecuentes. Además, el hecho de estar almacenando información no crítica (esto es, no son registros de usuarios, por ejemplo), esto no plantea mayores riesgos.

Naturalmente, la tarea de realizar scraping selectivo pero sumamente intensivo de un gran número de fuentes, junto con el trabajo de almacenar la enorme cantidad de información recolectada resultan en un proceso sumamente exigente tanto en capacidad de cómputo, almacenamiento en disco y ancho de banda. Resultó claro desde un principio que utilizar una computadora personal no resultaría ser una opción razonable.

Se decidió por tanto evaluar las distintas alternativas existentes de proveedores para la contratación de un servidor virtual en la nube. Desde un principio se decidió que el servidor contratado no sería utilizado solamente para recolectar y almacenar documentos para la creación del corpus, sino que también se lo utilizaría para el entrenamiento de vectores de palabras y el alojamiento de la herramienta web a construir. Por estos motivos, se buscó el proveedor que ofreciera el mejor equilibrio entre poder de cómputo, espacio en disco, ancho de banda disponible y, por supuesto, costo mensual.

Inicialmente se decidió aplicar al programa de becas para la investigación y educación de Amazon [8]. Dicho programa admite la presentación de proyectos en ciertas áreas de investigación, entre ellas PLN y aprendizaje automático, y de ser aprobados otorga crédito en una cuenta de *Amazon Web Services* (AWS)

que puede utilizarse para contratar servidores en la nube de Amazon durante el tiempo que dure el proyecto. Para que la beca sea aprobada es necesario presentar un resumen del proyecto en cuestión junto con una estimación de los recursos necesarios en AWS para su desarrollo.

En nuestro caso presentamos una solicitud de beca en abril de 2015 por un valor estimado de recursos en AWS de 2.200 dólares, que equivale al alquiler por un año de un servidor con las características necesarias para la realización del proyecto. Al presentar nuestra solicitud Amazon nos informó que recibiríamos el resultado de la misma en aproximadamente tres meses, demasiado tiempo para los objetivos del proyecto.

Procedimos entonces a buscar otras alternativas, como se explica a continuación. De cualquier manera, nuestra solicitud fue aprobada por Amazon en setiembre de 2015. A pesar de que ya era tarde para usar el crédito obtenido en la contratación de un servidor, pudimos utilizar la beca para contratar otros servicios de interés.

Entre las opciones consideradas para la contratación del servidor destacan *Amazon EC2* [3], *Microsoft Azure* [70] y *Google Cloud Platform* [39], todos ellos proveedores altamente prestigiosos que ofrecen excelentes servicios. Lamentablemente, nos resultó imposible asumir los costos mensuales de la clase servidores que cumplen con nuestras expectativas en todas las facetas, al menos con estos proveedores. Al continuar investigando encontramos *Webtropia* [119], un proveedor alemán no tan popular, pero con precios mucho más asequibles. Por tanto, se contrató un servidor virtual con las características presentadas en el cuadro 3.1.

Característica	Valor
Cantidad de núcleos virtuales	16
Memoria RAM garantizada	24GB
Memoria RAM dinámica	48GB
Espacio en disco (SSD)	500GB
Nivel de RAID (hardware)	10
Ancho de banda	500MBit
Sistema operativo	Ubuntu 14.04
Costo mensual (Euros)	39.99

Cuadro 3.1: Webtropia: vServer Cloud XL 4.0 (SSD).

Es importante destacar que el servidor fue contratado en el mes de abril de 2015 y los costos mensuales (39,99 EUR) fueron asumidos enteramente por nosotros.

Cabe mencionar también que el servidor contratado corre el proceso de Elasticsearch y toda la infraestructura de almacenamiento. Ejecuta además todos los trabajos de scraping periódicos, junto con una instancia de PostgreSQL para almacenamiento de datos de sincronización de dichos trabajos. Ahí se aloja también la herramienta construida para el manejo de vectores, que se analizará en gran detalle en una sección particular. Esto implica que en el servidor se ejecutan todos los trabajos de entrenamiento y evaluación de vectores, limpieza de documentos, etcétera.

Sin lugar a dudas podemos afirmar que la elección de contratar un servidor virtual fue una decisión acertada, pues simplificó mucho el manejo de enormes cantidades de información de forma remota. Y, sobre todo, permitió que tareas con enormes exigencias desde el punto de vista computacional, como son el entrenamiento y evaluación de vectores de palabras, pudieran realizarse en tiempos razonables.

Finalmente, es importante remarcar que se hicieron respaldos de todos los datos del sistema. En particular, se respaldó el corpus en su totalidad utilizando funcionalidades de Elasticsearch que permiten realizar un volcado de los datos directamente en un *bucket* de Amazon S3 [4]. Para el pago de este servicio se utilizó el crédito obtenido en la beca de Amazon mencionada anteriormente.

Además, se respaldaron todos los vectores construidos junto con los casos de prueba y sus respectivos resultados para cada vector. Para esto se realizaron descargas periódicas de los respaldos a nuestras computadoras personales y a medios de almacenamiento externo dedicados especialmente a esta tarea.

En las secciones siguientes se continúa con el análisis detallado del proceso de construcción del corpus, mencionando las técnicas y estructuras utilizadas para conseguirlo.

### Scraping Automático

Como se mencionó en la sección anterior, para el *scraping* de los portales de noticias que referencian a sus artículos con un identificador secuencial, se

construyó un sistema especializado para la tarea de extracción de los mismos.

Este sistema se compone de una base de datos con información de las fuentes de datos y los artículos que son necesarios descargar; un módulo de scraping que se encarga de descargar, procesar y almacenar en Elasticsearch cada uno de estos artículos; y un conjunto de módulos de extracción que especifican, para cada sitio, cómo realizar el procesamiento de sus artículos. La arquitectura se puede visualizar en el diagrama 3.1.

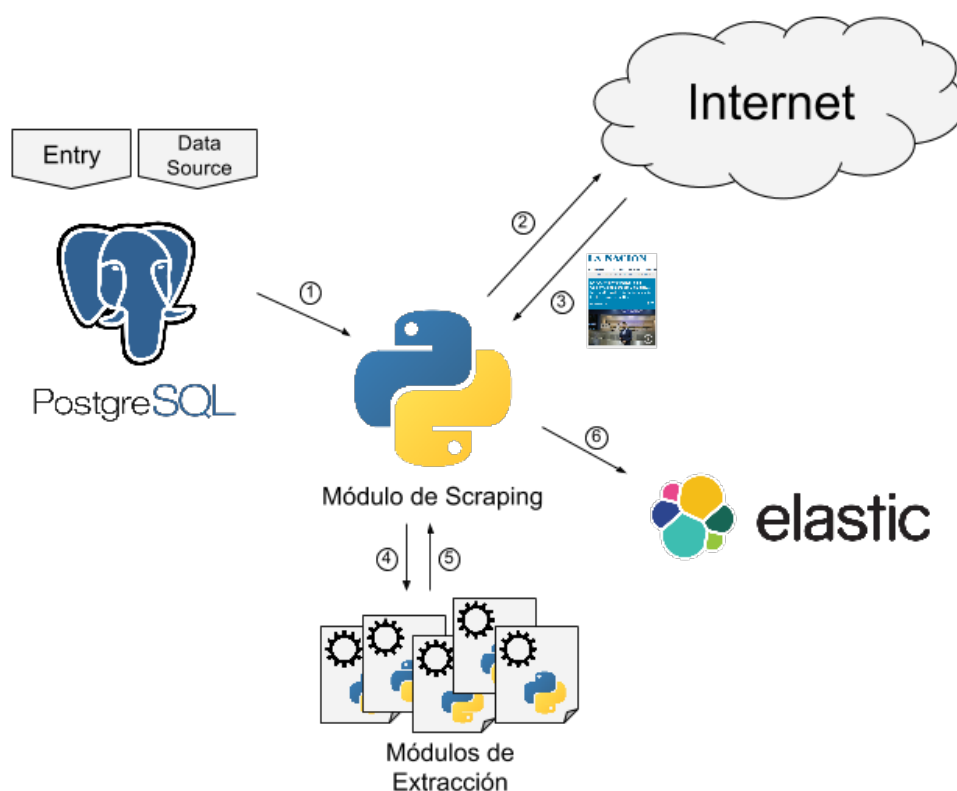


Figura 3.1: *Arquitectura general del sistema construido.* El módulo de scraping toma los datos de la base de datos (PostgreSQL), descarga la página web de Internet y se lo envía al módulo de extracción adecuado, guardándolo finalmente ya procesado en Elasticsearch.

A continuación detallaremos cada uno de estos componentes.

**Modelo de Datos** El modelo de datos consiste de fuentes de datos (`DataSource`) y de entradas (`Entry`), almacenados en una base de datos *PostgreSQL* [91]. Los `DataSource` son un modelo simple que describe las fuentes de palabras registradas en el sistema y cuenta básicamente del dominio del sitio (e.g. `lanacion.com.ar`), con el que se identifica a la fuente. Además mantiene dos atributos adicionales: si está activo (esto es, si se tienen que extraer documentos del mismo), y el nivel de concurrencia con el cuál realizar pedidos (para no saturar a la fuente; su funcionamiento se detalla más adelante).

Por otro lado, las `Entry` son registros que identifican cada documento de cada fuente de palabras, junto con el identificador a nivel de dicha fuente, el resultado del proceso de extracción, la fecha en la que se agregó, el último intento, la cantidad de intentos, y la fuente a la que pertenece. El resultado del proceso puede ser *pendiente*, cuando todavía no se intentó descargar el artículo asociado, *éxito*, cuando se extrajo correctamente el contenido, o uno de tres indicadores de error (*no encontrado*, *imposible de procesar*, o *intento fallido*, que se describen más adelante). Con la cantidad de intentos se busca evitar que un artículo no se descargue por un error incidental, buscando reintentar hasta cinco veces dicha acción.

Así, es posible mantener un registro detallado y estadísticas de todo el proceso de extracción. Para cada fuente de datos, es posible saber cuántas entradas fueron revisadas, qué porcentaje de éstas no contienen un documento asociado, y si alguna fuente está teniendo problemas en la extracción. Esto último ayuda, por ejemplo, a detectar rápidamente un cambio de diseño en un sitio que provoque que las reglas XPath queden obsoletas.

**Módulos de Extracción** Los módulos de extracción describen cómo es la interacción con los sitios de noticias en tres aspectos: en cómo obtener la lista de identificadores que faltan procesar, en cómo obtener el contenido de un artículo dado su código HTML, y en cómo obtener metadatos adicionales del artículo (como su fecha de publicación). Para ello se define una interfaz que cada módulo debe implementar, consistente de los siguientes elementos:

- Constantes `SOURCE_DOMAIN` y `DOCUMENT_URL`, que especifican el nombre de la fuente (e.g. `lanacion.com.ar`) y la URL de sus documentos dado un identificador, respectivamente.
- Función `get_missing_ids`, que recibe una lista de identificadores ya exis-

tentes en la base de datos y devuelve los identificadores faltantes. Para esto la función puede, por ejemplo, entrar a la página inicial del portal y obtener el identificador asociado a la noticia más reciente.

- Función `get_content`, que recibe la respuesta del portal ante el pedido de un artículo particular. Esta función deberá revisar el código de respuesta para asegurarse que efectivamente se haya encontrado un artículo. Aquí se encapsula la lógica de extracción del texto limpio, ya sea mediante la utilización de reglas XPath o selectores CSS, mediante la ayuda de la biblioteca `lxml` [95]. En caso de tener éxito, devolverá el contenido del artículo y un valor de salida `success`; en caso de haber un error, devolverá `notfound`, `failure`, o `unparseable`. El objetivo de esta distinción es saber si es necesario reintentar porque el fallo fue por un error circunstancial (caso `failure`), si no existe un artículo (caso `notfound`), o si hubo un problema al extraer los datos (caso `unparseable`), en cuyo caso será necesario revisar el proceso de extracción.
- Función `get_metadata`, que recibe la respuesta de un artículo para el cual se extrajo exitosamente el contenido, y devuelve los metadatos pertinentes al documento (fecha de publicación, título, etc.).

Así, es posible incorporar una nueva fuente de palabras simplemente agregando un archivo Python que siga la anterior interfaz. El módulo de scraping se encargará así de dar de alta la nueva fuente en la base de datos y empezar a descargar el contenido. Esto brinda un diseño flexible y fácil de extender en un futuro.

**Módulo de Scraping** El sistema corre como un *daemon* que realiza el siguiente ciclo:

- Revisa cuáles son las fuentes de datos existentes, junto a su configuración, dando de alta en la base de datos cualquier fuente que no tenga un registro, en base a los módulos existentes.
- Para cada fuente de datos, crea las entradas faltantes en la tabla correspondiente, en base a lo que le indique el módulo de extracción asociado a la fuente.

- Para cada entrada cuyo estado es *pendiente*, se descarga el HTML del artículo asociado y se extrae tanto el contenido como los metadatos del mismo, de acuerdo a lo especificado en el módulo de extracción asociado a la fuente.
- Se actualiza la entrada con el resultado obtenido, y se almacena el documento extraído en Elasticsearch con el formato adecuado.
- Cuando no quedan más entradas pendientes, duerme por 15 minutos y vuelve a empezar el ciclo.

Con el fin de no tener que esperar por las respuestas de los sitios de noticias uno a uno, lo que implicaría una espera de décimas de segundos para cada documento que haría imposible la descarga de los millones que se requieren, el módulo de scraping se implementa como un bucle de eventos.

Un bucle de eventos (*event loop*, en inglés), es una construcción que permite ejecutar concurrentemente funciones que dependen de eventos externos bloqueantes (como acceso a un dispositivo de Entrada/Salida) sin que el hilo del programa principal tenga que bloquearse esperando, de manera similar a como hace un sistema operativo de tiempo compartido.

Ésta técnica consiste de un bucle principal que se encarga de ejecutar una serie de corrutinas, las cuales se suspenderán cuando sean bloqueadas esperando un evento externo y continuarán su ejecución cuando el bucle principal se lo indique. Para esto, el bucle debe emplear técnicas de *polling* (o la funcionalidad equivalente que provea el sistema operativo) para saber cuándo un evento está listo para ser atendido.

Se utilizó la implementación de la biblioteca estándar de Python de esta construcción, denominada `asyncio` [94]. De esta forma, es posible descargar cientos de artículos concurrentemente, sin demorarse por un sitio particularmente lento. Para ello, cuando se recorren las entradas pendientes y se realiza un pedido HTTP para obtener el artículo, la función que procesa los artículos se suspende hasta que la descarga finalice, continuando con otro artículo mientras tanto.

De todos modos, es necesario limitar la cantidad máxima de concurrencia por dos razones: primero, porque se corre el riesgo de iniciar miles o hasta millones de pedidos en simultáneo, lo cual es computacionalmente muy costoso e improductivo; y segundo, porque no se quiere saturar a los sitios de noticias



con demasiados pedidos activos, ya que se correría el riesgo de que se le prohiba el acceso a nuestro sistema. Algunos sitios son particularmente susceptibles a este último punto, por lo que se decidió que el nivel de concurrencia sea configurable a nivel de cada fuente de datos.

Para concluir esta sección, presentamos algunos números del proceso. Mediante este sistema se extrajeron 11,363,251 documentos de 20 portales de noticias, obteniendo así un total de 4,391,944,678 mil millones de palabras. Se dieron de alta un total de 17,053,703 entradas, de las cuales un 58,6 % llevó a la extracción exitosa de un documento, donde algunas fuentes de noticias fueron más rentables que otras.

### Scraping Manual

**Scrapy** Para las fuentes de palabras que carecen de una estructura que favorece su extracción automática mediante el método anterior, se utilizaron también técnicas de scraping convencionales, a través de *Scrapy* [105].

Scrapy es un framework escrito en Python ideado para brindar una solución integral al problema de realizar scraping en la web. Entre sus principales ventajas se encuentra la sencillez de su propuesta, basada en la construcción de web spiders (arañas web) especializadas para cada dominio del cual interesa extraer información. Además, Scrapy brinda una serie de herramientas y utilidades que simplifican de manera importante este tipo de tareas.

La habilidad de recorrer el contenido de un portal iterando sobre los identificadores de sus artículos o noticias es una gran ventaja y facilita mucho el trabajo de extracción, pero hay multitud de fuentes interesantes que no permiten esta metodología. En particular los portales El País (tanto de Madrid como de Uruguay) son de sumo interés para la construcción del corpus del proyecto y se requirió construir web spiders para los mismos.

Para este tipo de casos se escribieron web spiders con Scrapy que primero navegaran a las secciones de archivo o hemeroteca de cada portal y que luego, siguiendo diferentes pasos, accedieran a los artículos en sí mismos. Naturalmente, las rutas de navegación para cada sitio son variables y por lo tanto fue necesario escribir spiders para cada portal que requiriera scraping manual. Es importante mencionar que cada uno de estos spiders especializados cuenta con reglas específicas para extraer y limpiar el contenido útil de cada artículo ex-

traído.

Una vez construido, cada web spider es ejecutado para agregar los artículos recopilados al corpus. Cada uno de ellos puede ejecutarse en varias oportunidades, permitiendo obtener nuevos artículos y parando cuando se detecta que ya se obtuvieron todos los nuevos resultados. Además, en todos los casos se buscó encontrar identificadores únicos para cada artículo de forma de no agregar elementos repetidos al corpus. Esto se logró utilizando identificadores propios de cada portal o usando fragmentos de la URL de cada artículo.

**Scripts de limpieza** Para algunas fuentes, como es el caso de Wikipedia, se puede descargar su contenido directamente a través de un dump (o volcado) en algún formato portable y de fácil distribución. Por ejemplo, en algunos casos puede descargarse un dump de una base de datos en formato SQL, o también en formato XML, como es el caso de Wikipedia. Otras fuentes utilizan sus propios formatos para la distribución de sus datos, pero en todos ellos resulta indispensable realizar una limpieza antes de proceder a agregarlos al corpus.

En nuestro caso, para aquellas fuentes que ofrecen su contenido de forma directa y sin necesidad de realizar scraping, decidimos utilizar scripts de limpieza escritos en Python que lidien directamente con los dumps obtenidos. Los mismos recorren todos los archivos que compongan un dump en particular, extrayendo y limpiando los datos útiles para luego indexarlos directamente en Elasticsearch.

El proceso de extracción resulta más o menos complicado dependiendo del formato provisto por cada fuente, pero las tareas de limpieza suelen ser sencillas. El objetivo siempre es preservar el texto original, limitándonos simplemente a remover etiquetas o restos de código que pueden quedar al procesar los documentos.

En particular, para Wikipedia se utilizó el popular script WikiExtractor [122], para las tareas más complejas de procesamiento del dump de Wikipedia, junto con un script propio para el procesamiento final y posterior inserción en Elasticsearch. Dicho script se encuentra en el archivo `wiki.py`, en el directorio `scripts` del código fuente del proyecto. Se utilizaron también scripts para la limpieza e inserción de las sesiones del parlamento Uruguayo (`parlamento.py`) y los documentos oficiales de las Naciones Unidas (`multiun.py`). Finalmente, para las fuentes EU Bookshop y el sitio *tusubtitulo.com* se utilizaron los scripts

`eubookshop.py` y `tusubtitulo.py` respectivamente.

## 3.4. Resultado

En esta sección se pretende presentar un análisis de la composición y la calidad del corpus construido, mostrando algunas cifras por vertical de texto. Se incluye una caracterización del corpus según los tipos de fuente que lo componen y se presenta una breve discusión acerca de los aspectos más importantes de calidad.

### 3.4.1. Composición del Corpus

Luego de meses de trabajo se logró no solo alcanzar la meta de dos mil millones de palabras, fijada al inicio del proyecto, sino que se logró superarla ampliamente logrando construir un corpus con casi seis mil millones de palabras (5,970,953,659). Esta cantidad se encuentra repartida en trece millones de documentos (13,108,394), con un promedio de 455 palabras por documento.

La cantidad total de palabras alcanzada en el corpus es un logro sumamente significativo, consiguiendo casi triplicar la cantidad fijada como objetivo al comienzo del proyecto. Este hecho adquiere mayor relevancia considerando que los mayores tamaños conseguidos en los trabajos de estado del arte en materia de construcción de corpus rondan los ocho mil millones de palabras.

Sin embargo, es importante resaltar que todos los trabajos que alcanzaron dichas cantidades utilizaron técnicas de crawling masivo como metodología para la construcción de sus corpus. Esto contrasta con el enfoque adoptado en el presente proyecto, en el cuál se realizó crawling selectivo logrando algunas garantías básicas de calidad y un conocimiento más detallado de los documentos que componen el corpus. El objetivo fue por tanto lograr un corpus de calidad por construcción.

Como ya se mencionó, todos los documentos que componen el corpus fueron etiquetados de acuerdo a sus características. Las etiquetas utilizadas pueden dividirse en tres categorías: tipo de documento, región de origen e idioma. Naturalmente, todos los textos que componen el corpus contienen la etiqueta de

idioma español, pero aun así se decidió incluir este tipo de etiqueta pensando en un posible trabajo futuro, donde las herramientas aquí construidas podrán ser utilizadas para trabajar con corpus en varios idiomas.

En el cuadro 3.3 puede verse el detalle de cantidad de palabras por zona geográfica de los documentos que componen el corpus, detallando además las cantidades por tipo de documento. En el cuadro 3.2 en cambio, se realiza un análisis complementario incluyendo datos sólo por tipo de documento.

Tipo de documento	Documentos	Palabras	Proporción (palabras)
Noticias	11.318.776	4.376.315.796	73.2 %
Wikipedia	1.113.372	416.932.056	7.0 %
Documentos oficiales	69.965	417.833.686	7.0 %
Escritura amateur	372.627	318.811.674	5.3 %
Libros	7.437	202.546.087	3.4 %
Foros	199.129	133.942.466	2.2 %
Subtítulos	27.105	106.501.897	1.8 %

Cuadro 3.2: Composición del corpus por tipo de documento.

Es importante notar que no todas las fuentes lograron ser etiquetadas por su origen y que la proporción que se muestra en el cuadro 3.3 corresponde a la comparación con la totalidad de palabras del corpus. Por otro lado, sí se logró etiquetar todos los documentos de acuerdo a su tipo de documento.

Como se puede ver, la mayor cantidad de palabras provienen de fuentes del tipo noticias, aunque de todas formas se consiguió el objetivo de tener una considerable variedad de tipos de fuentes representadas.

### 3.4.2. Calidad del Corpus

Como ya se comentó previamente, al momento de elegir las fuentes para la composición del corpus se realizó un cuidadoso proceso de selección. Para las fuentes que requirieron crawling se escribieron reglas específicas para obtener el contenido útil de sus páginas. En el caso de fuentes recopiladas en formatos disponibles para descargar de forma directa, se escribieron scripts de limpieza especializados para cada una. De esta forma, se buscó en todo momento que el corpus generado tuviera atributos de calidad por construcción.

Origen	Tipo	Documentos	Palabras	Porcentaje <sup>2</sup>
Argentina	Noticias	2.130.965	969.052.149	18.5 %
	Foros	199.129	133.942.466	
	<i>Total</i>	2.330.094	<b>1.102.994.615</b>	
México	Noticias	2.489.280	<b>934.356.171</b>	15.6 %
Uruguay	Noticias	1.961.752	748.998.277	14.3 %
	Docs. oficiales	3.418	103.988.021	
	<i>Total</i>	1.965.170	<b>852.986.298</b>	
España	Noticias	1.631.521	<b>809.067.269</b>	13.5 %
Paraguay	Noticias	1.919.737	<b>529.593.496</b>	8.9 %
Unión Europea	Docs. oficiales	66.547	313.845.665	8.6 %
	Libros	7.437	202.546.087	
	<i>Total</i>	73.984	<b>516.391.752</b>	
Chile	Noticias	713.541	<b>228.490.971</b>	3.8 %
Perú	Noticias	313.081	<b>100.124.272</b>	1.7 %
Bolivia	Noticias	158.924	<b>56.640.181</b>	0.9 %

Cuadro 3.3: Composición del corpus por zona geográfica.

En casos donde se requiere un corpus etiquetado, los requerimientos de calidad del mismo son naturalmente más exigentes y es recomendable realizar un análisis riguroso de sus características de composición y calidad. Sin embargo, para nuestro caso de estudio consideramos como suficientes los atributos de calidad obtenidos gracias a las técnicas utilizadas para la construcción del mismo. Todas las reglas de extracción y scripts de limpieza fueron debidamente evaluados de modo de obtener una alta confianza en la calidad de la composición del corpus.

# Capítulo 4

## Herramienta

El entrenamiento de modelos de representaciones vectoriales es un proceso costoso tanto desde el punto de vista computacional como cognitivo: requiere recopilar una gran cantidad de texto, realizarle un preprocesamiento adecuado (e.g. sacarle mayúsculas, símbolos), utilizarlo para alimentar a un modelo que tiene un gran consumo de memoria y de poder de cómputo, para luego obtener un modelo vectorial también de gran tamaño. Este modelo debe también poder evaluarse para determinar su utilidad, corriendo una variada batería de pruebas, explorando así el espacio de hiperparámetros para obtener una configuración razonable.

Con el fin de simplificar este proceso, y permitir a cualquier investigador realizar experimentos con modelos vectoriales, se plantea la elaboración de una herramienta que sea capaz de abstraerse de todas las tareas de bajo nivel, permitiendo construir representaciones vectoriales a través de una interfaz web. El objetivo es pues brindar herramienta que, en base a un fragmento del corpus y una configuración de hiperparámetros, entrene y deje disponible para utilizar vectores de palabras generados a medida para una tarea particular.

### 4.1. Requerimientos

Antes de iniciar la construcción de la herramienta, se fijaron una serie de requerimientos que se esperaba que la misma lograra satisfacer:

- Dado que se cuenta con un corpus de gran tamaño, etiquetado y almacenado en un motor de búsqueda, es conveniente ofrecer la posibilidad de explorarlo de manera interactiva. Para esto se pretende brindar funcionalidades de búsqueda a través de consultas de texto basadas en el contenido de los documentos, o filtrando a partir de los campos estructurados (los metadatos, la fuente de palabras, las etiquetas, etc.).

Esto permitirá que un usuario pueda encontrar ejemplos de uso del lenguaje particulares fácilmente pudiendo, por ejemplo, ver todos los documentos donde aparece la palabra *fútbol* en portales de noticias Uruguayos (documentos con las etiquetas *uruguay* y *news*). Lograr particionar así el corpus permitirá también entrenar vectores con datos especializados.

- Los algoritmos que se utilizan para construir representaciones vectoriales requieren de una capacidad de cómputo muy elevada, por lo que no se pueden entrenar localmente en una computadora común (al menos no en tiempos razonables). Por esta razón, es imprescindible contar con un servidor de cómputo especializado que tenga las capacidades necesarias para correr los algoritmos.

Resulta conveniente, por lo tanto, que la interfaz sirva de mediador entre el usuario y dicho servidor, pudiendo entrenar o evaluar modelos allí de manera remota, para no tener que realizar esta tarea manualmente, que presenta sus dificultades. Así, un usuario será capaz de enviar a entrenar un modelo y que éste quede corriendo de fondo en el servidor de cómputo por el tiempo que sea necesario, sin requerir de interacción adicional hasta que el algoritmo finalice.

- Además de brindar acceso a un servidor especializado, se desea que el usuario pueda entrenar los algoritmos deseados a medida, a partir del corpus o de secciones del mismo. Para ello, deberá ser posible elegir el modelo de representación vectorial a utilizar (Skipgram, CBOW, GloVe, o PPMI), junto a los hiperparámetros que cada uno de ellos posee. Además es necesario que se pueda indicar qué corpus utilizar para el entrenamiento, pudiendo elegirse la totalidad del mismo o secciones particulares en caso que se desee obtener vectores especializados en algún campo. Para esto último, se deberá permitir ingresar una consulta de Elasticsearch para usar el resultado de la misma como corpus de entrenamiento.
- También debe ser posible dar de alta conjuntos de pruebas para distintos tipos de tareas (esto es, analogías, similitud entre palabras, etc.) y correr las evaluaciones en los modelos ya entrenados, pudiendo estudiar así el comportamiento de los mismos en distintos escenarios.

- Considerando estos dos últimos puntos, también es deseable que el usuario pueda fácilmente visualizar y comparar el resultado obtenido en un conjunto de pruebas para los distintos modelos entrenados, pudiendo así elegir fácilmente la mejor configuración de hiperparámetros para una tarea particular.
- Puesto que tanto el corpus como los modelos y los conjuntos de pruebas están almacenados en servidores remotos, es necesario poder descargarlos. Para el corpus es deseable también ofrecer la posibilidad de descargar partes del mismo para no tener que procesarlo localmente, lo cual puede ser muy costoso debido a su tamaño.
- Dado que el proceso de construcción del corpus es continuo, como se detalló en la sección de scraping automático, puede ser de utilidad ofrecer estadísticas sobre la composición del corpus, incluyendo cómo ha variado su tamaño en recientemente, con el fin de poder controlar que el proceso de extracción esté funcionando correctamente. Esto ayuda considerablemente a detectar cuándo una fuente de palabras ha dejado de contribuir texto, lo cuál puede ocurrir por, por ejemplo, un cambio en el diseño de la misma que rompa las reglas XPath empleadas.
- Por último, es importante tener en cuenta la usabilidad de la herramienta, manteniendo presente que debe facilitar la construcción de modelos vectoriales, y no dificultarlas. Para esto, deberá prestarse especial cuidado al diseño final de la misma.

En definitiva, uno de los objetivos principales de la herramienta es la coordinación entre las distintas componentes de la arquitectura de la aplicación. Se cuenta por un lado con un Elasticsearch donde se almacena de manera organizada todo el corpus recopilado. También se cuenta con un servidor de cómputo que entrena y evalúa remotamente los modelos deseados. La herramienta servirá como nexo para estos dos nodos, permitiendo al usuario acceder, interactuar y descargar los distintos artefactos (corpus, modelos, pruebas) de la aplicación.

## 4.2. Diseño de la Solución

En esta sección se presenta el diseño de la herramienta a alto nivel. El objetivo principal aquí es mostrar las funcionalidades principales de la misma desde



el punto de vista de un usuario. La discusión es por tanto a nivel conceptual, haciendo especial hincapié en mostrar qué puede hacerse con la herramienta y cómo se organizan estas funcionalidades.

Desde el punto de vista conceptual, la herramienta se divide en cuatro grandes secciones: *Dashboard*, *Corpus*, *Embeddings* y *Tests*. A continuación se encuentra la descripción en detalle de cada una de estas secciones.

### 4.2.1. Dashboard

La sección *Dashboard* es la más sencilla aunque aporta elementos de visualización muy útiles. Principalmente se incluye un apartado por cada fuente utilizada para construir el corpus. En dichos apartados se detalla el nombre de la fuente, la cantidad de palabras que la misma aporta al corpus y una pequeña gráfica que muestra la cantidad de palabras que han sido obtenidas recientemente de dicha fuente.

Estas gráficas cumplen la doble función de presentar la cantidad de palabras obtenidas de cada fuente de forma diaria y además alertar de un posible defecto en el correspondiente script de extracción cuando la cantidad extraída presenta una caída muy pronunciada con respecto a registros inmediatamente anteriores.

Como se explicó en secciones anteriores, fue necesario elaborar una cantidad considerable de scripts para extraer información de las diferentes fuentes elegidas para construir el corpus. En algunos casos dicha extracción se realizó en una única etapa. En otros casos, como por ejemplo los portales de noticias, es de interés volver a visitar las fuentes de forma diaria para poder indexar los nuevos documentos que hayan sido agregados. Naturalmente, las fuentes pueden cambiar su estructura y los scripts utilizados pueden fallar ante estos cambios. Por este motivo, resulta sumamente útil contar con una forma visual de detectar estos problemas rápidamente.

Finalmente, en esta sección se incluye la cantidad total de palabras que forman el corpus. Dicho número se actualiza de forma automática en intervalos regulares y se despliega un mensaje cada vez que se obtienen nuevas palabras de alguna de las fuentes.

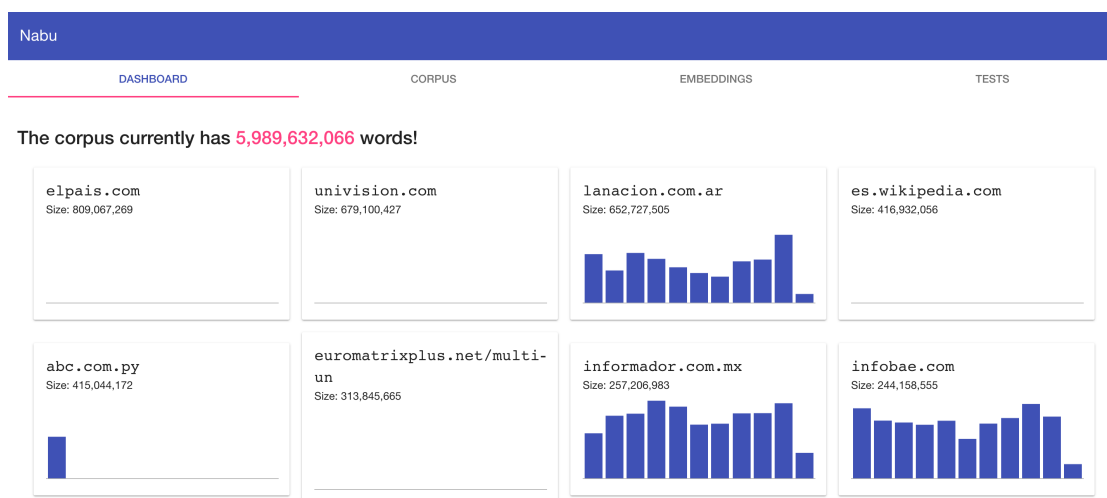


Figura 4.1: Pantalla Dashboard en la aplicación web.

### 4.2.2. Corpus

La sección *Corpus* permite explorar la totalidad del corpus construido en el proyecto sin apenas restricciones. Se ofrece un campo de búsqueda en el cual un usuario puede escribir una serie de términos de consulta y se ofrece además la posibilidad de filtrar por un subconjunto de las fuentes consideradas.

Estas dos operaciones de apariencia sencilla construyen por detrás consultas en el formato JSON empleado por Elasticsearch. Se permite visualizar y eventualmente modificar completamente la consulta inherente en formato JSON a través del interruptor de *consulta avanzada*. Al activar este interruptor, el usuario cuenta con todo el poder de expresividad del formato de consultas de Elasticsearch y por tanto puede ejecutar consultas potencialmente complejas sobre el corpus.

Una vez ejecutada una consulta se presenta una tabla con los documentos resultantes de la misma, con su correspondiente paginación. En la tabla se incluye la fecha de extracción del documento, un breve fragmento del texto que lo compone, resaltando los términos que lo hacen relevante a la consulta, y la fuente de la que fue extraído.

Al hacer click en un documento de la tabla se presenta un cuadro de diálogo con información más detallada del mismo. Se incluye cantidad de total de palabras, etiquetas, la fecha de creación en la fuente (si está disponible) y el cuerpo

completo del texto que lo compone. Se ofrece además un botón para abrir en una nueva pestaña el documento en su fuente original, de modo de poder corroborar en cualquier momento la fidelidad de los elementos del corpus.

En la vista principal se ofrecen además dos acciones adicionales. La primera de ellas permite descargar el conjunto completo de documentos retornado al ejecutar la consulta, comprimidos en formato ZIP. La segunda acción permite utilizar la consulta como entrada para crear un nuevo vector, que se entrenará con el subconjunto de documentos obtenido a partir de la consulta. Los detalles de creación de vectores en el frontend se detallan más adelante. Pero dado que el corpus se encuentra en constante crecimiento, es importante mencionar aquí que es recomendable especificar rangos de fechas de extracción en las consultas al momento de crear nuevos vectores, de modo de permitir la posterior reproducción de los resultados obtenidos.



Figura 4.2: Pantalla Corpus en la aplicación web.

### 4.2.3. Embeddings

En la sección *Embeddings* se encapsulan la mayoría de las funcionalidades vinculadas a las operaciones sobre vectores. En su vista principal se listan todos los vectores creados en el sistema. De cada uno se detalla su descripción, el tipo de representación vectorial utilizada (*word2vec*, *glove*, o *svd*), los paráme-

tros de configuración del algoritmo elegido y su estado de entrenamiento. Para cada vector los estados de entrenamiento posibles son *entrenado*, *en entrenamiento* y *sin entrenar*.

Esta vista ofrece un botón para crear y poner a entrenar un nuevo vector. Al momento de crear vectores se debe seleccionar uno de los tres modelos (en el caso de `word2vec` es necesario además especificar el algoritmo a utilizar, `Skipgram` ó `CBOW`), fijar los valores de sus parámetros, especificar la consulta en formato JSON que Elasticsearch utilizará para devolver los documentos de entrenamiento y finalmente elegir los parámetros de preprocesamiento de texto. Una vez creado el vector, este será agregado a la cola de entrenamiento.

Al hacer click en las tarjetas de información de los vectores se accede a una vista en detalle del vector seleccionado. En los detalles, además de la información ya provista en la vista de listado, se incluye el tamaño total en palabras del sub-corpus utilizado en el entrenamiento del vector, el detalle completo de los parámetros del modelo elegido, la consulta JSON utilizada para seleccionar los documentos de entrenamiento y las opciones de preprocesamiento para el texto de dichos documentos. Cuando el vector se encuentra en entrenamiento se incluye además una barra de progreso informando del avance actual en el entrenamiento.

De forma conveniente, junto al cuadro de la consulta en formato JSON se incluye un botón para ejecutar la misma en la sección de *Corpus*. Esto facilita la posibilidad de explorar el conjunto de documentos utilizados para entrenar el vector. Eventualmente, un usuario podría descargar dicho conjunto para entrenar un nuevo vector de forma local utilizando el mismo algoritmo, de modo de verificar los resultados logrados con la herramienta presentada en este proyecto.

Continuando con la descripción de la vista en detalle, se incluye al final de la misma una tabla con información acerca de resultados de evaluación del vector. En esta tabla se listan todos los conjuntos de prueba con los que este fue evaluado, la fecha de cada evaluación, el porcentaje de precisión alcanzado en cada una y una botón para obtener una visión más detallada de los resultados de cada prueba. Además, se incluye una columna que indica el desempeño del vector en cada evaluación en comparación con el resto de vectores del sistema. Cuando el vector es el de mayor precisión en una determinada prueba, se muestra un indicador del hecho junto a su posición.

La tabla de resultados de evaluación ofrece también una acción para ejecutar nuevas evaluaciones sobre los vectores, permitiendo reevaluar todas las pruebas, sólo evaluar aquellas aun no ejecutadas, o evaluar un caso de prueba particular.

Finalmente se ofrecen acciones para eliminar el vector y para descargarlo a la computadora del usuario. La opción de descargar los vectores entrenados con la herramienta es una de las funcionalidad más valiosas e importantes del proyecto. Esta funcionalidad permite a cualquier usuario interesado en el campo de las representaciones vectoriales de palabras poder entrenar sus propios vectores y luego descargarlos para su uso en alguna aplicación de interés, sin la necesidad de poseer detallados conocimientos de los aspectos de bajo nivel de las representaciones.

	DASHBOARD	CORPUS	EMBEDDINGS	TESTS
W	word2vec algo=skipgram dim=300 win=10 alpha=0.025 hs=False neg=10 epochs=10 Even fuller word2vec, more epochs			Training - 90%
W	word2vec algo=skipgram dim=100 win=7 alpha=0.025 hs=False neg=5 epochs=2 Full word2vec			
S	svd dim=300 win=5 cds=0.75 context=True Reduced SVD			
W	word2vec algo=skipgram dim=300 win=7 alpha=0.025 hs=False neg=5 epochs=1 Full word2vec, no subsampling			
W	word2vec algo=skipgram dim=300 win=7 alpha=0.025 hs=False neg=7 epochs=1 Full word2vec			
W	word2vec algo=skipgram dim=300 win=7 alpha=0.025 hs=False neg=7 epochs=1 Reduced word2vec			

Figura 4.3: Pantalla Embeddings en la aplicación web.

#### 4.2.4. Tests

En la sección *Tests* se encuentra toda la información relacionada a la evaluación de los vectores de palabras creados en el sistema. En su vista principal se presenta la lista de casos de prueba disponibles, indicando para cada uno su nombre, descripción y categoría. Las categorías principales son *Analogías*, *Similitud* y *Odd-one-out* (palabra que no encaja). De forma conveniente, en esta vista se muestra también una pequeña medalla en cada caso de prueba con la cantidad de vectores que están siendo evaluados actualmente, junto con un indicador de progreso de la tarea actual.

Los usuarios pueden hacer click en un caso de prueba para acceder a la vista de detalles, donde se presenta información adicional. Además de los datos mostrados en la vista principal, se presenta un ejemplo puntual del caso de prueba para mayor claridad de lo que se pretende evaluar. De manera adicional, se muestran mayores detalles acerca de las tareas de evaluación que se están ejecutando en el momento.

En la vista de detalles se presenta también una tabla con resultados de evaluación. Para cada vector evaluado con el caso de prueba se indica la fecha de la evaluación, un enlace a la página de detalles del vector, el modelo utilizado por dicho vector, el porcentaje de precisión logrado en el caso de prueba y un botón para ver los detalles en profundidad de la evaluación. En los detalles en profundidad se encuentra, cuando corresponde, el desempeño en las métricas 3COSADD y 3COSMUL (porcentaje de aciertos exactos, y entre las primeras cinco y diez sugerencias), palabras no encontradas, entradas faltantes, entradas equivocadas y cantidad total de entradas.

Desde la vista de detalles también es posible agendar nuevos trabajos de evaluación. Al momento de crearlos se puede optar por elegir todos los vectores que aun no fueron evaluados con el caso de prueba ó por elegir uno en particular. También es posible optar por ejecutar el caso de prueba en todos los vectores del sistema. En la parte superior de la pantalla se ofrecen además dos acciones adicionales, una para eliminar el caso de prueba del sistema y otra para descargarlo en un archivo en formato de cuatro columnas.

Finalmente, en la vista principal se cuenta con un botón que da acceso a un formulario para crear un nuevo caso de pruebas en el sistema. En el formulario es necesario especificar nombre, descripción y categoría para la nueva evaluación. Además es necesario subir un archivo de texto en formato de cuatro columnas desde la computadora del cliente. Dicho archivo debe contener cuatro palabras separadas por un espacio por línea, donde las primeras tres columnas se utilizarán en la evaluación y la cuarta es el resultado esperado. El formato recién descrito es el mismo para las tres categorías existentes actualmente, pero la semántica de cada columna depende de cada categoría, como bien se explicó en secciones anteriores.

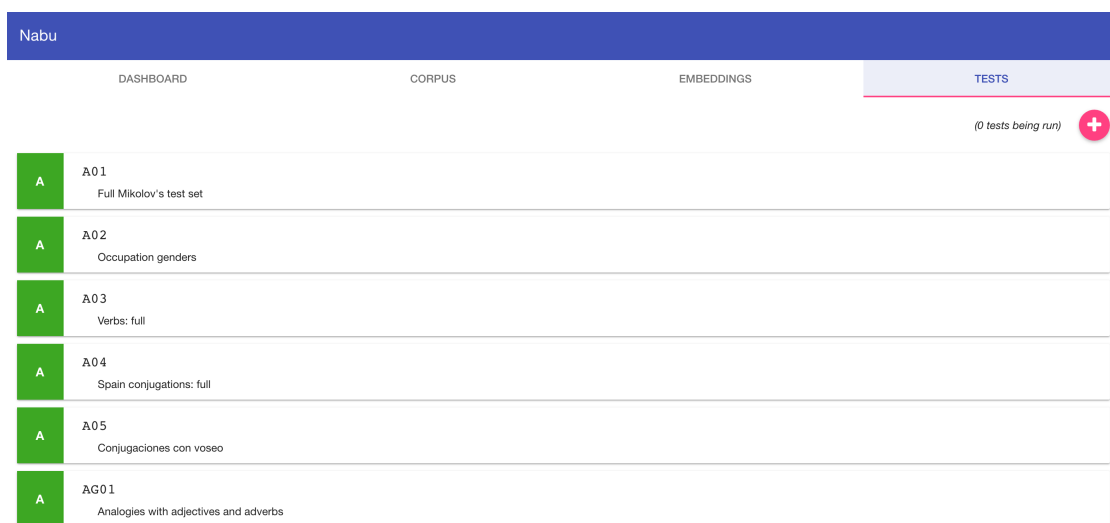


Figura 4.4: Pantalla Tests en la aplicación web.

## 4.3. Implementación

En esta sección se presenta la implementación de la herramienta. Se comienza dando una descripción de la arquitectura general de la misma, pasando luego a detallar la implementación de cada módulo.

### 4.3.1. Arquitectura General

Dada la cantidad de requerimientos que se plantearon para la herramienta, fue necesario diagramar de antemano una arquitectura que logre escalar y brindar todas las funcionalidades satisfactoriamente. Ésta cuenta de cinco componentes, o nodos, cada uno especializado en una función distinta:

- Un nodo corriendo Elasticsearch, donde se almacena la totalidad del corpus de texto, como se detalló en el capítulo anterior.
- Un nodo corriendo PostgreSQL, donde se almacenan tanto las tablas relacionadas al scraping automático como el modelo de datos empleado para la herramienta (esto es, información relacionada a los modelos vectoriales entrenados y sus evaluaciones).

- Un conjunto de nodos, denominados trabajadores o *workers*, donde corren los algoritmos para generar las representaciones vectoriales. Estos nodos son especiales en cuanto a que deben contar con mayores recursos para poder entrenar los modelos en tiempos razonables. Su función es consumir pedidos de una cola de tareas que indica qué algoritmo se debe entrenar a continuación, y devolver el resultado.
- Un nodo donde corre el servidor de aplicación que coordina los distintos componentes de la arquitectura y ofrece una interfaz RESTful [36] para interacción con el sistema. Sus funciones incluyen la administración de la cola de tareas, la realización de consultas en Elasticsearch, y la actualización del modelo de datos, entre otros.
- Un nodo que sirve una aplicación web encargada de ofrecer una interfaz web sobre el servidor de aplicaciones que pueda ser utilizada por un usuario no especializado.

Cabe notar que en la actualidad todos estos componentes corren en un único servidor con muchos recursos (mencionado en el capítulo anterior), por no tener la herramienta demasiada demanda. Sin embargo, es posible dividirlo en distintos servidores simplemente cambiando la configuración de los nodos, permitiendo así escalar a un mayor número de usuarios de ser necesario.

La comunicación entre las distintas partes puede observarse en la figura [figura]. En el centro de la arquitectura se encuentra el servidor de aplicación, que se encarga de coordinar el resto de los nodos. Éste ofrece una API (o *Application Programming Interface*) RESTful que permite realizar consultas sobre el corpus, crear nuevos modelos vectoriales, enviarlos a entrenar y evaluar, y todo el resto de las funcionalidades que ofrece la herramienta. Tiene, por lo tanto, que comunicarse con el nodo de Elasticsearch, con el nodo de PostgreSQL, y mantener la cola de tareas que los *workers* posteriormente consumirán.

Los nodos *workers* también deben comunicarse con Elasticsearch, para obtener el contenido del corpus de entrenamiento, y con PostgreSQL, para actualizar el estado de los modelos vectoriales que se entrenan o evalúan.

Por otro lado, la aplicación web se comunica únicamente con el servidor de aplicaciones, pues la interfaz de este último es capaz de abstraer toda la maquinaria interna de la herramienta. Por esta razón, denominamos la aplicación web como la parte delantera de la aplicación (o *frontend*) y al resto de los nodos (el servidor de aplicación y los otros nodos) la parte trasera (o *backend*).



[diagrama ES + PSQL + BACKEND + FRONTEND + JOBQUEUE]

### 4.3.2. Backend

El *backend* de la aplicación busca, como se mencionó anteriormente, brindar una interfaz RESTful capaz de abstraer las particularidades de la implementación de la herramienta. Internamente se encarga de la comunicación con Elasticsearch (donde se almacena el corpus) y PostgreSQL (donde se mantiene el estado de la aplicación), y de coordinar y realizar el entrenamiento y evaluación de los vectores de manera distribuida a través de una cola de tareas. Permite también la interacción con los datos que componen el estado de la aplicación.

#### Modelo de Datos

Empezaremos detallando el modelo de datos que define al dominio con el que trata la herramienta:

- En primer lugar, se cuenta con modelos (esto es, tablas en la base de datos) para las representaciones vectoriales que se registraron en la herramienta. Para cada una de ellas se guarda el algoritmo empleado para su generación, los hiperparámetros del mismo (que dependen, claro está, del algoritmo), la consulta de Elasticsearch a través de la cual se obtiene el corpus de entrenamiento, y el tipo de preprocesamiento empleado para tratar el texto previo a entrenar.

Además almacena la fecha de creación y el estado actual del modelo, que puede ser *sin entrenar*, *entrenando*, o *entrenado*, dependiendo si ya se corrió el algoritmo o no. En caso de que ya se haya entrenado, se guarda también una referencia a la ubicación de los archivos de los vectores.

- También se cuenta con modelos para los distintos conjuntos de prueba dados de alta en el sistema. Para cada uno de ellos se registra el tipo de pruebas (esto es, si son analogías, similitud de palabras, etc.) y la ubicación del archivo que contiene los datos de prueba. Por comodidad, también se les puede asignar un nombre y una descripción.

- Se emplean modelos adicionales para almacenar los resultados de las evaluaciones de los distintos vectores de palabras. Cada uno de estos cuenta con referencias al modelo vectorial y el conjunto de pruebas a los que describe, junto con los resultados obtenidos en la evaluación (esto es, la precisión y otros datos, dependiendo del tipo de prueba).
- Por último, se cuenta con modelos para registrar las tareas (o *jobs*) que corren en los nodos trabajadores para el entrenamiento y evaluación de los vectores. Su funcionamiento se describirá más adelante, pero se puede mencionar que se guardan datos acerca del tiempo empleado y fecha de agendado de la tarea, para poder luego estudiar el tiempo de cómputo requerido para generar las representaciones.

### Cola de Tareas

Para el entrenamiento de vectores, se ideó una arquitectura basada en una cola de tareas (o *job queue*) en el que el servidor de aplicación da de alta tareas que serán luego llevadas a cabo por nodos trabajadores (o *workers*), los cuales cuentan con amplios recursos computacionales para correr los algoritmos. Esto es necesario ya que los algoritmos pueden demorar horas e incluso días en finalizar, por lo que es imposible correrlos en el tiempo en que se debe atender un pedido HTTP.

Se utilizó la biblioteca Celery [21] para la comunicación y la administración de dicha cola. Celery ofrece un mecanismo para producir y consumir mensajes en una cola de tareas en tiempo real, a través de un sistema distribuido, flexible, y confiable, lo que lo hace una buena opción para la herramienta a construir. A través de esta biblioteca, es posible definir tipos de tareas (como puede ser entrenar o evaluar un modelo vectorial) y luego dar de alta mensajes que serán consumido por nodos trabajadores, los cuales se encargarán de correr el código necesario y devolver el resultado.

Celery se limita a coordinar el uso de la cola de tareas, por lo que toda la información adicional que sea necesaria almacenar respecto a las tareas (identificadores y resultados, por ejemplo), debe ser mantenida por una base de datos especializada. Para la presente arquitectura se decidió utilizar Redis, un almacén de estructuras de datos en memoria, por ser una solución simple y liviana.

Se definen dos tipos de tareas que el sistema correrá de manera asincrónica: una para el entrenamiento de representaciones vectoriales y otra para la evaluación de las mismas. El primer tipo recibe el modelo vectorial a entrenar (esto es, el algoritmo a utilizar, sus hiperparámetros, la consulta de Elasticsearch que describe al corpus de texto, y las opciones de preprocesamiento de los datos) y luego procede a correr el algoritmo, reportando el progreso periódicamente. Una vez finalizado, actualiza los registros asociados a los vectores en la base de datos (pasando el estado de la tarea a *entrenado*, por ejemplo) y los persiste en el sistema de archivos del servidor.

El segundo tipo de tarea recibe el modelo vectorial (ya entrenado) a evaluar y el conjunto de pruebas a utilizar. Una vez cargados todos los datos en memoria, procede a realizar la evaluación, la cual dependerá del tipo de prueba que se está realizando (esto es, si es una tarea de analogías o de similitud de palabra, por ejemplo). Reporta el progreso conforme avanza con la evaluación y finalmente almacena el resultado en la base de datos. En caso de ya existir un resultado para la combinación de vectores y pruebas, lo sobrescribe.

Para cada tipo de tarea, es necesario mantener ciertos metadatos asociados a la misma, por lo que se mantiene una tabla para cada una con este fin, como se mencionó anteriormente. En éstas se almacena información pertinente para la ejecución de la tarea (modelos vectoriales y conjuntos de pruebas sobre los que actuar, principalmente) e información sobre la tarea en sí. En particular, se registra un identificador (denominado `task_id`) con el que se puede consultar el progreso y el estado de la tarea a través de Celery. También se almacenan otros metadatos como la fecha de agendado y el tiempo de ejecución de la tarea.

Al recibir un pedido a través de la API para entrenar un modelo vectorial particular, el servidor de aplicación da de alta una nueva tarea en la cola mediante Celery, creando también un registro asociado en la base de datos, y devolviendo al pedido HTTP el identificador de la tarea. Por detrás, un nodo trabajador recibirá la tarea a ejecutar y la iniciará, cambiando el estado de la misma a *entrenando* y reportando el progreso periódicamente. Mientras ejecuta, el usuario puede realizar otro llamado a la API para consultar el estado de la tarea utilizando el identificador de la misma. Una vez finalizada la ejecución el estado pasará a *entrenado* y, cuando el usuario vuelva a consultar por el progreso, se le indicará que ya ha terminado. Esto lo habilitará a descargar o evaluar el modelo.

Para la evaluación de modelos el procedimiento es análogo, con la diferencia

que a través de un único llamado a la API es posible evaluar un modelo en varios conjuntos de prueba o vice versa. Para ambos casos (entrenamiento y evaluación) se tienen consideraciones especiales cuando se crea una tarea si la misma está actualmente en ejecución o ya ha terminado: para el entrenamiento de un vector, se devolverá un error, mientras que para la evaluación se borrarán primero los resultados existentes.

En la figura [figura] se diagrama el funcionamiento del procedimiento completo. Se muestra además cómo interactúan los distintos componentes de la cola de tareas entre sí y cómo se comunican con el resto de los nodos del sistema.

[diagrama (API -¿celery -¿redis -¿worker -¿redis; API -¿celery -¿redis)]

## Entrenamiento

Con el fin de evitar errores de implementación en los algoritmos para generar representaciones vectoriales, se buscó, donde fue posible, aprovechar bibliotecas ya existentes y probadas.

**word2vec** Debido a su popularidad, existen varias implementaciones de `word2vec` en la comunidad. En primer lugar se encuentra, claro está, la implementación de los algoritmos CBOW y SGNS hechas por Mikolov [125]. También existen implementaciones en diversos lenguajes de programación, como la provista por `Gensim` (escrita en Python [99]), o la provista por `mllib` (escrita en Java [126]), entre otras.

Se optó por utilizar la implementación de la biblioteca `Gensim` pues el hecho de estar escrita en Python facilita mucho su integración con el resto del sistema. Además, como muestran los contactos que tuvo el autor de la misma con Mikolov [citas], es una implementación probada que llega incluso a ser más eficiente computacionalmente que la original, a pesar de estar escrita en Python.

**GloVe** Para el caso de GloVe se decidió utilizar la implementación provista por los autores [89], pues no existen bibliotecas satisfactorias escritas en Python. Por esta razón la tarea de integración fue más compleja, pues fue necesario utilizar el módulo Python `subprocess` para comunicarse con un proceso hijo

que corre los algoritmos, transmitiendo el texto del corpus a través de la entrada estándar del mismo.

**Modelo Estadístico** Para el cuarto algoritmo, el modelo estadístico basado en la matriz PPMI con SVD, fue necesario realizar una implementación propia, pues no fue posible encontrar ninguna que cumpliera con los requerimientos necesarios. Partiendo del artículo de Levy y Goldberg [60], y aprovechando parte del código provisto por los autores en [49], se elaboró un módulo Python para la construcción de representaciones con dicho modelo.

Se utilizaron las bibliotecas `numpy` [86] y `scipy` [104] para la manipulación numérica de matrices (matrices dispersas, en particular, como lo es la matriz de coocurrencias con medida PPMI), y el `wrapper sparsesvd` [110] de la biblioteca `SVDLIBC` [112] para la aplicación de SVD a matrices dispersas.

Teniendo en cuenta algunas sugerencias de los autores en cuanto al tratamiento efectivo de matrices dispersas (en lo que respecta al uso de memoria principalmente), se logró a una implementación satisfactoria del algoritmo con un comportamiento similar al que describen los autores en el artículo original. Se implementan también las heurísticas que los autores encuentran que favorecen la performance del algoritmo, como el *subsampling* de palabras comunes y la eliminación de palabras poco frecuentes.

## Evaluación

Se implementaron tres mecanismos de evaluación para las representaciones vectoriales, a continuación se describe el proceso de implementación para cada uno.

**Analogías** El primero de ellos es la tarea de analogías, descrita anteriormente, donde se debe obtener una palabra ( $w_4$ ) en base a otras tres ( $w_1, w_2, w_3$ ) bajo el esquema “ $w_1$  es a  $w_2$  lo que  $w_3$  es a  $w_4$ ”.

Los conjuntos de pruebas para esta tarea se componen de una lista de 4-uplas con las palabras que forman la analogía, donde la última es que se debe recuperar. El *job* encargado de correr la evaluación leerá el archivo con los datos

(una analogía por línea) y utilizará las métricas 3COSADD y 3COSMUL para obtener el resultado (como se especifica en el [capítulo 2]).

Se almacena el porcentaje de aciertos exactos, el porcentaje de aciertos entre las cinco primeras sugerencias, y el porcentaje de aciertos entre las diez primeras sugerencias. De esta forma se puede estimar, en caso de que haya fallado la recuperación, qué tan cerca se estuvo. Se registra también la cantidad de palabras que no se encontraron en el vocabulario del modelo para tener una idea de qué tanto afecta esto al resultado final, pues la ausencia en el vocabulario cuenta como un fallo<sup>1</sup>.

**Similitud** El segundo mecanismo de evaluación es la similitud de palabras. Esta tarea asigna un puntaje entre 0 y 10 a la similitud o relación entre pares de palabras, donde 10 significa que una palabra puede ser sustituida por otra en un contexto dado (caso similitud) o son palabras que están estrechamente relacionadas (caso relación).

La prueba en sí consiste en cargar la lista de pares de palabras, asignar un puntaje a cada par de palabras (utilizando la distancia coseno entre sus representaciones vectoriales) y calcular la correlación entre los puntajes obtenidos y los del conjunto de pruebas (que son asignados por jueces humanos). Esta es la técnica estándar en la literatura para evaluar la capacidad de capturar relaciones de similitud por parte de los vectores de palabras, como se vio en el [capítulo 2].

Los archivos con los datos de prueba consisten en una lista de dos palabras y su puntaje de similitud asociado. Por otro lado, y al igual que en las analogías, se guarda también la cantidad de palabras que no se encontraron en el vocabulario.

**Odd-one-out** El tercer mecanismo de evaluación consiste en encontrar la palabra que no encaja en un conjunto de palabras (encontrar el *odd-one-out*). Por ejemplo, la palabra *auto* en el conjunto de palabras *auto*, *rótula*, *pelvis*, y *metatarso*. Se pueden construir, por ejemplo, pruebas tanto por campo semántico (como el recién ejemplificado) como por campo sintáctico (donde se busca, por ejemplo, identificar al verbo con conjugación distinta).

---

<sup>1</sup>Si no contara como un fallo, un modelo vectorial con un vocabulario de diez palabras podría tener un porcentaje de aciertos perfecto en todas las pruebas.

No existe mucho trabajo en la literatura con este esquema de pruebas, pero aún así es útil para comparar los distintos tipos de representaciones entre sí, en una tarea que busca medir también qué tanto se capturan las similitudes entre palabras.

El conjunto de pruebas consta de una lista de palabras (de largo variable) donde la primera es la palabra que no encaja. Para obtener cuál es dicha palabra, se toma el centroide (el promedio componente a componente de los vectores) y se devuelve la palabra más lejana al mismo. En este caso se almacenan la cantidad de resultados donde ninguna palabra está presente en el vocabulario; se considera aceptable que falten palabras mientras que sea capaz de obtener correctamente el resultado.

Cabe notar también que al momento de evaluar los modelos vectoriales se le aplica a las palabras del conjunto de pruebas el mismo preprocesamiento que se le aplicó al corpus de texto al construir los vectores. Así se evitan problemas de incompatibilidad entre las pruebas y las representaciones (donde uno saca los tildes y el otro no, por ejemplo).

## API HTTP

El último gran componente del backend es la API web, cuyo objetivo es brindar una interfaz HTTP RESTful que permita interactuar con toda esta maquinaria ya descrita, buscando en lo posible esconder las complejidades de la misma. Esto es, se busca que el usuario que utilice esta API no requiera conocimiento de Celery, ni de PostgreSQL, ni de la implementación particular de los algoritmos y evaluaciones utilizados, ni de ningún otro componente interno del sistema. Así, para el usuario, los modelos vectoriales estarán siendo entrenados por una caja negra que devuelve una lista de vectores con determinadas características al finalizar.

Con este fin, la API se maneja exclusivamente a nivel del modelo de datos: esto es, el usuario interactúa con recursos REST [36] que representan al dominio del sistema que se describió antes, junto con un recurso especial para la búsqueda de documentos en el corpus.

El principal objetivo de esta interfaz es ser consumida por el frontend de la

herramienta, aunque puede ser utilizada por un usuario realizando los pedidos HTTP manualmente si así lo desea.

**Corpus** Se exponen tres *endpoints* (URLs que referencian a un recurso particular) relacionados con el corpus de texto, todos bajo el prefijo `/corpus/`. El primero de ellos, `/corpus/search/` permite realizar una búsqueda en el texto, filtrando por la aparición de uno o más términos determinados o por campos de los metadatos asociados a cada documento. La consulta se especifica a través de un documento JSON [52], siguiendo el formato empleado por Elasticsearch, por lo que ofrece toda las funcionalidades que este motor de búsqueda brinda. Para cada documento recuperado, se devuelve fragmento de su contenido, con el texto que coincide con el término de búsqueda resaltado. También se provee funcionalidades de paginado para no tener problemas con consultas demasiado grandes.

A través del endpoint `/corpus/document/<id>/`, es posible recuperar un documento en su totalidad, con el contenido completo y todos sus metadatos. En caso de existir, también se provee una URL para acceder al documento directamente en la fuente correspondiente.

Puesto que recorrer todo el corpus documento a documento a través de los anteriores llamados sería extremadamente ineficiente, se provee un endpoint adicional, `/corpus/download/`, que, a partir de una consulta con el mismo formato de las búsquedas, devuelve un archivo con el contenido de todos los documentos que coinciden con la misma. Para ello, se recuperan los documentos y se construye un archivo comprimido en formato ZIP [130] compuesto por un archivo de texto plano por documento.

Dado que los contenidos asociados al resultado de una consulta podrían ocupar un gran tamaño (en el orden de *gigabytes*), es imprescindible este archivo no se genere por completo en el servidor y que luego se envíe al usuario. Con este fin, se utilizó la biblioteca de Python `zipstream` [96], que permite ir construyendo y sirviendo el contenido de un archivo ZIP mientras el usuario lo va descargando, agregándole los archivos con el contenido de los documentos uno a uno, logrando así que el archivo final nunca se almacene por completo en el servidor.

Por otro lado, cabe notar que permitir al usuario ingresar una consulta genérica a través de la API plantea ciertas consideraciones de seguridad. Dado que la



entrada del usuario se restringe a una consulta sobre el corpus, no podrá modificar el contenido almacenado. Sin embargo, fue necesario tomar precauciones adicionales y bloquear la funcionalidad de consultas con scripts de Elasticsearch [33] para evitar inconvenientes<sup>2</sup>.

**Vectores y Pruebas** La API también brinda funcionalidades para manipular vectores de palabras, conjuntos de pruebas y resultados. Para cada uno de estos tres recursos, es posible crearlos, obtener sus detalles (a través de un identificador asignado a cada uno, e.g. `/embeddings/1/`), listarlos, modificarlos, y eliminarlos.

En el caso de las representaciones vectoriales, la vista detallada devuelve qué algoritmo se utilizó para entrenar, los hiperparámetros empleados, el corpus utilizado (la consulta de Elasticsearch, el tamaño en cantidad de palabras, y las opciones de preprocesamiento), y si ya ha sido entrenado o no. Es posible asignarles una descripción para poder identificarlos más fácilmente. También es posible descargar los vectores a través del endpoint `/embeddings/<id>/download/`, donde se emplea una técnica similar a la descrita en la sección anterior para devolverle al usuario los archivos asociados a dicho modelo.

Los conjuntos de pruebas devuelven el tipo de prueba que contienen (e.g. analogías), junto con un nombre y una descripción asignadas por el usuario. Se devuelve también un ejemplo de la prueba, para que el usuario tenga como referencia (por ejemplo, “‘increíble’ is to ‘increíblemente’ as ‘aparente’ is to... (‘aparentemente’)”). Al igual que en los vectores, es posible descargar los datos del conjunto de pruebas a través del endpoint `/testsets/<id>/download/`, donde se devuelve directamente un archivo de texto plano con las entradas.

Para los dos anteriores casos, sólo es posible modificar el nombre y descripción de los recursos; en caso de querer cambiar, por ejemplo, los hiperparámetros, es necesario crear un nuevo modelo, pues sino quedaría inconsistente el modelo ya entrenado con los registros en la base de datos. Se toma esta decisión para evitar que el usuario inadvertidamente tenga que volver a entrenar los vectores de palabras por realizar un cambio menor.

Por último, en el caso de los resultados, sólo es posible ver, listar y eliminarlos. La vista de los detalles de un resultado contienen el porcentaje de aciertos

---

<sup>2</sup>De hecho, las nuevas versiones de Elasticsearch vienen con esta funcionalidad deshabilitada por este mismo motivo.

logrados y datos adicionales dependiendo del tipo de prueba (por ejemplo, el porcentaje de aciertos en el top 10 en las analogías). El listado también permite filtrar por vector de palabras o por conjunto de pruebas, para poder fácilmente visualizar cuáles son los resultados de las pruebas para una representación, o vice versa.

**Manejo de Tareas** Como ya se mencionó anteriormente, la ejecución de tareas (que abarca tanto el entrenamiento como la evaluación de las representaciones) se realiza también a través de una API, bajo el prefijo `/jobs/`. Para entrenar un modelo vectorial, es necesario simplemente indicar cuál es el identificador del recurso. En caso de ya estar entrenado, o de estar actualmente en entrenamiento, se devolverá un error. En otro caso, se agregará a la cola de tareas y se devolverá el identificador de la tarea asociada.

Estos identificadores se pueden luego utilizar para ver el estado de las tareas, mediante el endpoint `/jobs/training/<id>/`. A través de este llamado se devolverá el estado (si todavía está esperando, si ya está corriendo, o si ha ocurrido un error) y el progreso de la tarea (un porcentaje). Si no se indica ningún identificador, es posible listar todas las tareas existentes, las cuales se pueden filtrar según si ya han terminado o si están en la cola.

Se puede también cancelar el entrenamiento utilizando el verbo HTTP `DELETE`, lo cual abortará al algoritmo y borrará el registro de la tarea de la base de datos.

El tratamiento con las tareas de evaluación es análogo, con diferencias únicamente al momento de agregar una tarea. Es posible, en este caso, indicar que una representación vectorial debe ser evaluado con un conjunto de pruebas particular, con los conjuntos con los que no ha sido evaluado aún, o con todos los disponibles. En caso de ya haber sido evaluado, se eliminará el resultado anterior y se correrá de nuevo. Lo opuesto también es posible indicando, para un conjunto de pruebas, que sea utilizado para evaluar todos los modelos vectoriales faltantes. Esto ayuda a evitar que tenga que enviarse todas las combinaciones de pruebas y vectores a la hora de evaluar.

**Introspección** En los endpoints que se han descrito hasta ahora hay muchos datos que el usuario debe ingresar que cumplen con ciertas restricciones: por ejemplo, el tipo de representación vectorial puede ser únicamente `word2vec`, `glove`, o `svd`. Cada uno de ellos, a su vez, tiene un conjunto de hiperparáme-

tros particulares, con tipos de datos específicos.

Con el fin de no tener que realizar un *hard code* de estas alternativas en el frontend de la herramienta, y para dejar parte de la funcionalidad documentada para un posible usuario, se decidió brindar una serie de endpoints que describen las variantes de modelos vectoriales, conjuntos de pruebas, y opciones de preprocesamiento. Esto funciona también como una única *fuentes de verdad* sobre las funcionalidades de la herramienta.

El primero de ellos, `/enums/models/`, devuelve una lista de modelos, junto con su nombre descriptivo, y una lista de hiperparámetros que el usuario debe especificar. Por ejemplo, para el caso `word2vec`, se indica que hay un hiperparámetro denominado `algorithm` que puede tomar los valores `skipgram` o `cbow`, para entrenar cualquiera de las dos variantes propuestas por Mikolov. También se indican valores por defecto para cada posible hiperparámetro, por si el usuario no especifica uno.

Para los conjuntos de pruebas se indica, a través de `/enums/tests/`, los tipos de pruebas que el usuario puede elegir, junto con su nombre. Para las opciones de preprocesamiento se indica, a través de `/enums/corpus/`, las opciones que hay para elegir y los valores que éstas pueden tomar (por ejemplo, cómo realizar la tokenización de las palabras con la opción `word_tokenizer`, o si remover los tildes con la opción `remove_accents`).

De esta forma, es posible agregar nuevos modelos, pruebas, y opciones de preprocesamiento dinámicamente, sin tener que estar modificando luego el frontend. Los detalles de cómo esto se lleva a cabo se presentan en la siguiente sección.

### 4.3.3. Frontend

El principal objetivo del componente *frontend* de la herramienta es brindar a un usuario la posibilidad de utilizar de forma intuitiva todas las funcionalidades expuestas por el backend sin la exigencia adicional de poseer conocimientos detallados del funcionamiento interno de la herramienta. El frontend es el componente de la aplicación web que se ejecuta en el navegador del usuario y que funciona como interfaz entre el mismo y la API expuesta por el backend.

Además de exponer las funcionalidad de las capas inferiores de forma sencilla e intuitiva, el frontend tiene como gran objetivo ofrecer herramientas de visualización que complementen las complejas tareas de cómputo que se realizan en los demás nodos. Se busca entonces lograr una interfaz amigable y expresiva que permita la interacción con la aplicación escondiendo lo máximo posible la gran complejidad del resto del sistema.

Para el desarrollo de este componente se decidió aprovechar al máximo el rico ecosistema de herramientas de código abierto existente para el desarrollo de aplicaciones web dinámicas. Dado que la elección de las herramientas utilizadas y su combinación para lograr el producto final son actividades de valor en sí mismas, comenzaremos por listar las herramientas elegidas y los motivos que nos llevaron a hacerlo para luego describir la solución finalmente implementada.

## Herramientas

Como herramienta principal se decidió utilizar AngularJS [6], un popular framework JavaScript de código abierto mantenido por Google. AngularJS brinda importantes ventajas en comparación con otras alternativas populares como puede ser jQuery [51]. Entre sus principales características se encuentra el hecho de implementar el patrón de diseño MVC (modelo, vista, controlador) [56] el cual permite una organización de la aplicación que fomenta la reutilización de código y la separación de conceptos. Además, abstrae las operaciones de modificación del modelo de objetos del documento (DOM) del navegador, lo que simplifica el desarrollo de la aplicación.

Para lograr un estilo visual elegante y consistente de forma sencilla se decidió aprovechar el proyecto Angular Material [5]. Dicho proyecto provee una implementación de la especificación del Diseño Material de Google [67], de forma totalmente compatible con AngularJS. Dicha especificación de diseño es la que actualmente puede encontrarse en dispositivos móviles ejecutando el sistema operativo Android.

También se utilizó Yeoman [129], un generador de proyectos usualmente utilizado como andamiaje para la construcción inicial de una aplicación web. Su objetivo principal es sentar los fundamentos básicos de una aplicación tales como estructura de directorios, archivos de configuración iniciales e instalación de herramientas recomendadas.

Se decidió a su vez la adopción de una herramienta de ejecución de tareas, Grunt [42] en este caso, para simplificar y automatizar labores como minimización de código JavaScript y CSS o empaquetado de dependencias. Estas tareas ayudan reducir la cantidad y el tamaño de los archivos requeridos desde el navegador y por tanto mejoran el tiempo de respuesta de la aplicación.

Para el manejo de estilos de la aplicación se optó por utilizar Sass [103], una extensión del lenguaje de hojas de estilos CSS. Sass provee un conjunto de funcionalidades que simplifican la definición de estilos para las aplicaciones del lado de usuario. Naturalmente los navegadores no pueden interpretar hojas de estilos escritas en Sass, pero para resolver ese problema se automatizó una tarea en Grunt para realizar la traducción de Sass a CSS puro.

### Arquitectura de la aplicación

Siguiendo las pautas explicadas en la sección de diseño, se analizarán aquí las diferentes secciones que componen el frontend desde el punto de vista conceptual. De esta forma se tiene que el frontend de la herramienta se divide, nuevamente, en las cuatro secciones mencionadas en el análisis de diseño: *Dashboard*, *Corpus*, *Embeddings* y *Tests*. Por otro lado, desde el punto de vista lógico, y dado que se utiliza un framework MVC como AngularJS, la aplicación puede dividirse en tres grandes componentes: vistas, modelos y controladores.

Para el análisis de la implementación de los distintos componentes realizaremos un análisis guiado por la división conceptual, pero prestando atención a los detalles de implementación de cada uno, en particular haciendo referencia a los componentes MVC que hacen a cada sección.

[diagrama de la arquitectura de la aplicación (lógico y conceptual)]

**Dashboard** Desde el punto de vista lógico, esta sección cuenta con una sola vista principal, donde se muestra la información ya especificada de cada fuente que compone el corpus. Esta vista se implementa en el archivo `dashboard.html` en el directorio `views` de la aplicación. Para la elaboración de las gráficas se utilizó `angular-chart.js`, una colección de directivas nativas para la popular biblioteca `Chart.js` [22].

Se utilizó un sólo controlador ubicado, como todos los controladores de la

aplicación, en el directorio `scripts/controllers`. Dicho controlador, `dashboard.js`, se encarga simplemente de dibujar y mantener actualizadas las gráficas con llamadas periódicas al servidor. Para la comunicación con la API del backend se utiliza el servicio `corpus.js`, ubicado en el directorio `services`. Dicho servicio es utilizado en diferentes lugares de la aplicación y funciona como interfaz con los endpoints de Corpus ya descritos en la sección 4.3.2.

**Corpus** En la implementación de esta sección se utilizaron dos vistas. La vista principal implementada en el archivo `corpus-search.html` presenta el formulario de búsqueda y los resultados. Se tiene una vista secundaria en `document-detail.html` para presentar el cuadro de diálogo con los detalles de un documento particular.

Se utilizaron además dos controladores para la lógica de la sección. En `corpus.js` se maneja la creación de las consultas en formato JSON, el control de la tabla de resultados y la utilización de la biblioteca Ace [1] para dibujar el cuadro de texto para las consultas avanzadas. También se cuenta con el controlador `document-detail-dialog.js` que se encarga de controlar el cuadro de diálogo para los detalles de los documentos. Esta sección utiliza también el servicio `corpus.js`, que ya fue descrito en la sección anterior.

**Embeddings** Para la implementación de esta sección se utilizaron dos vistas principales. En el archivo `embeddings.html` se implementa la lista de vectores del sistema, mientras que en `embedding-detail.html` se encuentra el código de la vista en detalle para un vector en particular. Se tienen además vistas adicionales para crear un nuevo vector y para ejecutar evaluaciones en los vectores, en los archivos `embedding-new.html` y `evaluate-on-testset-dialog.html` respectivamente.

Desde el punto de vista lógico, se utiliza el controlador `embeddings.js` para dibujar la lista de vectores y actualizar el indicador de progreso para aquellos vectores que están siendo entrenados. El controlador `embedding-detail.js` es utilizado en la vista de detalles de un vector y se encarga de construir las tablas de datos y mantener actualizado el indicador de progreso de entrenamiento. Además, se encarga de realizar algunos procesos de formateo de los datos obtenidos de los servicios `services/embeddings.js` y `services/jobstesting.js`, utilizados para consumir los endpoints de vectores y casos de prueba respectivamente. También se utiliza el servicio `services/jobstraining.js` para la comunicación con los endpoints encargados de manejar el entrenamiento de

vectores.

Conviene destacar también el controlador `embedding-new-dialog.js` que se encarga de presentar los datos para la creación de un nuevo vector de forma eficiente y mutando los parámetros presentados en función del algoritmo de entrenamiento seleccionado. Este controlador y su vista acompañante pueden ser invocados desde la vista de resultados de consultas al corpus, como ya se explico en la sección anterior.

**Tests** Como en el caso de la sección *Embeddings*, para la implementación de esta sección también se utilizaron dos vistas principales. La vista con la lista de casos de prueba del sistema fue implementada en el archivo `tests.html`. La implementación de la vista de detalles de un caso de prueba se incluye en el archivo `test-detail.html`. Para las demás funcionalidades se utilizaron vistas auxiliares. La creación de nuevos casos de prueba y nuevos trabajos de evaluación fueron implementadas utilizando sendos cuadros de diálogo implementados en `test-new.html` y `test-embedding-new.html`, respectivamente. Finalmente, la vista en detalle de los resultados de una evaluación sobre un vector fue implementada con otro cuadro de diálogo en `test-result-dialog.html`.

Para la lógica de esta sección se utilizaron varios controladores. En la vista de listado de casos de prueba se utilizó el controlador `tests.js`, encargado mayoritariamente de dibujar la lista y actualizar el progreso de ejecución de los trabajos de evaluación. Para la vista de detalles se implementó el controlador `test-detail.js`, responsable de dibujar las tablas de datos, mantener actualizadas las barras de progreso de evaluación y llevar la cuenta de la cantidad de trabajos ejecutándose en cada momento. Adicionalmente, el controlador `test-new-dialog.js` fue utilizado para manejar la creación de nuevos casos de prueba. Finalmente los controladores `test-result-dialog.js` y `new-embedding-test-dialog.js` fueron utilizados para desplegar la información detallada de la ejecución de un caso de prueba en un vector y la creación de nuevos trabajos de entrenamiento, respectivamente.

Los servicios más importantes para esta sección son `testsets.js` para realizar operaciones CRUD (crear, recuperar, actualizar y destruir) sobre los casos de prueba, `results.js` para consultar los resultados de la evaluación de vectores y `jobtesting.js`, para la creación de nuevos trabajos de evaluación en el sistema.

### Consideraciones de diseño

Una vez terminado el análisis de la arquitectura del frontend, es interesante mencionar ciertos objetivos y decisiones que guiaron la construcción del mismo. Se incluye a continuación una lista de puntos que fueron tomados en cuenta al momento de construir la solución.

- Desde su concepción se buscó que el frontend sea altamente flexible ante cambios en la API expuesta por el backend. Es decir, se buscó parametrizar la vistas más complejas de modo de soportar cambios en la cantidad o formato de ciertos campos con el mínimo impacto en el código del frontend. Como ejemplo se tiene la vista de creación de nuevos vectores. La API define un formato específico y flexible para los parámetros de entrenamiento de un nuevo vector en función del algoritmo de entrenamiento elegido. De esta forma se pueden agregar nuevas clases de algoritmos en el backend y estos estarán disponibles en el frontend sin requerir modificaciones adicionales.
- Se buscó también lograr una interfaz sencilla e intuitiva. Fue por este motivo que se decidió utilizar el Diseño Material de Google al ser una tecnología ampliamente probada y aceptada. Principalmente se logró presentar la información y funcionalidades de forma directa y clara pero manteniendo un estilo consistente y elegante en todas las pantallas.
- Se consideró como prioritario construir una interfaz rápida y eficiente que aproveche al máximo las ventajas de los navegadores modernos. A pesar de que este proyecto no tiene como objetivo probar técnicas de diseño y programación para la web, buscamos en todo momento lograr un desarrollo de calidad que utilice las bondades y excelentes avances de las herramientas para la creación de aplicaciones web modernas.
- Finalmente se puso como objetivo lograr un diseño desacoplado para la interacción de los componentes backend y frontend de la herramienta. Esto se consiguió utilizando la API REST expuesta como único punto de intercambio entre ambas componentes. Entre otras ventajas, esto permite eventualmente poner en producción cada componente en nodos separados.





# Capítulo 5

## Evaluación

Contando ya con la herramienta y el corpus de texto en español, se procede a construir representaciones vectoriales empleando los principales algoritmos en el área y a evaluar su comportamiento en el idioma español. Con el fin de tener valores de referencia con los cuales comparar los modelos entrenados, se traducen del inglés al español los conjuntos de pruebas más utilizados en la literatura.

El capítulo comienza detallando el proceso de entrenamiento, enumerando cuáles son los modelos vectoriales entrenados y qué hiperparámetros estos utilizan. Luego se expone la comparación de dichos modelos con los resultados obtenidos para el inglés, presentando cuáles son los principales conjuntos de pruebas empleados. También se realiza un estudio sobre la performance de los modelos frente a pruebas diseñadas para evaluar particularidades del idioma español. Por último, se realiza un análisis cualitativo de las representaciones, mostrando algunos ejemplos de su comportamiento de manera más informal pero ilustrativa.

### 5.1. Modelos Entrenados

Como se mencionó anteriormente, se optó por entrenar representaciones vectoriales siguiendo los tres principales enfoques de la literatura: modelos neuronales a través del algoritmo `word2vec`, modelos estadísticos mediante

el empleo de una matriz PPMI con SVD, y modelos híbridos mediante el algoritmo GloVe. El primero y el último utilizaron implementaciones ya existentes (Gensim y la provista por los autores, respectivamente), mientras que el segundo fue una implementación propia siguiendo los lineamientos de [60].

Cada uno de estos modelos tiene distintos hiperparámetros que pueden afectar significativamente su performance. En [60] los autores buscan unificar los hiperparámetros de estos modelos, proponiendo un subconjunto de los mismos que contempla las tres variantes. El enfoque tomado en este proyecto no llega a tal profundidad, pues quita parte de la versatilidad de algunos algoritmos, pero intenta aún así presentarlos de manera unificada cuando es posible.

En el caso de `word2vec`, los hiperparámetros disponibles para modificar son:

- **Dimensión** (`dim`): dimensión de las representaciones inducidas (valor por defecto: 300).
- **Cantidad de ocurrencias mínima** (`min_count`): cantidad mínima de ocurrencias que una palabra debe tener para ser considerada parte del vocabulario (valor por defecto: 5). En caso de no llegar a dicho límite, se excluye del corpus como si no estuviera presente.
- **Ventana de contexto** (`win`): tamaño de la ventana de contexto utilizada hacia cada lado de la palabra central (valor por defecto: 5). Notar que no se estudian variantes con contextos asimétricos o con otras características.
- **Subsampling** (`sub`): qué nivel de *subsampling* realizar a las palabras muy frecuentes, para evitar que sean sobrerrepresentadas en los vectores finales (valor por defecto: 0.00001). Hacer subsampling de una palabra implica removerla de una oración con una probabilidad  $p^1$ .
- **Algoritmo empleado** (`algo`): qué algoritmo de `word2vec` utilizar, Skip-gram (`sg`) o CBOW (`cbow`) (valor por defecto: `sg`). Como fue mencionado en el capítulo 2, el primero busca predecir la palabra central en base a su contexto y el segundo lo opuesto.

---

<sup>1</sup>Se realiza subsampling si  $\text{sub} \times |V| > \#w$ , donde  $|V|$  es el tamaño del vocabulario y  $\#w$  la cantidad de ocurrencias de la palabra  $w \in V$ . En ese caso, el subsampling se realiza con una probabilidad  $p = 1 - \sqrt{\frac{\text{sub}}{\#w}}$ , siguiendo la sugerencia de [60].

- **Variante utilizada** (`var`): si construir y utilizar un softmax jerárquico para la estimación de la probabilidad (`hs`) o si emplear la técnica de *negative sampling* (`ns`) (valor por defecto: `ns`).
- **Cantidad de muestras negativas** (`neg`): en caso de utilizar *negative sampling*, la cantidad de muestras negativas a tomar por cada ejemplo positivo (valor por defecto: 7).
- **Ritmo de aprendizaje** (`alpha`): ritmo de aprendizaje a utilizar en el empleo del descenso estocástico por el gradiente (SGD) mediante el cuál se aproximan las probabilidades (valor por defecto: 0,025). Un mayor valor para este parámetro corre el riesgo de que SGD no converja, mientras que un menor valor puede hacer que se requieran de múltiples recorridas sobre el corpus para obtener resultados aceptables. De todos modos, este valor es el ritmo inicial, e irá disminuyendo conforme avance el entrenamiento para ayudar a la convergencia.
- **Recorridas sobre el corpus** (`epoch`): cantidad de veces que se recorre el corpus de texto (valor por defecto: 1). Recorrer un mayor número de veces el corpus de entrenamiento mejora la convergencia del algoritmo pero, obviamente, hará que aumente el tiempo de entrenamiento drásticamente.

El modelo GloVe presenta mucho de los mismos hiperparámetros (en particular, `dim`, `min_count`, `win`, `alpha`, y `epoch`), con algunos hiperparámetros adicionales:

- **Tamaño máximo del vocabulario** (`max_count`): cantidad máxima de palabras que puede contener el vocabulario donde, en caso de alcanzarse, se utilizan únicamente las `max_count` palabras más frecuentes (valor por defecto: *sin máximo*).
- **Cota de la función de peso** (`x_max`): cota superior a utilizar para la métrica de asociación entre los pares de las palabras en la matriz de coocurrencia intermedia (valor por defecto: 100). Si la métrica asume valores superiores a 100, se toma el valor 100 en su lugar.
- **Exponente para la función de peso** (`eta`): exponente a utilizar en la función de peso, tal como es definido en [89] (valor por defecto: 0,75). Tanto este parámetro como el anterior fueron dejados en sus valores por defecto en todos los modelos generados, puesto que son muy particulares al algoritmo y su estudio escapa el alcance del proyecto. De todos modos, como

comentan los propios autores, su valor no debería ser determinante en la performance de las representaciones resultantes.

Cabe notar, sin embargo, que el hiperparámetro `epoch` tiene una importancia mayor en este algoritmo, pues no implica una recorrida por todo el corpus sino por la matriz de coocurrencias intermedia que se genera (en particular, por el vocabulario empleado). `epoch` en este contexto indica la cantidad de iteraciones empleada en la generación de la matriz reducida, y debe ser un número alto para asegurar una correcta factorización. El valor por defecto es 15, aunque los autores sugieren utilizar entre 50 y 100 iteraciones.

Por último, el modelo PPMI con SVD tiene también algunos hiperparámetros adicionales (`dim`, `min_count`, `max_count`, `win`, `sub`) con la incorporación de dos adicionales:

- **Suavizado de la distribución del contexto** (`cds`): suavizado empleado para las coocurrencias de las palabras en la construcción de la matriz de coocurrencia, tal como es detallado en [60] (valor por defecto: 0,75). Este parámetro disminuye el sesgo natural que la medida PMI tiene con las palabras raras, e incrementa consistentemente la performance sobre la opción sin suavizado (valor 1,0). Por esta razón, en los modelos entrenados siempre se utilizó el valor por defecto.
- **Suma de vectores de contexto** (`w+c`): luego de aplicar SVD a la matriz de coocurrencias, se obtiene una matriz que asocia las palabras del vocabulario al espacio reducido y otra que asocia las palabras de los contextos al mismo espacio (valor por defecto: `true`). En [60], los autores proponen utilizar la suma de ambos vectores en lugar de únicamente los vectores base, obteniendo en algunos casos mejores resultados.

Este último modelo tal como es planteado por los autores cuenta con algunos hiperparámetros adicionales, como la normalización de los vectores resultantes y la variante de [20] en SVD. Sin embargo, puesto que los resultados a los que llegan los autores sistemáticamente favorecen a una variante particular, se optó por dejarlos fijos.

Por otro lado, también se cuenta con hiperparámetros para el preprocesamiento del corpus de texto previo a ser alimentado a los algoritmos. En particular, se tienen dos opciones: **remover tildes** (`acc`), que remueve todo tipo

de tildes del texto previo al entrenamiento, y **pasar a minúsculas** (`lower`), que pasa todo el texto a minúsculas, no haciendo distinción entre *Papa* y *papa*.

También está la posibilidad de evaluar distintos mecanismos para la tokenización de oraciones y palabras, pero se decidió limitar el estudio a los dos anteriores. En el caso de la tokenización de palabras, se partió las oraciones en secuencias de caracteres alfanuméricos, descartando todo tipo de símbolo distinto.

La gran cantidad de hiperparámetros disponibles para cada algoritmo deja un espacio de búsqueda extremadamente grande, que no es posible explorar por completo. Por este motivo se construyó sobre el trabajo previo en la literatura, utilizando los valores de parámetros que mejores resultados han obtenido y explorando en la proximidad de cada uno.

Procediendo de este modo, es posible obtener una mejor visión de cómo funcionan los distintos algoritmos en su versión equivalente en español, replicando los comportamientos obtenidos en inglés. Además, probando alternativas de los hiperparámetros no necesariamente estudiadas en la literatura, se evita que se escapen variantes particulares o prometedoras.

Los valores por defecto de cada hiperparámetro son los que mejores resultados han obtenido en la literatura, buscando que si se deja sin fijar uno de ellos, el modelo resultante sea aún así razonablemente bueno. En el caso de `word2vec`, el modelo arquetípico utiliza la variante Skipgram con negative sampling (utilizando 7 muestras negativas); establece una dimensión resultante de 300, y una ventana de contexto de ancho 5; un subsampling de  $1 \times 10^{-5}$ , 5 ocurrencias mínimas de una palabra para entrar al vocabulario y una única recorrida del corpus.

Para `GloVe` se parte de valores similares: 300 componentes en los vectores resultantes, al menos 5 ocurrencias para ingresar al vocabulario, y una ventana de tamaño 5. No se limita el tamaño máximo del vocabulario y, como se mencionó anteriormente, se utilizan los valores propuestos por los autores del algoritmo para la cota y el exponente de la función de peso. Por último, se realizan 15 recorridas por la matriz de coocurrencias.

El modelo estadístico se basa también en los valores de hiperparámetros de los otros dos algoritmos. Para el suavizado de la distribución de contexto se utiliza, como se explicó antes, un valor de 0,75 (y no se varió en ningún modelo),

mientras que se realiza la suma de vectores de contexto.

Algunos de estos hiperparámetros, como la dimensión de los vectores resultantes o el tamaño de la ventana, dependen del tamaño del corpus que se utilice para entrenarlos, donde a mayores valores funcionarán bien con más datos. De todos modos, los valores elegidos para éstos son razonables para los volúmenes de texto que se manejan.

Por otro lado, hay hiperparámetros cuyos valores dependen de otros, como la cantidad de muestras negativas en `word2vec` (que no aplica cuando se utiliza un softmax jerárquico). Otro ejemplo son las limitantes al tamaño del vocabulario, donde `max_count`, `min_count`, e incluso la dimensión y el tamaño de la ventana de contexto son utilizadas en conjunto para acotar los requerimientos computacionales de correr los algoritmos.

Relacionado a este último punto, la cantidad de recorridas sobre el corpus en `word2vec` o de la matriz de coocurrencias en `GloVe` tienen una influencia directa en el tiempo de cómputo del que se disponga. Para este tipo de hiperparámetros, se tomaron valores que permitan entrenar adecuadamente los modelos en el servidor del que se disponía, buscando mantener el tiempo de entrenamiento para la mayoría de los vectores por debajo de un día.

Sobre estos valores base se entrenan a su vez alternativas, comparando los resultados al variar hiperparámetros particulares, donde se mantiene el resto de los valores fijos. De esta forma se busca estudiar la influencia que tiene, por ejemplo, la dimensión de los vectores o la cantidad de recorridas por el corpus en la performance de las representaciones vectoriales.

En cuanto al corpus de entrenamiento empleado, se entrenaron dos grandes grupos de modelos vectoriales: uno con un corpus de 4000 millones de palabras de todas las fuentes (con la excepción del texto de baja calidad obtenido de los foros) y otro de 400 millones de palabras entrenado exclusivamente con noticias de Uruguay, ambos con los tildes removidos. Se toman estas dos variantes con el objetivo de estudiar cómo afecta el tamaño del corpus en la calidad de los vectores resultantes. Estos grupos de modelos entrenados con texto genérico, a su vez, buscan ser comparables con las representaciones que se entrenan en la literatura, los cuales utilizan corpus de texto que tratan de no influir a los vectores de ninguna manera particular.

Además de estos dos conjuntos se entrenaron modelos adicionales con datos

exclusivamente de España (con alrededor de 400 millones de palabras), con datos provenientes tanto de noticias como de foros, con los datos anteriores pero sin los tildes removidos, y con la totalidad del corpus obtenido finalmente (6000 millones de palabras). Estas variantes se pensaron con el fin de estudiar cómo difiere el comportamiento de los vectores según el texto con el que se alimenta.

En el cuadro 5.1 se listan las variantes de corpus utilizados más relevantes, junto con un código para identificarlos fácilmente. Por otra parte, en el cuadro 5.2 se presenta una lista de los modelos vectoriales construidos más importantes y de mejor desempeño, especificando los hiperparámetros empleados para cada uno y el corpus utilizado en su entrenamiento.

Corpus			
Id	Descripción	Palabras	Preprocesado
C01	Todos los documentos anteriores al 03/11/2015	4,071,127,366	Minúsculas, con tildes
C02	Todos los documentos anteriores al 03/11/2015	4,081,771,827	Minúsculas, sin tildes
C03	Todos los documentos de Uruguay anteriores al 11/10/2015	475,785,121	Minúsculas, sin tildes
C04	Todos los documentos de <i>gxzone.com</i> y <i>lanacion.com.ar</i>	785,446,039	Minúsculas, sin tildes

Cuadro 5.1: Detalle de los subconjuntos del corpus utilizados.

El entrenamiento de los modelos vectoriales fue realizado a través de la herramienta construida y detallada en el capítulo 4. Los hiperparámetros a evaluar se fijaron a priori, dando de alta los *embeddings* en la interfaz web y mandando posteriormente a entrenar cada uno de ellos.

Como se puede apreciar en el cuadro 5.2, destacamos especialmente once representaciones vectoriales: cinco utilizando *word2vec*, tres utilizando *GloVe*, y tres utilizando *PPMI*. El tiempo de entrenamiento promedio de cada modelo fue de un día y catorce horas, donde el más rápido tomó poco más de una hora (W04) y el más lento tres días y diez horas (W01). Existe una diferencia significativa entre el tiempo empleado en ambos extremos, lo que resalta la importancia de la limitante que impone la capacidad de cómputo disponible al entrenamien-



word2vec									
Id	Algoritmo	Dim	Ven	$\alpha$	HS	NS	Epochs	Corpus	
W01	skipgram	300	7	0.025	No	7	5	C01	
W02 <sup>2</sup>	skipgram	300	7	0.025	No	7	5	C02	
W03	skipgram	500	7	0.025	No	7	1	C02	
W04	skipgram	300	7	0.025	No	7	1	C03	
W05	skipgram	200	7	0.025	No	7	5	C04	
GloVe									
Id	Dimensiones		Ventana	$\alpha$	Epochs		Corpus		
G01	300		7	0.75	50		C02		
G02	300		7	0.75	200		C02		
G03	300		7	0.75	15		C02		
PPMI/SVD									
Id	Dimensiones		Ventana	Suavizado	Contexto		Corpus		
S01	500		2	0.75	Sí		C01		
S02	500		2	0.75	Sí		C02		
S03	300		5	0.75	No		C03		

Cuadro 5.2: Detalle de los modelos vectoriales.

to de vectores. En total, se invirtieron *diecisiete días y doce horas* entrenando los modelos vectoriales aquí analizados.

Cada modelo vectorial ocupa entre 300MB y 1000MB (con algunos llegando a 1700MB), dependiendo principalmente de la dimensión elegida y los límites que se le establezcan al vocabulario (cantidad mínima de ocurrencias, o directamente el tamaño máximo del vocabulario). Esto no genera grandes presiones en el almacenamiento, aunque aún así no es un tema menor a la hora de descargar los modelos o de cargarlos en memoria, pues se tiene un tiempo de arranque no despreciable.

## 5.2. Comparación con la Literatura

Uno de los principales objetivos del proceso de evaluación es comparar la calidad de las representaciones vectoriales generadas con texto en español con las generadas con texto en inglés. Puesto que todos los conjuntos de pruebas son inherentemente dependientes al idioma de los vectores, no es posible realizar una comparación perfecta, en especial debido a la fuerte dependencia que tiene la calidad de los vectores con el corpus de entrenamiento empleado.

De todos modos, y para tener al menos un punto de comparación inicial entre ambos idiomas, se optó por tomar los principales conjuntos de pruebas utilizados en la literatura inglesa y traducirlos al idioma español, adaptando las pruebas cuando fuera necesario (por ejemplo, cuando se evalúan cualidades sintácticas no existentes en español). Así, es posible obtener una referencia aproximada de qué tanto se acercan los modelos entrenados a los obtenidos por la comunidad.

Se emplean dos tipos de pruebas para realizar la comparación: pruebas basadas en analogías y pruebas basadas en similitud de palabras. Como ya fue mencionado en capítulos anteriores, la primera busca recuperar una palabra en base a otras tres palabras dadas, mientras la segunda busca asignar un puntaje de similitud entre pares de palabras.

Para las analogías existen dos conjuntos de pruebas muy utilizados por la comunidad: el conjunto de analogías de Microsoft (MSR), compuesto exclusivamente por analogías que buscan regularidades sintácticas en los vectores, y el conjunto de Google [80], compuesto tanto por analogías sintácticas como semánticas. De estos dos, se optó por utilizar únicamente el de Google, pues el MSR tiene demasiadas pruebas sintácticas específicas al inglés (como posesivos, comparativos, y superlativos) que deben ser descartadas en el proceso de traducción, haciendo que el conjunto resultante sea tan distinto que una comparación de los resultados sería insustancial.

Debido a la antigüedad del campo, existe una gran cantidad de conjuntos de pruebas para la tarea de similitud de palabras, en especial en lo que respecta a la evaluación de modelos estadísticos. Se decidió, para limitar la cantidad de conjuntos a un número razonable, elegir las pruebas más recientemente utilizados por la literatura, con el fin de tener comparaciones más fiables. En particular, se toman los conjuntos empleados por [60], pues son evaluados con los tres tipos de modelos empleados en el proyecto. Estos conjuntos son:

- WordSim [37], un conjunto compuesto por 353 pares de palabras puntuados en base a la relación entre ambas palabras (si los jueces humanos consideran que las palabras están relacionadas de alguna manera cualquiera) y su similitud (si existe una relación más fuerte entre los pares, ya sea sinonimia, hiponimia, etc.). Se utiliza el conjunto partido entre los pares que miden relación y los que miden similitud, como se hace en [60].
- MEN [16], compuesto por 3000 pares de palabras elegidas al azar entre las palabras que aparecen al menos 700 veces en el corpus WaCky [9]. Los autores utilizaron la plataforma Mechanical Turk [68] para la construcción del conjunto, y el puntaje se asigna en base a comparaciones binarias entre entradas del conjunto.
- El conjunto MTurk [98], compuesto de 287 pares de palabras, con puntajes también asignados a partir de la herramienta Mechanical Turk.
- SimLex [45], compuesto de 999 pares puntuados exclusivamente en base a la similitud entre las palabras. Esto implica que pares como *ropa* y *ropero* tienen asignado un puntaje bajo, por no ser estrictamente similares. Este conjunto es particularmente complicado de resolver por parte de los modelos vectoriales, pues éstos aprenden en base a la coocurrencia de pares y la coocurrencia refleja principalmente la relación que existe entre las palabras.

Por otro lado, se descarta el conjunto de palabras raras propuesto por [65] debido a que la sutileza entre los pares de palabras empleados se perdería en el proceso de traducción.

Los cinco conjuntos de pruebas seleccionados para realizar la comparación debieron ser traducidos manualmente, pues no fue posible encontrar traducciones satisfactorias de los mismos.

Se construyó un script que aprovecha el servicio de Google Translate [40] para realizar una traducción semi-automática de las pruebas. Este script lee una lista de palabras de entrada, realiza un pedido HTTP al servicio y obtiene la primera traducción sugerida. Esta palabra se toma posteriormente como una sugerencia que es revisada manualmente, pero que no obstante ayuda a agilizar la tarea.

El proceso de traducción para cada conjunto contó, pues, de cuatro etapas: en primer lugar, se corrió el script para la lista de palabras del conjunto; luego

se recorrió la lista de palabras traducidas, comparándolas con las versiones en inglés y se corrigieron o eliminan las traducciones incorrectas, ya sea por estar mal la traducción en sí o porque no era el sentido que esperaba en la prueba; en tercer lugar, se sustituyen las traducciones por las palabras originales en los conjuntos de prueba, eliminando la entrada si no se encuentra la traducción; por último, se recorre la lista pruebas buscando posibles errores y eliminando o corrigiendo entradas adicionales.

El proceso de traducción, sin embargo, es falible, por lo que es de esperar que existan traducciones incorrectas en los conjuntos de pruebas, aunque la proporción no sea alta. Puesto que algunos conjuntos de pruebas llegan a tener más de diez mil líneas, la revisión final fue más bien superficial.

En el caso de las tareas de similitud de palabra, donde se encuentra frecuentemente diferencias finas en el significado de los pares de palabras, se buscó que las traducciones siguieran la intención de los autores. Por ejemplo, mientras que Google Translate sugería la traducción *costa* tanto para *shore* como para *coast*, se tomó la decisión de traducir *shore* como *orilla*, que es una palabra también válida pero que se ajusta al puntaje que el par tenía asociado. Esto indudablemente está sesgando el conjunto de pruebas, pero es la única alternativa para realizar una comparación, fuera de construir los conjuntos de nuevo como hicieron los autores originales.

En el conjunto de analogías de Google fue necesario eliminar por completo algunas secciones por no ser pertinentes al idioma español. En particular, se eliminaron las categorías *gram3-comparative* y *gram4-superlative*, que tienen analogías entre adjetivos y sus comparativos o sus superlativos (e.g. *great*, *greater*, y *greatest*), pues no tienen traducciones al español de una única palabra. También se decidió eliminar la sección *city-in-state*, que tiene analogías de ciudades y estados de EE.UU., pues nuestro corpus de texto se basa en fuentes hispanas y no tendrá muchas menciones de las mismas.

En la tabla 5.3 se resumen los conjuntos de pruebas empleados para la evaluación, junto con la cantidad de entradas originales y resultantes de cada uno. Como se puede apreciar, las pruebas resultantes tienen un promedio de 92 % de las entradas originales, con algunos conjuntos más afectados que otros.

La tabla 5.4 muestra los resultados obtenidos para los mejores dos mode-

Conjunto de pruebas	Entradas originales	Entradas luego de la traducción	Porcentaje luego de la traducción
Google	19.544	13.906	71 %
WordSim	455	440	97 %
MEN	3.000	2.902	97 %
MTurk	287	282	98 %
SimLex	999	991	99 %

Cuadro 5.3: Comparación entre conjuntos de pruebas antes y después de ser traducidos.

los vectoriales de cada algoritmo. También se presentan, como punto inicial de comparación, los resultados obtenidos en la literatura.

Modelo	Google	WordSim Related	WordSim Similarity	MEN	MTurk	SimLex
W01	<b>63 %</b>	55 %	73 %	69 %	<b>57 %</b>	26 %
W02	60 %	50 %	70 %	66 %	55 %	24 %
W04	31 %	50 %	55 %	48 %	52 %	24 %
G01	57 %	48 %	64 %	67 %	52 %	29 %
G02	57 %	49 %	67 %	67 %	53 %	29 %
S01	45 %	56 %	<b>74 %</b>	<b>72 %</b>	52 %	33 %
S02	46 %	<b>57 %</b>	73 %	<b>72 %</b>	51 %	<b>34 %</b>

Cuadro 5.4: Desempeño de los principales modelos en los conjuntos de prueba.

El primer punto a observar es que los resultados obtenidos por nuestros vectores son muy similares a los obtenidos en inglés, particularmente en las tareas de analogías: los resultados de estado del arte varían entre una exactitud de 0,61 y 0,69 [60, 10, 89, 76], mientras que los vectores en español (particularmente, el modelo W01), obtiene 0,63.

Parte de esta diferencia puede explicarse por el hecho de que las secciones

que se remueven del conjunto de pruebas (comparativos, superlativos, y ciudad en estado) son entradas que obtienen por lo general buenos resultados. Este fenómeno puede observarse en [58], donde los autores presentan los resultados desglosados por sección. Allí, el conjunto de comparativos, por ejemplo, obtiene una exactitud de 0,86.

En el cuadro 5.5 se muestran los valores obtenidos separados por sección del conjunto de analogías, junto a los valores obtenidos por [58]. Es interesante ver que el comportamiento del mejor modelo es relativamente similar al inglés, incluso con las pruebas sintácticas donde ambos idiomas, provenientes de familias de lenguajes distintos, varían significativamente.

Por ejemplo, las secciones que peor performance obtienen son las mismas en ambos idiomas: Países y monedas (*currency*), Adjetivos y adverbios (*gram1-adjective-to-adverb*), Opuestos (*gram2-opposite*), todas muy debajo del promedio. Por otro lado, también se repiten las que mejor funcionan: Países y capitales más comunes (*capital-common-countries*), Países y nacionalidades (*gram6-nationality-adjective*), Verbos y plurales (*gram9-plural-verbs*), donde hay tanto categorías sintácticas como semánticas.

Analogía	W01	W02	W04	G01	G02	S01	S02	Levy
Adjetivos y adverbios	22 %	<b>26 %</b>	10 %	14 %	14 %	16 %	16 %	24 %
Países y capitales (más comunes)	<b>97 %</b>	93 %	69 %	91 %	92 %	89 %	87 %	91 %
Países y capitales (general)	<b>72 %</b>	71 %	23 %	<b>72 %</b>	71 %	59 %	62 %	78 %
Países y monedas	<b>6 %</b>	5 %	0 %	2 %	2 %	2 %	2 %	15 %
Miembros de la familia	<b>76 %</b>	67 %	31 %	72 %	73 %	68 %	54 %	76 %
Verbos en infinitivo y gerundios	<b>74 %</b>	72 %	51 %	64 %	64 %	59 %	60 %	63 %
Verbos en pasado y gerundios	<b>54 %</b>	30 %	13 %	25 %	26 %	20 %	15 %	66 %
Países y nacionalidades	89 %	90 %	68 %	<b>91 %</b>	<b>91 %</b>	75 %	77 %	89 %
Sustantivos y plurales	55 %	<b>61 %</b>	24 %	44 %	45 %	16 %	18 %	72 %
Verbos y plurales	82 %	<b>83 %</b>	64 %	76 %	76 %	44 %	43 %	71 %
Opuestos	<b>19 %</b>	18 %	7 %	18 %	<b>19 %</b>	<b>19 %</b>	18 %	37 %

Cuadro 5.5: Desempeño de los principales modelos en las pruebas de analogías.

El modelo vectorial vectorial que más éxito obtiene en analogías es W01, el

cual utiliza el algoritmo `word2vec` con Skipgram y *negative sampling*, seguido de un modelo GloVe y finalmente por un modelo PPMI/SVD. Esto sigue lo observado por los autores en [60], aunque en ese caso la diferencia entre el modelo híbrido y el estadístico es mucho menor.

De todos modos, en el conjunto de pruebas MSR (el cual cuenta con analogías exclusivamente sintácticas) los autores sí tienen una diferencia amplia entre ambos algoritmos, lo que puede explicar este fenómeno; en especial si se nota que la mayor diferencia de aciertos en los vectores en español se da en las secciones Sustantivos y plurales (*gram8-plural-nouns*) y Verbos y plurales (*gram9-plural-verbs*): en pruebas sintácticas. La diferencia en el conjunto de Google en particular podría explicarse por la extracción de secciones durante el proceso de traducción.

Curiosamente, el comportamiento en el caso de similitud de palabras es opuesto: salvo por el conjunto de pruebas MTurk [98], PPMI/SVD es consistentemente superior a las alternativas, con los modelos GloVe y `word2vec` seguidos con resultados muy parecidos. Esto también es similar al comportamiento obtenido en [60].

Algo que cabe resaltar, sin embargo, es que la diferencia entre los resultados en inglés y español es mayor que para el caso de las analogías: mientras que las analogías obtenían aproximadamente un 5 % de diferencia relativa en los resultados, estas pruebas llegan hasta un 25 % de diferencia (en el conjunto SimLex, por ejemplo).

Esto último se puede explicar, en parte, porque los conjuntos de similitud de palabras son más difíciles de traducir: el puntaje asignado es una noción muy intuitiva a la persona que los asigna, algo que difícilmente se traslade de un par de palabras en inglés a su traducción en español. El hecho de que el conjunto WordSim (entradas de similitud) y MEN obtengan resultados que van más acorde al estado del arte, con aproximadamente un 5 % de diferencia relativa, podría explicarse porque tienen entradas que resisten más el proceso de traducción (con menos sutilezas del significado de las palabras).

Para obtener resultados equivalentes, sería necesario seguir un proceso similar a los creadores de los conjuntos y buscar asignar puntajes a los traducciones de las palabras (así, por lo menos, es equivalente el conjunto).

Vale la pena repetir que, como muestran los autores en [60], la calidad de

los vectores resultantes está fuertemente ligada a la composición del corpus con que se entrenan, por lo que las medidas presentadas de vectores en inglés, entrenados por otros autores, con otras implementaciones, y otros corpus, deben limitarse a ser solamente una referencia. Esto es particularmente cierto en el escenario actual por el hecho de estar además traduciendo los conjuntos de pruebas mediante un proceso de traducción que, como ya se mencionó anteriormente, no está ni cerca de ser perfecto.

Otro punto interesante a comentar es que se logran reproducir los resultados obtenidos por los autores en [58], donde se propone la medida 3COSMUL para la recuperación de analogías. En todas las pruebas realizadas, esta medida obtiene resultados consistentemente superiores a 3COSADD.

Una cuestión que no ha sido estudiado en profundidad en la literatura es, en los casos donde la recuperación de la analogía falla, qué tan cerca se queda la respuesta. Con este objetivo se calcula, además del porcentaje de aciertos en la primer posición (esto es, la palabra que maximiza 3COSMUL), el porcentaje de entradas para las cuales la respuesta está entre las cinco o diez palabras con mejor puntaje. En la tabla 5.6 se presenta esta información para el mejor modelo de antes (W01):

Analogía	Top 1	Top 5	Top 10
Adjetivos y adverbios	22 %	41 %	48 %
Países y capitales (más comunes)	97 %	100 %	100 %
Países y capitales (general)	72 %	86 %	89 %
Países y monedas	6 %	11 %	13 %
Miembros de la familia	76 %	93 %	98 %
Verbos en infinitivo y gerundios	74 %	87 %	89 %
Verbos en pasado y gerundios	54 %	78 %	82 %
Países y nacionalidades	89 %	96 %	97 %
Sustantivos y plurales	55 %	69 %	73 %
Verbos y plurales	82 %	90 %	92 %
Opuestos	19 %	30 %	35 %

Cuadro 5.6: Desempeño del modelo W01 en las posiciones del top 1, top 5 y top 10

Es interesante ver que los valores mejoran significativamente al considerar el top 5 y el top 10: para el mejor modelo vectorial, se pasa de un 0,63 a un 0,76 en el



top 5 y un 0,79 en el top 10. Esto podría sugerir que con más cantidad de texto o con una mejor forma de recuperar analogías se podrían obtener resultados aún mejores, porque los modelos cuentan con la información y no están tan alejados de las respuestas correctas como parecería a priori: la sección de adjetivos y adverbios (`gram1-adjective-to-adverb`), por ejemplo, pasa de un 0,22 a un 0,48, la mayor mejora de todas las categorías.

Por último, es llamativo ver que, en contradicción a nuestra primera intuición, eliminar los tildes tiene un efecto negativo sobre los resultados del corpus: en todos los casos donde se entrenaron modelos con los mismos hiperparámetros salvo por la eliminación de los tildes, la versión que los mantenía obtuvo mejores resultados en la mayoría de las pruebas.

Es posible que este fenómeno se dé por la dificultad que tienen estos algoritmos de distinguir palabras polisémicas. Cuando una palabra puede tener más de un significado, el vector resultante asociado será una mezcla de los vectores de cada uno de los sentidos de la palabra si se intercambiaran por un *token* propio<sup>3</sup>.

Esto es, de hecho, lo que hacen los autores en [48, 114], donde construyen tokens de la forma *palabra.1*, *palabra.2* para los significados 1 y 2. Así, incluir los tildes de las palabras ayuda a distinguir entre las diferentes acepciones de las palabras, bajo la suposición de que la cantidad de faltas de ortografía en el corpus de entrenamiento no es demasiado elevada.

En la literatura existen también comparaciones de los algoritmos aquí presentados en distintos idiomas, aunque con un nivel de profundidad menor. En [12], los autores realizan una comparación de `word2vec` y `GloVe` con vectores entrenados en italiano con un corpus compuesto de la Wikipedia (alrededor de 300 millones de palabras) y libros (alrededor de 2200 millones de palabras) en dicho idioma, realizando también una traducción de las analogías de Google similar a la hecha en este proyecto. Consiguen, sin embargo, resultados significativamente inferiores a los aquí presentados: entrenando con Wikipedia obtienen un acierto de 0,40, mientras que agregando libros 0,47.

Los autores también corren las pruebas con Polyglot [100], que son un conjunto de modelos vectoriales en múltiples idiomas propuestos por sus autores

---

<sup>3</sup>Esta mezcla, además, estará sesgada en base a qué uso de la palabra es más frecuente: cuando uno es mucho más usado que otro, se corre el riesgo de *diluir* uno de los significados en el otro

como línea de base para distintos experimentos, entrenados con las Wikipedias de cada lenguaje. Consiguen, sin embargo, una exactitud en la recuperación de tan solo 0,04, por lo que se decidió ni evaluar los vectores en español.

En español se cuenta con los vectores presentados en [19], donde el autor obtiene resultados levemente inferiores a los nuestros con el conjunto de pruebas de Google traducido por él<sup>4</sup>. No hay, sin embargo, una publicación adjunta que describa el proceso de evaluación, por lo que se desconoce el detalle de las pruebas realizadas.

### 5.3. Comportamiento Específico al Español

Teniendo un punto de comparación de la performance de los modelos vectoriales en ambos idiomas, se procedió a realizar un estudio más detallado de su comportamiento en español, con el objetivo siendo obtener una mejor visión de qué tanta información son capaces de capturar los vectores en un idioma con mayor complejidad gramatical, investigando cuáles son las características que resultan más difíciles de representar.

Con este fin, se armaron conjuntos de pruebas que exponen cualidades del español, como conjugaciones verbales, géneros de sustantivos, y más. Son conjuntos de prueba contruidos para el presente proyecto, por lo que no se tiene un punto de comparación con otros trabajos en la literatura. De todos modos, consideramos que la información que aportan es valiosa, pues ayudan a tener un mejor entendimiento de cómo actúan los modelos bajo diferentes circunstancias.

El primer grupo de pruebas contruido está compuesto por analogías que buscan estudiar la capacidad de representar las conjugaciones de los verbos. Se eligen doce formas verbales a evaluar (e.g. participio, gerundio) y se arman grupos de analogías con el verbo en infinitivo y cada una de estas formas verbales. Esto es, para el verbo *correr* se arma, por ejemplo, una analogía de la forma *correr es a corriendo lo que cantar es a cantando* y una de la forma *corrido es a correr lo que jugado es a jugar*.

---

<sup>4</sup>Dicha traducción no fue utilizada en el proyecto porque se publicó una vez que ya se había traducido el conjunto de pruebas. Aún así, se realizó una comparación entre ambas traducciones y se vio que la misma contenía algunos errores.

Para la construcción de dicho conjunto, se eligieron los 147 verbos más comunes del español<sup>5</sup>, se obtuvieron sus conjugaciones<sup>6</sup>, y se generaron un grupo de analogías para cada una de las doce formas verbales. Estos grupos se armaron tomando, para cada verbo, otros diez verbos de la lista y construyendo analogías de la forma *verbo\_infinitivo\_1 es a verbo\_conjugado\_1 lo que verbo\_infinitivo\_2 es a verbo\_conjugado\_2*, o en el orden inverso, con el conjugado primero.

Esta tarea se realizó con la ayuda de un script que facilitó la tarea de conjugar y elegir verbos aleatoriamente, asegurando una distribución no sesgada en el conjunto de pruebas. Así, se obtuvieron 1470 analogías por cada grupo, teniendo un total de 17640 analogías dedicadas al estudio de conjugaciones verbales.

Buscando estudiar la relación de los vectores con el corpus utilizado para el entrenamiento, también se generaron analogías utilizando conjugaciones verbales específicas al Río de la Plata (en particular, la conjugación de *vos*, o *voseo*), con el fin de ver la performance de los vectores en estas pruebas cuando se entrena con un corpus exclusivamente rioplatense, uno exclusivamente español, o uno global. La construcción de dicho conjunto de pruebas fue igual al recién detallado, donde se toma una única forma verbal en lugar de doce.

El último conjunto de analogías construido estudia el género de sustantivos. Más específicamente, toma ocupaciones (como *plomero*, *maestro*, o *doctor*) y genera analogías de la forma *doctor es a doctora lo que pescador es a pescadora*. Para su construcción, se tomó una lista de 78 ocupaciones en sus formas masculina y femenina<sup>7</sup> y se generaron analogías en un esquema similar a los anteriores, donde cada ocupación fue emparejada con otras seis ocupaciones, teniendo así un total de 468 entradas.

Se construyeron, por último, dos conjuntos de pruebas siguiendo el esquema *odd-one-out* descrito en el capítulo anterior. El primero no estudia fenómenos particulares del español, sino que tiene un enfoque semántico: busca identificar la palabra que no encaja (desde el punto de vista de su significado) con un conjunto de varias palabras. Para ello, se obtuvieron listas de palabras por campo semántico<sup>8</sup>, como colores, frutas, y vehículos, y se generaron combinaciones con tres o cuatro palabras de un campo particular y una de otro. Se construyó un

---

<sup>5</sup>Acorde a [cita].

<sup>6</sup>Las conjugaciones se consiguieron mediante el scraping de [cita].

<sup>7</sup>La lista fue tomada de [cita].

<sup>8</sup>Obtenidas mediante [cita].

conjunto con un total de 529 entradas con estas características, obteniendo así una forma de probar la capacidad de los vectores de agrupar palabras similares sin tener que recurrir a una prueba que asigne puntajes (a veces arbitrarios) a pares de palabras, como en el caso de las pruebas de similitud antes mencionadas.

El segundo conjunto de pruebas de este esquema tiene las mismas características pero propone pruebas sintácticas en lugar de semánticas. Para ello, se generaron entradas utilizando la misma lista de 147 verbos y se armaron diez pruebas para cada uno de ellos. Se tomaron cinco formas verbales y se generaron así cinco subconjuntos de pruebas con 294 entradas cada una, obteniendo un total de 1470 entradas.

En la tabla 5.7 se listan todos los conjuntos de pruebas contruidos en esta sección, junto a la cantidad de entradas de cada uno y cuál es su propósito (i.e. qué área buscan evaluar).

En la tabla 5.8 se muestran los resultados a los que llegan las mejores dos representaciones vectoriales de cada algoritmo. En el caso de los conjuntos sintácticos, se dividen también por conjugación verbal. También se incluye el modelo vectorial entrenado con texto de foros argentinos (*Bad quality text*, W05).

El primer punto a notar es que en el caso de las analogías los mejores resultados son similares a los obtenidos en la sección anterior, con las pruebas de ocupaciones levemente superiores y las de verbos algunos puntos por debajo. El algoritmo que mejor funciona en la tarea de analogías es nuevamente *word2vec*, con *GloVe* en segundo lugar y *PPMI/SVD* en tercero.

Observando los valores, es posible ver que los resultados de las pruebas varían significativamente entre una conjugación y otra: mientras los gerundios (T02-04) llegan a un acierto de 0,84, el futuro subjuntivo (T02-11) obtiene sólo 0,08. Esto parece razonable, pues una conjugación es mucho más usada que la otra, y los algoritmos aprenden mejores representaciones para palabras más comunes<sup>9</sup>.

De hecho, uno de los principales problemas con el conjunto T02-11 es que muchas de las palabras que lo componen no se encuentran ni siquiera en el

---

<sup>9</sup>Esto es especialmente cierto en el lenguaje empleado en las noticias, que abarcan la mayor parte del corpus.

Conjunto	Tipo	Descripción	Cantidad de entradas
T01	Ana.	Géneros de ocupaciones	468
T02-01	Ana.	Conj. verb. (infinitivo y condicional)	1470
T02-02	Ana.	Conj. verb. (infinitivo y pret. subj. singular)	1470
T02-03	Ana.	Conj. verb. (infinitivo y futuro plural)	1470
T02-04	Ana.	Conj. verb. (infinitivo y gerundio)	1470
T02-05	Ana.	Conj. verb. (infinitivo y pretérito)	1470
T02-06	Ana.	Conj. verb. (infinitivo y participio)	1470
T02-07	Ana.	Conj. verb. (infinitivo y pretérito simple)	1470
T02-08	Ana.	Conj. verb. (infinitivo y presente plural)	1470
T02-09	Ana.	Conj. verb. (infinitivo y presente singular)	1470
T02-10	Ana.	Conj. verb. (infinitivo y pretérito imperfecto)	1470
T02-11	Ana.	Conj. verb. (infinitivo y futuro subjuntivo)	1470
T02-12	Ana.	Conj. verb. (infinitivo y pret. subj. plural)	1470
T03	Ana.	Conj. verb. con voseo	1470
T04	OOO	Tuplas por campo semántico	529
T05-01	OOO	Conj. verb. (condicional en infinitivos)	294
T05-02	OOO	Conj. verb. (futuro en infinitivos)	294
T05-03	OOO	Conj. verb. (pretérito en infinitivos)	294
T05-04	OOO	Conj. verb. (futuro en presentes)	294
T05-05	OOO	Conj. verb. (futuro en futuro subjuntivo)	294

Cuadro 5.7: Listado de conjuntos de pruebas utilizados para el español.

vocabulario del mejor modelo vectorial<sup>10</sup>, lo que hace que casi la tercera parte de las entradas no puedan ser respondidas correctamente. Es de esperar, por lo tanto, que si se obtiene un corpus con una mejor distribución de conjugaciones

<sup>10</sup>Los datos completos de la cantidad de palabras faltantes no se exponen por brevedad, pero por referencia, en el mejor modelo vectorial se tienen veinte palabras faltantes en el conjunto T02-11, lo que provoca 365 entradas faltantes o un 25 % del total.

Conjunto	W01	W02	S01	G01	G02	S02	W05
T01	64 %	63 %	45 %	46 %	46 %	46 %	45 %
T02	54 %	52 %	42 %	42 %	31 %	32 %	44 %
T02-01	38 %	32 %	15 %	13 %	16 %	17 %	17 %
T02-02	68 %	62 %	48 %	48 %	40 %	50 %	40 %
T02-03	49 %	49 %	41 %	41 %	24 %	19 %	36 %
T02-04	83 %	84 %	75 %	75 %	64 %	63 %	79 %
T02-05	65 %	64 %	51 %	50 %	44 %	45 %	60 %
T02-06	54 %	55 %	45 %	46 %	33 %	33 %	46 %
T02-07	61 %	46 %	45 %	44 %	23 %	25 %	42 %
T02-08	67 %	68 %	59 %	59 %	35 %	35 %	68 %
T02-09	52 %	52 %	44 %	44 %	30 %	31 %	50 %
T02-10	56 %	57 %	40 %	40 %	29 %	29 %	48 %
T02-11	7 %	15 %	8 %	6 %	11 %	3 %	6 %
T02-12	47 %	45 %	33 %	33 %	23 %	32 %	33 %
T03	18 %	19 %	9 %	10 %	12 %	12 %	29 %
T04	90 %	81 %	78 %	77 %	86 %	87 %	73 %
T05	80 %	74 %	75 %	76 %	67 %	65 %	80 %
T05-01	70 %	70 %	77 %	77 %	48 %	47 %	73 %
T05-02	88 %	85 %	86 %	86 %	60 %	59 %	91 %
T05-03	82 %	82 %	76 %	75 %	84 %	80 %	79 %
T05-04	85 %	77 %	75 %	77 %	85 %	79 %	74 %
T05-05	72 %	56 %	62 %	64 %	58 %	60 %	85 %

Cuadro 5.8: Desempeño de los principales modelos en las pruebas del español. Nota: T02 y T05 son los promedios de los resultados en los subconjuntos que los componen.

verbales, el resultado de las pruebas mejore significativamente.

Siguiendo la discusión de la sección anterior respecto al uso de tildes en el corpus, es interesante ver que en el conjunto T02-07 (conjugaciones en pretérito simple, tercera persona del singular) el resultado obtenido por el modelo vectorial que mantiene los tildes es significativamente superior al que no usa, presentando una mejora de un 32 %.

Esto refuerza la idea de que los tildes ayudan a desambiguar palabras que

de otra forma serían polisémicas. En el caso de esta conjugación verbal, permite distinguir entre *cambió* y *cambio*, *cortó* y *corto*, o *sacó* y *saco*. De hecho, la única otra conjugación verbal para la cual hay una diferencia grande entre ambas modalidades de preprocesamiento es en T02-11 (subjuntivo futuro, singular), pues es la otra donde hay colisiones de palabras al remover los tildes: *apagare* y *apagaré*, *volare* y *volaré*, o *tocare* y *tocaré*. Las otras conjugaciones que utilizan tildes, como T02-01 (condicionales), no pasan a ser otra conjugación al removerlos.

Es interesante ver que el aumento en los aciertos en el top 1 y el top 10 es mucho mayor para el caso de los verbos (pasando de 0,54 a 0,77 en el mejor modelo) que en el caso de las ocupaciones (que va de 0,63 a 0,78). Esto podría explicarse porque en el caso de los verbos es más posible que se confunda la palabra con distintas conjugaciones de la misma (que muchas veces pueden utilizarse en contextos similares), lo que más difícilmente ocurre en el caso de ocupaciones (por haber dos ejes para variar: género y número).

En cuanto a las pruebas del tipo *odd-one-out*, los resultados obtenidos son muy elevados, con el 90 % y 80 % de las respuestas siendo correctas en las pruebas semánticas y sintácticas, respectivamente. El mejor algoritmo vuelve a ser *word2vec*, pero en el caso de la prueba semántica, T04, PPMI/SVD está en un cercano segundo lugar.

En las prueba sintáctica (T05), sin embargo, PPMI/SVD consigue resultados bastante inferiores a los otros modelos, con GloVe en un segundo lugar. Este punto sigue apoyando la noción de que el modelo estadístico captura mejor las relaciones semánticas entre las palabras que las relaciones sintácticas, pues vuelve a sobresalir en este escenario al igual que lo hizo en las tareas de similitud de palabras.

Este último punto es importante, porque parecería indicar que PPMI/SVD logra capturar únicamente relaciones de más alto nivel, donde las relaciones de coocurrencia son más fuertes, y no las sutilezas entre usos de palabras menos frecuentes, como distintas conjugaciones de verbos en las que cada variante aparece una menor cantidad de veces. Esto coincide con las conclusiones de [59], en la que los autores plantean que la principal fortaleza de *word2vec* (específicamente, de Skipgram con negative sampling) radica en la capacidad que tiene este algoritmo de no sobrerrepresentar palabras demasiado comunes, distribuyendo la información en los vectores de manera más uniforme.

En la tabla 5.8 también se muestran los resultados de las evaluaciones con el

conjunto de conjugaciones verbales específicas del Río de la Plata (T03). Es interesante ver cómo los modelos vectoriales que son entrenados exclusivamente con texto de foros argentinos (en este caso W05) obtienen mejores resultados que los entrenados con la totalidad del texto. En los modelos vectoriales grandes hay también muchas ocurrencias del *voseo* (principalmente viniendo de los sitios de literatura amateur), pero proporcionalmente es mayor la cantidad en los modelos construidos a partir de foros, por tener un tono más informal y conversacional.

Este último punto vuelve a resaltar la importancia de la composición del corpus de entrenamiento, además de indicar una especie de dilución de los vectores de palabras cuando la ocurrencia de las mismas se encuentra limitada a una sección del corpus completo (en este caso, el uso del *voseo* a foros y sitios de literatura amateur, y no tanto en noticias).

## 5.4. Análisis Cualitativo de Resultados

En las secciones anteriores se presentó un análisis formal basado en la evaluación de vectores con características variadas bajo una serie de conjuntos de prueba común. Se realizó además una comparación con la literatura existente para el caso del inglés. En esta sección se presenta un estudio más intuitivo de los resultados obtenidos a través de una serie de ejemplos con características interesantes.

Los ejemplos mostrados a continuación fueron generados utilizando dos modelos diferentes, ambos entrenados utilizando `word2vec`. En uno de los casos se entrenó utilizando un corpus compuesto de documentos de todas las fuentes recopiladas hasta principios de noviembre de 2015, totalizando aproximadamente unos cuatro mil millones de palabras (W01). En el otro caso se utilizaron solamente documentos uruguayos con fecha no más reciente que octubre de 2015, alcanzando un total de 475 millones de palabras (W04).

Para el análisis cualitativo se realizaron dos tipos de ensayos: analogías y palabra que no encaja. Las analogías son del estilo *peso es a Uruguay lo que rupia es a India*. En términos vectoriales se puede expresar como  $rupia \approx india + (peso - uruguay)$ . El segundo ensayo consiste en detectar que *amarillo* es la palabra que no encaja en la lista *saturno, marte, venus, amarillo, urano*.



Comenzamos presentando en los cuadros 5.9 y 5.10 analogías relacionadas a presidentes y monedas de países. En ambos casos se utilizó el modelo W01 y como puede apreciarse el modelo se comporta de forma deseable.

En el caso de presidentes se parte de la relación de Uruguay con el expresidente José Mujica y tanto para Brasil como para España se obtienen sus actuales primeros mandatarios, Dilma Rousseff y Mariano Rajoy, y también exmandatarios como son Luiz Inácio Lula da Silva y José Luis Rodríguez Zapatero. En el caso de Argentina se obtienen tanto el nombre como el apellido de la expresidenta Cristina Fernández de Kirchner.

uruguay $\Rightarrow$ mujica brasil $\Rightarrow$ ?	uruguay $\Rightarrow$ mujica espana $\Rightarrow$ ?	uruguay $\Rightarrow$ mujica argentina $\Rightarrow$ ?
dilma, 0.68 rousseff, 0.67 lula, 0.66	zapatero, 0.54 rajoy, 0.54	kirchner, 0.64 cristina, 0.62

Cuadro 5.9: Analogías para países y presidentes.

Para el caso de analogía de monedas también se obtienen resultados satisfactorios. Se parte de la relación entre Uruguay y peso y se obtienen las monedas actuales o recientes de España, Japón e India. En el caso de India, se obtiene también taka, moneda oficial de Bangladesh.

uruguay $\Rightarrow$ pesos espana $\Rightarrow$ ?	(uruguay, pesos india $\Rightarrow$ ?	uruguay $\Rightarrow$ pesos japon $\Rightarrow$ ?
pesetas, 0.59 euros, 0.50	rupias, 0.60 takas, 0.48	yenes, 0.58 yens, 0.50

Cuadro 5.10: Analogías para países y monedas.

En el cuadro 5.11 se presenta un ejemplo relacionado al fútbol. Se parte de la relación entre el club español Valencia CF y su estadio Mestalla, y se obtiene tanto como para el club español Real Madrid y el club argentino Boca Juniors los nombres de sus respectivos estadios; Santiago Bernabéu y Bombonera. Se explora también cómo se comporta el modelo cuando se le presentan conceptos relacionados a dos clubes de gran rivalidad deportiva. Se parte entonces de la relación del club Real Madrid y su exentrenador José Mourinho y se obtiene para el FC Barcelona el nombre de su también exentrenador Pep Guardiola.

Se buscó también ver los resultados proporcionados por el modelo al explorar la relación entre compañías y sus principales productos. En el cuadro 5.12

valencia $\Rightarrow$ mestalla madrid $\Rightarrow$ ?	valencia $\Rightarrow$ mestalla boca $\Rightarrow$ ?	madrid $\Rightarrow$ mourinho barcelona $\Rightarrow$ ?
bernabeu, 0.79 madridista, 0.74	bombonera, 0.60 xeneize, 0.55	guardiola, 0.80 cule, 0.74

Cuadro 5.11: Analogías relacionadas al fútbol.

se parte de la relación entre Volkswagen, fabricante alemán de automóviles, y la palabra autos y se obtienen interesantes resultados para las compañías Sony, Apple y Zara.

volkswagen $\Rightarrow$ autos sony $\Rightarrow$ ?	volkswagen $\Rightarrow$ autos apple $\Rightarrow$ ?	volkswagen $\Rightarrow$ autos zara $\Rightarrow$ ?
dvds, 0.67 lcds, 0.62 consolas, 0.62	iphones, 0.65 ipods, 0.64 smartphones, 0.63	tiendas, 0.52 accesorios, 0.51 zapaterias, 0.51

Cuadro 5.12: Analogías relacionadas a marcas y sus productos.

Se realizaron también algunas pruebas con analogías de personajes de ficción. En el cuadro 5.13 se puede ver la relación entre nombres y apellidos (o nombre compuesto) de personajes y la relación entre el título de un libro y el apellido de su autor. Se puede ver como la relación entre Darth y Vader ayuda a construir el nombre Frodo Baggins. En el caso de Harry Potter y Ron Weasley podemos observar que el modelo se confunde y relaciona la palabra ron con su acepción como bebida alcohólica, sugiriendo por tanto la marca de ron Bacardi.

darth $\Rightarrow$ vader frodo $\Rightarrow$ ?	harry $\Rightarrow$ potter ron $\Rightarrow$ ?	harry $\Rightarrow$ potter hermione $\Rightarrow$ ?	anillos $\Rightarrow$ tolkien potter $\Rightarrow$ ?
baggins, 0.65 hobbit, 0.62 elijah, 0.60	bacardi, 0.59 harpper, 0.59 dennis, 0.58	weasley, 0.60 granger, 0.57 grint, 0.55	harry, 0.69 rowling, 0.63 hallows, 0.58

Cuadro 5.13: Analogías relacionadas a personajes y autores de ficción.

Como ya se comentó, se realizaron también pruebas de palabra que no encaja. Se presentan a continuación los resultados del modelo W01 cuando se mezcla un político entre escritores, un político uruguayo entre políticos europeos y un futbolista inglés entre futbolistas brasileños. Los resultados en estos casos fueron todos satisfactorios.

```
>>> w01.doesnt_match(['rowling', 'tolkien', 'cortazar',
```

```

                                'obama' ] )
<<< 'obama'

>>> w01.doesnt_match(['cameron', 'putin', 'mujica',
                        'merkel', 'rajoy'])
<<< 'mujica'

```

También resultó interesante explorar analogías relacionadas estrictamente con Uruguay, utilizando el modelo W04. Se incluyen en el cuadro 5.14 analogías relacionadas a entes y figuras estatales de Uruguay. En el cuadro 5.15 se presentan analogías referentes al fútbol uruguayo y algunas de sus figuras más relevantes.

agua $\Rightarrow$ ose energía $\Rightarrow$ ?	ose $\Rightarrow$ agua ancap $\Rightarrow$ ?	interior $\Rightarrow$ bonomi ancap $\Rightarrow$ ?
ute, 0.71 ruchansky, 0.67	petroleo, 0.57 hidrocarburos, 0.55	coya, 0.62 sendic, 0.58

Cuadro 5.14: Analogías relacionadas a entes públicos uruguayos.

manya $\Rightarrow$ penarol bolso $\Rightarrow$ ?	pacheco $\Rightarrow$ penarol recoba $\Rightarrow$ ?	defensor $\Rightarrow$ franzini river $\Rightarrow$ ?
tricolores, 0.51 bolsos, 0.50	danubio, 0.68 tricolor, 0.68	plate, 0.67 saroldi, 0.65

Cuadro 5.15: Analogías relacionadas al fútbol uruguayo.

Finalmente, se logró comprobar que, en algunos casos, las analogías referentes a Uruguay que funcionan muy bien en el modelo reducido se pierden cuando se las evalúa en el modelo completo. En el cuadro 5.16 puede observarse el comportamiento en el modelo W01 de algunas de las analogías evaluadas satisfactoriamente en el modelo W04.

manya $\Rightarrow$ penarol bolso $\Rightarrow$ ?	ose $\Rightarrow$ agua ancap $\Rightarrow$ ?
mochila, 0.61 maleta, 0.61 bolsito, 0.60	cual, 0.47 estalactita, 0.46 liquido, 0.46

Cuadro 5.16: Analogías relacionadas a Uruguay con modelo completo.

## Capítulo 6

# Conclusiones y Trabajo Futuro

Como resultado final del proyecto se logró construir un corpus en idioma español de casi seis mil millones de palabras, el cual resultó sumamente útil para la construcción de vectores de palabras. Se desarrolló además una herramienta que permite, entre otras cosas, consultar el corpus generado, utilizar dicho corpus (o un subconjunto de sus documentos) para entrenar y evaluar vectores de palabras y controlar los distintos mecanismos para continuar agregando documentos al corpus de manera continua. Es importante resaltar que todos los objetivos planteados al comienzo del proyecto fueron alcanzados de forma satisfactoria.

Desde el punto de vista académico se tuvo la oportunidad de realizar una investigación profunda en un área en pleno auge y desarrollo, como es la construcción, aplicación y evaluación de vectores de palabras. Además, se logró investigar y aplicar muchas herramientas y técnicas para el desarrollo de aplicaciones web, scraping de internet, extracción y almacenamiento de grandes cantidades de datos, etc. De esta manera, se logró elaborar un proyecto que requirió aplicar de forma integral una gran cantidad de experiencias y conocimientos adquiridos durante la carrera y nuestra actividad profesional.

En las próximas secciones incluimos un compilado de las principales conclusiones obtenidas, junto con una serie de propuestas y caminos para futuros trabajos en el área.

## 6.1. Conclusiones

Como era esperado, se logró comprobar la gran dificultad de trabajar con vectores de palabras. Entre los principales desafíos se encuentra la necesidad de contar con un corpus masivo, lo cual en sí mismo conlleva una serie de desafíos de implementación y almacenamiento. Cómo se pudo comprobar al realizar el estudio de estado del arte, la construcción de corpus de gran tamaño continúa siendo un problema abierto. En particular, es necesario un cuidadoso proceso de selección de fuentes y posterior limpieza de los datos obtenidos para obtener buenos resultados al entrenar vectores con los mismos.

Además, una vez construido el corpus, se comprobó que el entrenamiento de los vectores, así como su posterior evaluación, son tareas que requieren una gran capacidad de cómputo si se espera poder realizarlas en tiempos razonables. Por otro lado, el almacenamiento de un corpus masivo y de los vectores generados requiere también una considerable cantidad de espacio en disco. Ambos tipos de capacidades requeridas superan las de una computadora de uso general.

Aun con servidores que cuenten con la capacidad requerida, el entrenamiento de un vector de palabras puede llevar varios días. Esto dificulta la posibilidad de probar la combinación de diferentes hiperparámetros para encontrar el mejor resultado.

A pesar de todas las dificultades mencionadas, no cabe duda que el campo de los vectores de palabras es sumamente interesante. Recientemente se han escrito multitud de trabajos relacionados con resultados prometedores y el área continua siendo objeto de una intensa y rica investigación, por lo cuál resulta un tema de investigación muy atractivo con posibilidades reales para realizar contribuciones significativas. Encontrar la técnica óptima para la construcción de vectores de palabras sigue siendo un problema abierto, pero este parece ser el mejor camino para conectar el campo de *deep learning* al PLN.

## 6.2. Trabajo Futuro

Se identifican dos grandes caminos para extender y continuar lo realizado en el proyecto de grado. El primero va por seguir las tareas de generación del

corpus y de construcción de la herramienta, mientras que el segundo por continuar la línea de investigación identificada durante el relevamiento del estado del arte y de la evaluación de los modelos vectoriales.

**Corpus** Respecto al corpus de texto construido, se obtuvo un tamaño muy satisfactorio, pero se podría conseguir un volumen incluso mayor y con más variedad: se priorizó incluir fuentes de palabras diversas con el objetivo de mostrar qué tipos de datos existen, pero para cada una de estas áreas es posible recolectar aún más palabras.

La mayor parte del corpus generado consta de noticias, pero se podrían incluir libros de texto (en [12] los autores obtienen dos mil millones de palabras de libros en italiano, y en el presente proyecto apenas se incluyeron libros), más literatura amateur, más subtítulos (incluyendo películas además de series), más foros (de distintas temáticas, se tomó un único sitio), el resto de los portales de Wikimedia (como Wikilibros, Wikiviajes, y Wikicitas), y más documentos oficiales (podrían buscarse parlamentos de otros países además de Uruguay).

Yendo más allá del español, se podría incluir texto en otros idiomas; todos los documentos que se almacenaron se etiquetaron como texto en español, por lo que no sería necesario adaptar ninguna parte del proyecto.

**Herramienta** La herramienta cumplió con los objetivos planteados originalmente, pero vemos muchas oportunidades de mejora que podrían aumentar su versatilidad y utilidad en futuros proyectos.

Por un lado, por más que la arquitectura fue pensada con un enfoque distribuido que permite escalar agregando más nodos trabajadores, presenta algunas debilidades que podrían hacerla menos robusta; por ejemplo, la transferencia de modelos vectoriales y datos de entrenamiento entre nodos puede ser un cuello de botella importante. Su comportamiento no ha sido evaluado en profundidad salvo por el escenario donde se corrió, por lo que sería recomendable desplegar la aplicación en un cluster dedicado y ponerla a prueba.

Otra funcionalidad de utilidad sería implementar un sistema de autenticación de usuarios que brinde acceso común al corpus pero que permita mantener distintos conjuntos de modelos para cada usuario. Dicho sistema permitiría también restringir el acceso a la herramienta para usuarios no identificados, evi-

tando así que un usuario malintencionado entre a la aplicación e interfiera con el correcto funcionamiento (por ejemplo, entrenando miles de modelos vectoriales).

En cuanto a la administración de representaciones vectoriales, sería de gran utilidad poder dar de alta y entrenar modelos masivamente pasando una lista de hiperparámetros a utilizar, en lugar de crearlos de a uno como se hace en la actualidad. Se podría permitir, incluso, que dada una lista de conjuntos de pruebas se busque el modelo que mejores resultados obtenga automáticamente, realizando una exploración del espacio de hiperparámetros (claro está, acotado) y empleando validación cruzada para evaluarlos, de manera similar al enfoque tomado por los autores en [60].

Relacionado al último punto, sería bueno también agregar más opciones de evaluación, incluyendo idealmente algún tipo de evaluación implícita para la cual valga la pena optimizar al máximo la performance de los modelos vectoriales.

Por último, con el fin de evitar tener que descargar las representaciones vectoriales para hacer pruebas básicas, sería bueno ofrecer más funcionalidades de introspección de las mismas permitiendo, por ejemplo, probar analogías desde la misma aplicación web, de manera de hacer evaluaciones cualitativas simples fácilmente. También se podría utilizar en algoritmo tSNE [66] para mostrar una visualización de algunas palabras comunes en el espacio de vectores.

**Investigación** A raíz de los resultados obtenidos en el proceso de evaluación realizado, surge la necesidad de estudiar en mayor profundidad el comportamiento de los modelos vectoriales en los escenarios particulares vistos en el proyecto. Por ejemplo, investigar qué es lo que hace que algunas conjugaciones verbales sean más fáciles de recuperar que otras, si la cantidad de ocurrencias en el corpus de entrenamiento es lo único que las afecta o si existe una propiedad inherente a las mismas que disminuye su performance (como el hecho de ser una construcción gramatical más compleja en, e.g., conjugaciones del subjuntivo).

Viendo también la influencia que tuvo el eliminar los tildes del corpus de entrenamiento en los resultados obtenidos, el estudio de cómo tratar palabras polisémicas parecería ser una rama de investigación con potencial para mejorar en gran medida la calidad de las representaciones obtenidas.

Durante el relevamiento del estado del arte también se identificaron algunas líneas de investigación más generales que resultarían muy interesantes de continuar. Una de ellas, planteada por los autores en [59], es buscar mejoras en la factorización de la matriz PPMI de los modelos estadísticos, pues ya se vio cómo las palabras con pocas ocurrencias (como conjugaciones verbales menos comunes) obtienen representaciones inferiores, afectando la performance en las tareas de analogías.

Otro punto a investigar, planteado en el capítulo 2, es la relación entre la evaluación implícita y explícita de los modelos vectoriales, y ver hasta qué punto se transfiere el hecho de obtener buena performance en tareas como las analogías a tareas de mayor complejidad y que usen los vectores como parte de una solución de mayor porte.

Como última propuesta de investigación, y algo que se tocó brevemente durante el proceso evaluación, es estudiar en mayor profundidad la viabilidad de emplear vectores preentrenados genéricos para otras tareas de PLN, y ver qué tan inferiores éstos resultan comparando con vectores entrenados para una tarea específica con, por ejemplo, texto del dominio particular.





# Bibliografía

- [1] *Ace: High performance code editor for the web*. Accedido: 2016-05-05. URL: <https://ace.c9.io/>.
- [2] Abdulrahman Almuhareb. "Attributes in Lexical Acquisition". En: *PhD Thesis, University of Essex* (2006).
- [3] *Amazon AWS EC2*. Accedido: 2016-05-04. URL: <https://aws.amazon.com/ec2/>.
- [4] *Amazon Simple Storage Service*. Accedido: 2016-05-04. URL: <https://aws.amazon.com/s3/>.
- [5] *Angular Material*. Accedido: 2016-05-05. URL: <https://material.angularjs.org/latest/>.
- [6] *AngularJS*. Accedido: 2016-05-05. URL: <https://angularjs.org/>.
- [7] *Apache Lucene*. Accedido: 2016-05-04. URL: <https://lucene.apache.org/>.
- [8] *AWS Programs for Research and Education*. Accedido: 2016-05-04. URL: <https://aws.amazon.com/grants/>.
- [9] Marco Baroni, Silvia Bernardini, Adriano Ferraresi y Eros Zanchetta. "The waCky wide web: A collection of very large linguistically processed web-crawled corpora". En: *Language Resources and Evaluation* 43.3 (2009), págs. 209-226. ISSN: 1574020X. DOI: 10.1007/s10579-009-9081-4.
- [10] Marco Baroni, Georgiana Dinu y German Kruszewski. "Don't count, predict! A systematic comparison of context-counting vs. context-predicting semantic vectors". En: *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics*. (2014), págs. 238-247. DOI: 10.3115/v1/P14-1023.

- [11] Yoshua Bengio, Réjean Ducharme, Pascal Vincent y Christian Janvin. "A Neural Probabilistic Language Model". En: *The Journal of Machine Learning Research* 3 (2003), págs. 1137-1155. DOI: 10.1162/153244303322533223. arXiv: arXiv:1301.3781v3.
- [12] Giacomo Berardi, Andrea Esuli y Diego Marcheggiani. "Word embeddings go to Italy: A comparison of models and training datasets". En: *CEUR Workshop Proceedings* 1404 (2015). ISSN: 16130073.
- [13] David M Blei, Andrew Y Ng y Michael I Jordan. "Latent Dirichlet Allocation". En: *Journal of Machine Learning Research* 3.4-5 (2012), págs. 993-1022. DOI: 10.1162/jmlr.2003.3.4-5.993. arXiv: 1111.6189v1.
- [14] Antonio Briz y Marta Albelda. *Estado actual de los corpus de lengua española hablada y escrita*. Accedido: 2016-05-03. URL: [http://cvc.cervantes.es/lengua/anuario/anuario\\_09/briz\\_albeida/p01.htm](http://cvc.cervantes.es/lengua/anuario/anuario_09/briz_albeida/p01.htm).
- [15] Peter Brown, Peter DeSouza, Robert Mercer, Vincent Pietra y Jenifer Lai. "Class-based n-gram models of natural language". En: *Comput. Linguist.* 18.4 (1992), págs. 467-479.
- [16] Elia Bruni y Daniel Gatica-perez. "Multimodal distributional semantics Marco Baroni , Thesis Advisor". En: 48.December (2013).
- [17] John a Bullinaria y Joseph P Levy. "Extracting semantic representations from word co-occurrence statistics: a computational study." En: *Behavior research methods* 39.3 (2007), págs. 510-26. ISSN: 1554-351X.
- [18] John a Bullinaria y Joseph P Levy. "Extracting semantic representations from word co-occurrence statistics: stop-lists, stemming, and SVD." En: *Behavior research methods* 44.3 (2012), págs. 890-907. DOI: 10.3758/s13428-011-0183-8.
- [19] Cristian Cardellino. *Spanish Billion Words Corpus and Embeddings*. Accedido: 2016-04-27. URL: <http://crscardellino.me/SBWCE/>.
- [20] John Caron. "Experiments with LSA scoring: Optimal rank and basis". En: *In Proceedings of SIAM Computational Information Retrieval Workshop* (2000), págs. 1-14.
- [21] *Celery: Distributed Task Queue*. Accedido: 2016-05-05. URL: <http://www.celeryproject.org/>.
- [22] *Chart.js: Open source HTML5 Charts*. Accedido: 2016-05-05. URL: <http://www.chartjs.org/>.

- [23] Kenneth Ward Church y Patrick Hanks. "Word association n-grams, Mutual Information, and lexicography". En: *Proceedings of the 27th Annual Conference of the Association for Computational Linguistics* 16.1 (1989), págs. 22-29. DOI: 10.3115/981623.981633.
- [24] Ronan Collobert y Jason Weston. "A unified architecture for natural language processing". En: *Proceedings of the 25th international conference on Machine learning - ICML '08* 20.1 (2008), págs. 160-167. ISSN: 07224028. DOI: 10.1145/1390156.1390177.
- [25] Ronan Collobert, Jason Weston, Léon Bottou, Michael Karlen, Koray Kavukcuoglu y Pavel Kuksa. "Natural Language Processing (almost) from Scratch". En: *Journal of Machine Learning Research* 1 (2011), págs. 1-48. DOI: 10.1145/2347736.2347755. arXiv: 1103.0398.
- [26] Mark Davies. *Corpus del Español*. Accedido: 2016-04-27. 2002. URL: <http://www.corpusdelespanol.org/>.
- [27] Scott Deerwester, Susan T. Dumais y Richard Harshman. "Indexing by latent semantic analysis". En: *Journal of the American society for information science* 41.6 (1990), págs. 391-407. ISSN: 0002-8231. DOI: 10.1002/(SICI)1097-4571(199009)41:6<391::AID-ASI1>3.0.CO;2-9.
- [28] *Diario La Nación*. Accedido: 2016-05-04. URL: <http://www.lanacion.com.ar>.
- [29] Georgiana Dinu. "DISSECT-DIStributional SEMantics Composition Toolkit". En: *Acl* (2) 2010 (2013), págs. 31-36.
- [30] Susan T Dumais, George W Furnas, Thomas K Landauer, Scott Deerwester y Richard Harshman. "Using Latent Semantic Analysis to Improve Access to Textual Information". En: *ACM Conference on Human Factors in Computing Systems, CHI '88* (1988), págs. 281-285. DOI: 10.1145/57167.57214.
- [31] Andreas Eisele y Yu Chen. "MultiUN: A Multilingual Corpus from United Nation Documents." En: *Lrec* (2010), págs. 2868-2872.
- [32] *Elasticsearch*. Accedido: 2015-12-10. URL: <https://www.elastic.co/>.
- [33] *Elasticsearch: Scripting*. Accedido: 2016-05-05. URL: <https://www.elastic.co/guide/en/elasticsearch/reference/current/modules-scripting.html>.
- [34] J L Elman. "Finding structure in time". En: *Cognitive science* 14.2 (1990), págs. 179-211. ISSN: 03640213. DOI: 10.1207/s15516709cog1402\_1.

- [35] *EU Bookshop*. Accedido: 2016-05-04. URL: <http://opus.lingfil.uu.se/EUbookshop.php>.
- [36] Roy Fielding. "Architectural Styles and the Design of Network-based Software Architectures". En: (2000).
- [37] Lev Finkelstein, Evgeniy Gabrilovich, Yossi Matias, Ehud Rivlin, Zach Solan, Gadi Wolfman y Eytan Ruppín. "Placing search in context: the concept revisited". En: *ACM Transactions on Information Systems* 20.1 (2002), págs. 116-131. ISSN: 10468188. DOI: 10.1145/503104.503110.
- [38] J. R. Firth. "Papers in Linguistics". En: (1957).
- [39] *Google Cloud Platform*. Accedido: 2016-05-04. URL: <https://cloud.google.com/>.
- [40] *Google Translate*. Accedido: 2016-04-27. URL: <https://translate.google.com/>.
- [41] Edward Grefenstette. *AMA: Nando de Freitas*.
- [42] *Grunt: The JavaScript Task Runner*. Accedido: 2016-05-05. URL: <http://gruntjs.com/>.
- [43] Michael U Gutmann. "Noise-Contrastive Estimation of Unnormalized Statistical Models, with Applications to Natural Image Statistics". En: *Journal of Machine Learning Research* 13 (2012), págs. 307-361.
- [44] Zellig S. Harris. "Distributional Structure". En: *Papers on Syntax*. Dordrecht: Springer Netherlands, 1954, págs. 3-22. DOI: 10.1007/978-94-009-8467-7\_1.
- [45] Felix Hill, Roi Reichart y Anna Korhonen. "SimLex-999: Evaluating Semantic Models with (Genuine) Similarity Estimation". En: *Computational Linguistics* 41.4 (2015), págs. 665-695. ISSN: 04194217. DOI: 10.1162/COLI.arXiv: 1408.3456.
- [46] Geoffrey E. Hinton. *Learning distributed representations of concepts*. 1986. DOI: 10.1109/69.917563.
- [47] Thomas Hofmann. "Probabilistic Latent Semantic Analysis". En: *Uncertainty in Artificial Intelligence - UAI'99* (1999), pág. 8. ISSN: 15206882. DOI: 10.1.1.33.1187.
- [48] Eric H Huang, Richard Socher, Christopher D Manning y Andrew Ng. "Improving word representations via global context and multiple word prototypes". En: *Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics: Long Papers-Volume 1* (2012), págs. 873-882.

- [49] *Hyperparameter-Enabled Word Representations*. Accedido: 2016-05-05. URL: <https://bitbucket.org/omerlevy/hyperwords>.
- [50] *Jepsen: Elasticsearch 1.5.0*. Accedido: 2016-05-04. URL: <https://aphyr.com/posts/323-jepsen-elasticsearch-1-5-0>.
- [51] *jQuery*. Accedido: 2016-05-05. URL: <https://jquery.com/>.
- [52] *JSON: JavaScript Object Notation*. Accedido: 2016-05-05. URL: <http://www.json.org/>.
- [53] S. Kaski. "Dimensionality reduction by random mapping: fast similarity computation for clustering". En: *1998 IEEE International Joint Conference on Neural Networks Proceedings. IEEE World Congress on Computational Intelligence (Cat. No.98CH36227)* 1.1 (1998), págs. 4-9. ISSN: 1098-7576. DOI: 10.1109/IJCNN.1998.682302.
- [54] Ruth Ann Lund Kevin, Burgess Curt y Atchley. "Semantic and Associative Priming in High-Dimensional Semantic Space". En: *Cognitive Science Proceedings, LEA JANUARY 1995* (1995), págs. 660-665. ISSN: 18736009. DOI: 10.1016/j.jconhyd.2010.08.009.
- [55] Thomas K Landauer y Susan T. Dumais. "A solution to Plato ' s problem : The Latent Semantic Analysis Theory of Acquisition , Induction , and Representation of Knowledge". En: *Psychological Review* 104.2 (1997), págs. 211-240. DOI: 10.1037/0033-295X.104.2.211.
- [56] Avraham Leff y James T. Rayfield. "Web-Application Development Using the Model/View/Controller Design Pattern". En: (2001), págs. 118-.
- [57] *Let's MT!* Accedido: 2016-05-04. URL: <http://letsmt.eu>.
- [58] O Levy, Y Goldberg e I Ramat-Gan. "Linguistic regularities in sparse and explicit word representations". En: *CoNLL-2014* (2014), págs. 171-180.
- [59] Omer Levy y Yoav Goldberg. "Neural Word Embedding as Implicit Matrix Factorization". En: (), págs. 1-9.
- [60] Omer Levy, Yoav Goldberg e Ido Dagan. "Improving Distributional Similarity with Lessons Learned from Word Embeddings". En: *Transactions of the Association for Computational Linguistics* 3 (2015), págs. 211-225. ISSN: 2307-387X.
- [61] Wei Li y Andrew McCallum. "Semi-Supervised Sequence Modeling with Syntactic Topic Models". En: *Proceedings of the 20th International conference on Artificial intelligence (AAAI 2005)* 2 (2005), págs. 813-818.
- [62] Dekang Lin y Xiaoyun Wu. "Phrase clustering for discriminative learning". En: *Proceedings of the Joint Conference of the 47th Annual ... August* (2009), págs. 1030-1038. DOI: 10.3115/1690219.1690290.

- [63] *Los Cuentos*. Accedido: 2016-05-04. URL: <http://loscuentos.net>.
- [64] Kevin Lund y Curt Burgess. "Producing high-dimensional semantic spaces from lexical co-occurrence". En: *Behavior Research Methods, Instruments, & Computers* 28.2 (1996), págs. 203-208. DOI: 10.3758/BF03204766.
- [65] Minh-Thang Luong, Richard Socher y Christopher D. Manning. "Better Word Representations with Recursive Neural Networks for Morphology". En: *CoNLL-2013* (2013), págs. 104-113.
- [66] Laurens Van Der Maaten y Geoffrey Hinton. "Visualizing Data using t-SNE". En: *Journal of Machine Learning Research* 9 (2008), págs. 2579-2605. ISSN: 02545330. DOI: 10.1007/s10479-011-0841-3.
- [67] *Material design*. Accedido: 2016-05-05. URL: <https://www.google.com/design/spec/material-design/>.
- [68] *Mechanical Turk*. Accedido: 2016-04-27. URL: <https://www.mturk.com/>.
- [69] Ângelo Mendonça, Daniel Jaquette, David Graff y Denise DiPersio. *Spanish Gigaword Third Edition*. Accedido: 2016-05-04. URL: <https://catalog.ldc.upenn.edu/LDC2011T12>.
- [70] *Microsoft Azure*. Accedido: 2016-05-04. URL: <https://azure.microsoft.com/en-us/>.
- [71] Risto Miikkulainen y Michael G Dyer. "Natural Language Processing with Modular Neural Networks and Distributed Lexicon". En: *UCLA-AI-90-02* (1990).
- [72] T Mikolov, M Karafiat, L Burget, J Cernocky y S Khudanpur. "Recurrent Neural Network based Language Model". En: *Interspeech* September (2010), págs. 1045-1048.
- [73] Toma Mikolov, Stefan Kombrink, Luka Burget, Jan Cernocky y Sanjeev Khudanpur. "Extensions of recurrent neural network language model". En: *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings* (2011), págs. 5528-5531. ISSN: 15206149. DOI: 10.1109/ICASSP.2011.5947611.
- [74] Tomáš Mikolov. "Language Models for Automatic Speech Recognition of Czech Lectures". En: *Proc. of STUDENT EEICT* 4 (2008).
- [75] Tomas Mikolov, Kai Chen, Greg Corrado y Jeffrey Dean. "Distributed Representations of Words and Phrases and their Compositionality". En: *Nips* (2013), págs. 1-9. ISSN: 10495258. DOI: 10.1162/jmlr.2003.3.4-5.951. arXiv: 1310.4546.

- [76] Tomas Mikolov, Greg Corrado, Kai Chen y Jeffrey Dean. "Efficient Estimation of Word Representations in Vector Space". En: *Proceedings of the International Conference on Learning Representations (ICLR 2013)* (2013), págs. 1-12. DOI: 10.1162/153244303322533223. arXiv: arXiv:1301.3781v3.
- [77] Tomáš Mikolov, Anoop Deoras, Daniel Povey, Lukáš Burget y Jan Černocký. "Strategies for training large scale neural network language models". En: *2011 IEEE Workshop on Automatic Speech Recognition and Understanding, ASRU 2011, Proceedings*. 2011, págs. 196-201. ISBN: 9781467303675. DOI: 10.1109/ASRU.2011.6163930.
- [78] Tomáš Mikolov, Stefan Kombrink, Anoop Deoras, Lukáš Burget y Jan Černocký. "RNNLM — Recurrent Neural Network Language Modeling Toolkit". En: *Proceedings of ASRU 2011* (2011), págs. 1-4.
- [79] Tomáš Mikolov, Jiří Kopecký, Lukáš Burget, Ondřej Glembek y Jan Honza Černocký. "Neural network based language models for highly inflective languages". En: *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings* (2009), págs. 4725-4728. ISSN: 15206149. DOI: 10.1109/ICASSP.2009.4960686.
- [80] Tomas Mikolov, Wen-tau Yih y Geoffrey Zweig. "Linguistic regularities in continuous space word representations". En: *Proceedings of NAACL-HLT June* (2013), págs. 746-751.
- [81] a Mnih y Ge Hinton. "Three new graphical models for statistical language modelling." En: *Proceedings of the 24th International Conference on Machine Learning* (2007) 62 (2007), págs. 641-648. DOI: 10.1145/1273496.1273577.
- [82] Andriy Mnih y Geoffrey E. Hinton. "A Scalable Hierarchical Distributed Language Model." En: *Advances in Neural Information Processing Systems* (2008), págs. 1-8.
- [83] Andriy Mnih y Yee Whye Teh. "A Fast and Simple Algorithm for Training Neural Probabilistic Language Models". En: *Proceedings of the 29th International Conference on Machine Learning (ICML'12)* (2012), págs. 1751-1758. arXiv: 1206.6426.
- [84] Frederic Morin e Y Bengio. "Hierarchical probabilistic neural network language model". En: *Proceedings of the Tenth International Workshop on Artificial Intelligence and Statistics* (2005), págs. 246-252. DOI: 10.1109/JCDL.2003.1204852.
- [85] *MultiUN Corpus*. Accedido: 2016-05-04. URL: <http://opus.lingfil.uu.se/MultiUN.php>.



- [86] *NumPy*. Accedido: 2016-05-05. URL: <http://www.numpy.org/>.
- [87] Sebastian Padó, Ulrike Padó y Katrin Erk. "Flexible, corpus-based modelling of human plausibility judgements". En: *Proceedings of EMNLP-CoNLL 7*. June (2007), págs. 400-409.
- [88] *Parlamento del Uruguay*. Accedido: 2016-05-04. URL: <https://parlamento.gub.uy/>.
- [89] Jeffrey Pennington, Richard Socher y Christopher Manning. "Glove: Global Vectors for Word Representation". En: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Stroudsburg, PA, USA: Association for Computational Linguistics, 2014. DOI: 10.3115/v1/D14-1162.
- [90] Jan Pomikálek. *Removing Boilerplate and Duplicate Content from Web Corpora*. Accedido: 2016-04-28. 2011. URL: [http://is.muni.cz/th/45523/fi\\_d/phdthesis.pdf](http://is.muni.cz/th/45523/fi_d/phdthesis.pdf).
- [91] *PostgreSQL*. Accedido: 2015-12-13. URL: <http://www.postgresql.org/>.
- [92] *Proyecto OPUS*. Accedido: 2016-05-04. URL: <http://opus.lingfil.uu.se/>.
- [93] *Python*. Accedido: 2015-12-13. URL: <https://www.python.org/>.
- [94] *Python asyncio*. Accedido: 2016-05-04. URL: <https://docs.python.org/3/library/asyncio.html>.
- [95] *Python lxml*. Accedido: 2016-05-04. URL: <http://lxml.de/>.
- [96] *Python zipstream lib*. Accedido: 2016-05-05. URL: <https://github.com/allanlei/python-zipstream>.
- [97] Lizhen Qu, Gabriela Ferraro, Liyuan Zhou, Weiwei Hou, Nathan Schneider y Timothy Baldwin. "Big Data Small Data , In Domain Out-of Domain , Known Word Unknown Word : The Impact of Word Representations on Sequence Labelling Tasks". En: *CoNLL-2015* (2015), págs. 83-93. arXiv: 1504.05319.
- [98] Kira Radinsky, Eugene Agichtein, Evgeniy Gabrilovich y Shaul Markovitch. "A word at a time: computing word relatedness using temporal semantic analysis". En: *Proceedings of the 20th International World Wide Web Conference WWW'11* (2011), págs. 337-346. DOI: 10.1145/1963405.1963455.
- [99] Radim Řehůřek y Petr Sojka. "Software Framework for Topic Modelling with Large Corpora". En: (2010), págs. 45-50.

- [100] Rami Al-Rfou, Bryan Perozzi y Steven Skiena. "Polyglot: Distributed Word Representations for Multilingual NLP". En: *Proceedings of the Seventeenth Conference on Computational Natural Language Learning* (2013), págs. 183-192. arXiv: 1307.1662.
- [101] D. E. Rumelhart, G. E. Hinton y R. J. Williams. *Learning Internal Representations by Error Propagation*. 2013. DOI: 10.1016/B978-1-4832-1446-7.50035-2. arXiv: arXiv:1011.1669v3.
- [102] Magnus Sahlgren. "Vector-based Semantic Analysis: Representing Word Meaning Based on Random Labels". En: *ESSLI Workshop on Semantic Knowledge Acquisition and Categorization* (2002). DOI: 10.1.1.20.4588.
- [103] *Sass: Syntactically Awesome Style Sheets*. Accedido: 2016-05-05. URL: <http://sass-lang.com/>.
- [104] *SciPy library*. Accedido: 2016-05-04. URL: <https://www.scipy.org/>.
- [105] *Scrapy*. Accedido: 2016-05-04. URL: <http://scrapy.org/>.
- [106] *Sketch Engine*. Accedido: 2016-05-04. URL: <https://www.sketchengine.co.uk/>.
- [107] Richard Socher, Eric H Huang, Jeffrey Pennin, Christopher D Manning y Andrew Y Ng. "Dynamic pooling and unfolding recursive autoencoders for paraphrase detection". En: *Advances in Neural Information Processing Systems* (2011), págs. 801-809.
- [108] Richard Socher, Jeffrey Pennington y Eh Huang. "Semi-supervised recursive autoencoders for predicting sentiment distributions". En: *Conference on Empirical Methods in Natural Language Processing, EMNLP i* (2011), págs. 151-161. ISSN: 1937284115. DOI: 10.1.1.224.9432.
- [109] Richard Socher, Alex Perelygin y Jy Wu. "Recursive deep models for semantic compositionality over a sentiment treebank". En: *Proceedings of the ...* (2013), págs. 1631-1642.
- [110] *sparsesvd*. Accedido: 2016-05-05. URL: <https://pypi.python.org/pypi/sparsesvd/>.
- [111] Vít Suchomel y Jan Pomikálek. *Efficient Web Crawling for Large Text Corpora*. Accedido: 2016-04-28. URL: [https://nlp.fi.muni.cz/~xsuchom2/papers/PomikalekSuchomel\\_SpiderlingEfficiency.pdf](https://nlp.fi.muni.cz/~xsuchom2/papers/PomikalekSuchomel_SpiderlingEfficiency.pdf).
- [112] *SVDLIBC: C library for computing Singular Value Decompositions*. Accedido: 2016-05-05. URL: <http://tedlab.mit.edu/~dr/SVDLIBC/>.
- [113] *TenTen Corpora*. Accedido: 2016-05-04. URL: <https://www.sketchengine.co.uk/tenten-corpora/>.

- [114] Fei Tian, Hanjun Dai, Jiang Bian, Bin Gao, Rui Zhang, Enhong Chen y Tie-Yan Liu. "A probabilistic model for learning multi-prototype word embeddings". En: *Proceedings of the 25th International Conference on Computational Linguistics (COLING 2014)* 5 (2014), págs. 151-160.
- [115] *Tu Subtítulo*. Accedido: 2016-05-04. URL: <http://www.tusubtitulo.com/>.
- [116] Joseph Turian, Lev Ratinov, Yoshua Bengio y Joseph Turian. "Word Representations: A Simple and General Method for Semi-supervised Learning". En: *Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics* July (2010), págs. 384-394. DOI: 10.1.1.301.5840.
- [117] Peter D Turney. "Mining the Web for synonyms: PMI-IR versus LSA on TOEFL". En: *Proceedings of the 12th European Conference on Machine Learning (ECML-2001), Freiburg, Germany* (2001), págs. 491-502. ISSN: 16113349. DOI: 10.1007/3-540-44795-4\_42. arXiv: 0212033 [cs].
- [118] Jaakko J Väyrynen y Timo Honkela. "Word Category Maps based on Emergent Features Created by ICA". En: ().
- [119] *Webtropia*. Accedido: 2016-05-04. URL: <https://www.webtropia.com/en.html>.
- [120] *Wikimedia*. Accedido: 2016-05-04. URL: <https://www.wikimedia.org/>.
- [121] *Wikipedia Dumps*. Accedido: 2016-05-04. URL: <https://dumps.wikimedia.org/>.
- [122] *Wikipedia Extractor*. Accedido: 2016-05-04. URL: <https://github.com/attardi/wikiextractor>.
- [123] *Wikipedia: Size Comparisons*. Accedido: 2016-05-04. URL: [https://en.wikipedia.org/wiki/Wikipedia:Size\\_comparisons](https://en.wikipedia.org/wiki/Wikipedia:Size_comparisons).
- [124] *Wikitext*. Accedido: 2016-05-04. URL: <https://www.mediawiki.org/wiki/Wikitext>.
- [125] *Word2vec at Google Code*. Accedido: 2016-05-05. URL: <https://code.google.com/archive/p/word2vec/>.
- [126] *Word2vec implementation in Spark MLlib*. Accedido: 2016-05-05. URL: <https://spark.apache.org/docs/latest/mllib-feature-extraction.html#word2vec>.
- [127] *XPath*. Accedido: 2016-05-04. URL: <https://www.w3.org/TR/xpath-31/>.

- 
- [128] Tae Yano y Moonyoung Kang. *Taking advantage of Wikipedia in Natural Language Processing*. Accedido: 2016-05-03. URL: <http://www.cs.cmu.edu/~taey/pub/wiki.pdf>.
- [129] Yeoman. Accedido: 2016-05-05. URL: <http://yeoman.io/>.
- [130] *ZIP File Format Specification*. Accedido: 2016-05-05. URL: <https://pkware.cachefly.net/webdocs/casestudies/APPNOTE.TXT>.
- [131] Will Y Zou, Richard Socher, Daniel Cer y Christopher D Manning. "Bilingual Word Embeddings for Phrase-Based Machine Translation". En: *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing (EMNLP 2013)* October (2013), págs. 1393-1398.